

Parte 2: concentraciones territoriales y composición

Reporte técnico ampliado y auditable

Proyecto Cuenca del Alto Atoyac

Septiembre de 2026

Resumen

Segunda pasada documental sobre la solución espacial fija HDBSCAN. No se reabre la selección ni se altera una membresía. Se explicitan definiciones, parámetros, fórmulas, diagnósticos desagregados, tablas completas y limitaciones. La detección usa 4,365 establecimientos y la interpretación 4,010 dentro de cuenca.

Índice

1. Hallazgo de auditoría y criterio de no modificación	2
2. Diseño metodológico paso a paso	2
2.1. Preparación espacial	2
2.2. Diagnósticos preliminares	2
2.3. Grillas completas	2
2.4. Evaluación y referencia	2
3. ARI: definición, comparaciones y sensibilidad a grupos grandes	3
4. Estabilidad de membresía entre especificaciones	3
5. Mega-cluster 20 y 18 subnúcleos exploratorios	5
5.1. Geometría	5
5.2. Perfilado económico posterior	6
6. Composición multilabel y diccionario analítico	7
7. Sobrerrepresentación	8
8. Lavanderías frente a manufactura	8
8.1. Sensibilidad en seis escenarios	10
9. Tipología y espacio métrico	11
9.1. Por qué son similares los pares principales	14
10.Explorador interactivo	15
11.Actividad dispersa, limitaciones y cierre	15
12.Glosario metodológico permanente	15
A. Las 57 configuraciones exploradas	17
B. Diccionario de variables analíticas	20
C. Índice de resultados completos	23

1. Hallazgo de auditoría y criterio de no modificación

El campo histórico `ari_top5_mismo_metodo` es la *media de las cinco particiones del mismo método con mayor ARI*, no una vecindad definida en el espacio de parámetros. Se conserva el valor histórico para trazabilidad, pero se corrige el lenguaje. La métrica llamada antes “persistencia territorial” es una fracción de acuerdo individual no ponderada entre cinco especificaciones, después de emparejar clusters por máximo Jaccard; no es cohesión ni `cluster_persistence_` de HDBSCAN. Ningún resultado se cambió silenciosamente.

2. Diseño metodológico paso a paso

2.1. Preparación espacial

Coordenadas originales EPSG:4326, validación de valores y llaves únicas, reproyección a UTM 14N (EPSG:32614; unidades metros). Se detecta sobre 4,365 unidades municipales y se interpreta sobre 4,010 interiores; las 355 externas reducen corte artificial en el borde.

2.2. Diagnósticos preliminares


Distancias k -NN diagnosticaron escalas locales; KDE representó intensidad suavizada sin membresías; hexágonos de 250 m resumieron ocupación y heterogeneidad. Son diagnósticos, no criterios productivos.

2.3. Grillas completas

DBSCAN: $\epsilon \in \{250, 400, 600, 800, 1200, 1600\}$ m y `min_samples` $\in \{5, 10, 15, 25\}$ (24). HDBSCAN: `min_cluster_size` $\in \{10, 20, 30, 50, 75\}$, `min_samples` $\in \{5, 10, 20\}$, método EOM/leaf (30). OPTICS: `min_samples` 10,20,30; $\xi = .05$; fracción mínima .01 (3). Total: 57.

2.4. Evaluación y referencia

Se examinan número de clusters, ruido, porcentaje del cluster mayor, continuidad, probabilidad HDBSCAN, ARI entre particiones y ARI bajo perturbación. La referencia fija es `min_cluster_size=10`, `min_samples=20`, EOM: 22 clusters municipales, 13.4% ruido y 45.8% en el mayor. Es una solución operativa razonable, no la única verdad territorial.



3. ARI: definición, comparaciones y sensibilidad a grupos grandes

ARI compara particiones completas mediante pares de observaciones y corrige acuerdo por azar. $ARI=1$ indica identidad; cerca de 0, acuerdo equivalente al azar; valores bajos o negativos, desacuerdo. La comparación histórica es la media de las cinco particiones HDBSCAN con mayor ARI frente a la principal. La perturbación suma ruido gaussiano independiente de desviación 25 m a cada eje, reajusta HDBSCAN completo tres veces y promedia; semilla maestra 20260921. Para “sin ruido” se restringe a observaciones no ruido en ambas particiones. Para “sin mega” se excluyen las observaciones cuyo cluster principal es 20.


Comparación	n	ARI global	ARI sin ruido	ARI sin mega
cinco_particiones_mas_similares_mismo_metodo	5	0.937	0.992	0.819
perturbacion_gaussiana_25m	3	0.926	0.986	0.896

El descenso sin el mega-cluster confirma contribución de las categorías grandes, pero la estabilidad residual continúa alta en promedio; los mínimos completos están en `resumen_ari_variantes.csv`.

4. Estabilidad de membresía entre especificaciones


Para cada cluster principal y cada una de cinco alternativas (DBSCAN de referencia y cuatro HDBSCAN de sensibilidad), se elige el cluster alternativo de Jaccard máximo. Para cada punto, s_i es la fracción de alternativas donde permanece en ese emparejamiento; cada escenario pesa 0.2. Ruido se compara con ruido. Clases: sensible 0–.49; estable .50–.79; núcleo robusto .80–1. No es cohesión interna, densidad, probabilidad HDBSCAN ni persistencia nativa.

Estabilidad de membresía entre especificaciones



5. Mega-cluster 20 y 18 subnúcleos exploratorios

El diagnóstico interno usa sólo coordenadas con HDBSCAN `min_cluster_size=30`, `min_samples=10`, método `leaf`. Leaf favorece ramas locales con tamaño suficiente y se usa para revelar heterogeneidad, no para reemplazar el cluster 20. El 44.5 % no asignado significa que esos puntos no pertenecen a una rama local suficientemente densa bajo esta especificación; siguen perteneciendo al cluster principal.



5.1. Geometría

Área convexa y densidad son descriptivas; el medoide es un establecimiento observado y la distancia vecina se mide entre centroides.

ID	n	% mega	Municipio	Localidad	Área km2	Dens./km2	Loc.	Vecino m
0	31	1.6	San Andrés Cholula	San Andrés Cholula	0.9	34.9	1	1949.8
1	76	3.8	San Pedro Cholula	Cholula de Rivadavia	4.4	17.3	2	1949.8
2	46	2.3	Puebla	Heroica Puebla de Zaragoza	4.1	11.1	3	2513.7
3	57	2.9	San Andrés Cholula	San Bernardino Tlaxcalancingo	2.9	19.6	1	2513.7
4	92	4.6	Puebla	Heroica Puebla de Zaragoza	9.9	9.3	1	3571.9

ID	n	% mega	Municipio	Localidad	Área km2	Dens./km2	Loc.	Vecino m
5	93	4.7	San Pedro Cholula	Santiago Momoxpan	8.4	11.1	5	3060.4
6	58	2.9	Puebla	Heroica Puebla de Zaragoza	4.5	12.8	1	2389.7
7	41	2.1	Puebla	Heroica Puebla de Zaragoza	2.0	20.3	1	3086.9
8	36	1.8	Puebla	Heroica Puebla de Zaragoza	1.7	20.7	1	1615.8
9	65	3.3	Puebla	Heroica Puebla de Zaragoza	2.9	22.7	1	2378.4
10	33	1.7	Puebla	Heroica Puebla de Zaragoza	1.7	19.9	1	2389.7
11	74	3.7	Puebla	Heroica Puebla de Zaragoza	3.8	19.7	1	3204.8
12	112	5.6	Puebla	Heroica Puebla de Zaragoza	6.6	17.1	1	2436.5
13	97	4.9	Puebla	Heroica Puebla de Zaragoza	4.7	20.7	1	2858.1
14	78	3.9	Puebla	Heroica Puebla de Zaragoza	3.2	24.4	1	1909.9
15	54	2.7	Puebla	Heroica Puebla de Zaragoza	2.2	25.0	1	1909.9
16	30	1.5	Puebla	Heroica Puebla de Zaragoza	1.2	25.3	1	1615.8
17	35	1.8	Puebla	Heroica Puebla de Zaragoza	1.3	26.3	1	1850.7


5.2. Perfilado económico posterior


Las siguientes variables se agregan después del diagnóstico espacial y no generaron los subnúcleos.

ID	Man.	Lav.	Conf.	Acab.	Telas	Maq.	Mez./pant.	Húm.	Seco	SCIAN-3
0	16.1	83.9	9.7	0.0	0.0	3.2	0.0	16.1	0.0	812 315
1	40.8	59.2	15.8	1.3	3.9	1.3	0.0	19.7	6.6	812 315 313
2	19.6	80.4	6.5	0.0	0.0	0.0	0.0	23.9	6.5	812 315 314
3	24.6	75.4	14.0	0.0	3.5	1.8	0.0	19.3	3.5	812 315 313
4	41.3	58.7	30.4	0.0	1.1	4.3	0.0	6.5	12.0	812 315 314
5	43.0	57.0	17.2	3.2	7.5	4.3	0.0	12.9	7.5	812 315 314
6	39.7	60.3	25.9	0.0	0.0	3.4	0.0	15.5	10.3	812 315 314
7	41.5	58.5	24.4	0.0	0.0	2.4	0.0	14.6	7.3	812 315 313
8	50.0	50.0	8.3	5.6	19.4	5.6	0.0	5.6	0.0	812 313 315
9	46.2	53.8	18.5	0.0	7.7	4.6	0.0	10.8	10.8	812 315 313
10	42.4	57.6	30.3	0.0	3.0	0.0	3.0	24.2	12.1	812 315 314
11	40.5	59.5	33.8	0.0	1.4	0.0	0.0	16.2	13.5	812 315 314
12	39.3	60.7	14.3	0.9	5.4	2.7	0.0	16.1	4.5	812 315 314
13	55.7	44.3	19.6	2.1	10.3	2.1	0.0	14.4	12.4	812 315 313
14	60.3	39.7	37.2	0.0	1.3	0.0	0.0	19.2	11.5	812 315 314
15	29.6	70.4	25.9	1.9	1.9	1.9	0.0	13.0	1.9	812 315 313
16	70.0	30.0	36.7	3.3	10.0	0.0	0.0	10.0	16.7	315 812 313
17	37.1	62.9	17.1	0.0	11.4	0.0	0.0	14.3	17.1	812 315 313

6. Composición multilabel y diccionario analítico

Los términos son cadenas disparadoras; las etiquetas canónicas son indicadores reproducibles derivados; las categorías agregadas reúnen reglas como SCIAN o señales temáticas. El heatmap principal conserva ocho variables centrales, interpretables y poco redundantes; el ampliado muestra las 18 variables útiles. Ninguno incluye miles de términos crudos. La trazabilidad completa está en `diccionario_variables_analiticas.csv`.






7. Sobrerrepresentación

Una señal está sobrerrepresentada cuando $p_c > p_U$. $lift = p_c/p_U$ y $\log_2(lift) = \log_2(p_c/p_U)$: cero significa igualdad; positivo, sobre-representación; negativo, subrepresentación. Se distingue NO_EVALUABLE (base global cero), NO_SOBRERREPRESENTADO ($lift \leq 1$), FILTRADO_POR_CRITERIO y SOBRERREPRESENTADO. El filtro exige conteo ≥ 5 , prevalencia $\geq 5\%$, $lift \geq 1.25$ y $p_{BH} \leq .05$. La tabla completa contiene conteo, prevalencias, diferencia en puntos porcentuales, lift, log2 lift, OR, IC95, Fisher y BH; `top_rasgos_por_cluster.csv` aporta 3–5 rasgos por cluster cuando existen.

8. Lavanderías frente a manufactura

El 80 % es un umbral descriptivo, no una frontera natural. En la referencia fija hay 12 concentraciones manufactureras y seis mixtas; ninguna predominantemente lavandería.

Ranking de los 18 clusters interiores



Cl.	n	Municipio	Localidad	Lav.	Man.	Conf.	Acab.	Maq.	Húm.	Seco	Mez./pant.
20	1997	Puebla	Heroica Puebla de Zaragoza	59.3	40.7	20.9	1.0	2.2	15.7	8.5	0.2
15	92	San Martín Texmelucan	San Martín Texmelucan de Labastida	48.9	51.1	40.2	0.0	12.0	6.5	18.5	0.0
7	99	Huejotzingo	Huejotzingo	44.4	55.6	31.3	1.0	3.0	5.1	13.1	5.1
21	31	Amozoc	Amozoc de Mota	41.9	58.1	25.8	0.0	3.2	6.5	0.0	0.0
18	32	Amozoc	Amozoc de Mota	40.6	59.4	40.6	0.0	3.1	6.2	28.1	0.0
14	14	Cuaautlancingo	San Lorenzo Almecatla	35.7	64.3	42.9	0.0	0.0	14.3	42.9	0.0
16	51	San Martín Texmelucan	Santa María Moyotzingo	15.7	84.3	70.6	2.0	45.1	2.0	17.6	2.0
17	45	San Martín Texmelucan	San Martín Texmelucan de Labastida	13.3	86.7	84.4	0.0	17.8	0.0	24.4	0.0
11	8	Ocoyucan	San Bernabé Temoxtitla	12.5	87.5	37.5	0.0	0.0	0.0	37.5	0.0
19	100	San Miguel Xoxtla	San Miguel Xoxtla	9.0	91.0	76.0	0.0	44.0	1.0	23.0	1.0
13	149	San Martín Texmelucan	San Rafael Tlanalapan	8.1	91.9	81.2	0.0	36.9	0.0	47.7	0.0

Cl.	n	Municipio	Localidad	Lav.	Man.	Conf.	Acab.	Maq.	Húm.	Seco	Mez./pant.
8	337	Huejotzingo	Santa Ana Xalmimilulco	8.0	92.0	85.8	1.2	55.8	1.5	15.7	40.7
12	224	San Matías Tlalancaleca	San Matías Tlalancaleca	7.1	92.9	83.9	1.3	25.0	0.0	48.7	13.8
4	28	Chiautzingo	San Lorenzo Chiautzingo	7.1	92.9	78.6	0.0	60.7	0.0	7.1	7.1
5	33	San Matías Tlalancaleca	Juárez Coronaco	6.1	93.9	78.8	0.0	63.6	0.0	27.3	0.0
10	142	Tlahuapan	San Rafael Ixtapalucan	3.5	96.5	0.7	0.7	9.2	2.1	1.4	0.0
6	20	Tlahuapan	Santiago Coltzingo	0.0	100.0	40.0	0.0	80.0	0.0	15.0	0.0
9	30	Tlahuapan	San Miguel Tianguistenco	0.0	100.0	16.7	0.0	10.0	0.0	10.0	0.0


8.1. Sensibilidad en seis escenarios


escenario_id	rol	n_clusters_interiores	max_pct_lavanderias	clusters_lavanderias_80pct	clusters_manufactura_80pct	clusters_coexistencia_mixta
hdbscan__min__cluster_size-10__min__samples-20__cluster_selection_method-eom	PRINCIPAL	18	59.339008512769160		12	6
dbscan__eps__m-1600__min__samples-25	REFERENCIA_ DBSCAN	9	58.218549127640040		5	4
hdbscan__min__cluster_size-20__min__samples-20__cluster_selection_method-eom	SENSIBILIDAD	17	59.339008512769160		12	5
hdbscan__min__cluster_size-30__min__samples-20__cluster_selection_method-eom	SENSIBILIDAD	15	59.339008512769160		10	5
hdbscan__min__cluster_size-20__min__samples-10__cluster_selection_method-eom	SENSIBILIDAD	20	58.934624697336560		13	7
hdbscan__min__cluster_size-30__min__samples-10__cluster_selection_method-eom	SENSIBILIDAD	17	58.934624697336560		10	7


La evidencia responde: las lavanderías no forman clusters interiores casi exclusivos; aparecen sobre todo en estructuras mixtas y coexisten con confección, acabado, maquila y señales textiles en proporciones variables. La conclusión permanece en los seis escenarios seleccionados. Esto no demuestra relación empresarial, productiva o hidráulica.


9. Tipología y espacio métrico

El vector coseno contiene prevalencias (0–1) de las 18 etiquetas canónicas. Se usa distancia, $1 - (x \cdot y) / (\|x\| \|y\|)$. Jensen–Shannon usa distribuciones SCIAN de 3 dígitos normalizadas por cluster y la distancia (raíz de la divergencia, base 2) implementada por SciPy. Personal ocupado aparece en el archivo de vectores histórico, pero no interviene en la distancia. La distancia final es $.5d_{cos} + .5d_{JS}$, sin normalización adicional porque ambas están en 0–1.









9.1. Por qué son similares los pares principales

A	B	Cos.	JS	Comb.	Señales compartidas	SCIÁN compartidos	Diferencias
CLUSTER_014	CLUSTER_018	0.021	0.045	0.033	scian_014:40.6 % textil:59.4 % textil:42.9 % actividad_014:40.6 % lavanderia_014:35.7 % tintoreria:35.7 %	315:40.6 % 812:35.7 % 314:18.8 %	proceso_seco_014:14.7pp explicito:14.7pp actividad_014:12.1pp bordado_014:9.8pp
CLUSTER_004	CLUSTER_013	0.071	0.016	0.043	scian_004:35.7 % scian_013:85.2 % textil:91.9 % actividad_013:78.6 % maquila:36.9 % textil:28.6 % scian_013:7.1 %	315:85.2 % 812:7.1 % 314:6.7 %	proceso_seco_013:40.5pp explicito:24.4pp maquila:23.8pp
CLUSTER_012	CLUSTER_013	0.017	0.089	0.053	scian_012:81.2 % textil:53.0 % proceso_seco_012:47.7 % maquila:25.0 %	315:85.2 % 812:7.1 % 314:4.9 %	senal_012:13.8pp mezclilla_o_012:12.6pp pantalon:12.0pp textil:12.6pp produccion:12.0pp
CLUSTER_007	CLUSTER_021	0.040	0.084	0.062	scian_007:41.9 % textil:55.6 % scian_021:41.9 % lavanderia_007:37.4 % tintoreria:41.9 % lavado_007:37.4 % generico:37.4 % actividad_007:25.8 %	812:41.9 % 315:29.0 % 313:13.1 %	textil:21.0pp proceso_seco_007:13.1pp explicito:10.7pp produccion:10.7pp

A	B	Cos.	JS	Comb.	Señales compartidas	SCIAN compartidos	Diferencias
CLUSTER_ 016	CLUSTER_ 019	0.035	0.090	0.062	scian_ textil:84.3 % actividad_ confeccion:70.6 % maquila:44.0 % textil:21.6 % proceso_seco explicito:17.6 %	315:72.5 % 314:9.0 % 812:9.0 %	produccion:29.1pp textil:17.4pp lavado_ generico:7.7pp
CLUSTER_ 008	CLUSTER_ 012	0.082	0.044	0.063	scian_ textil:92.0 % actividad_ confeccion:83.9 % textil:45.1 % maquila:25.0 % proceso_ seco_ explicito:15.7 %	315:86.6 % 812:7.1 % 314:3.0 %	proceso_seco_ explicito:32.9pp maquila:30.8pp senal_ pantalon:27.4pp
CLUSTER_ 012	CLUSTER_ 019	0.048	0.081	0.065	scian_ textil:91.0 % actividad_ confeccion:76.0 % textil:39.0 % maquila:25.0 % proceso_ seco_ explicito:23.0 %	315:80.0 % 812:7.1 % 314:4.9 %	textil:26.6pp proceso_seco_ explicito:25.7pp maquila:19.0pp
CLUSTER_ 013	CLUSTER_ 019	0.037	0.110	0.073	scian_ textil:91.0 % actividad_ confeccion:76.0 % textil:39.0 % maquila:36.9 % proceso_ seco_ explicito:23.0 %	315:80.0 % 812:8.1 % 314:6.7 %	produccion:25.6pp proceso_ seco_ explicito:24.7pp textil:14.0pp
CLUSTER_ 004	CLUSTER_ 019	0.043	0.111	0.077	scian_ textil:91.0 % actividad_ confeccion:76.0 % maquila:44.0 % textil:28.6 % scian_ lavanderia:7.1 %	315:80.0 % 314:7.1 % 812:7.1 %	produccion:27.9pp maquila:16.7pp proceso_ seco_ explicito:15.9pp
CLUSTER_ 013	CLUSTER_ 017	0.040	0.115	0.078	scian_ textil:86.7 % actividad_ confeccion:81.2 % proceso_ seco_ explicito:24.4 % textil:24.4 % maquila:17.8 %	315:84.4 % 812:8.1 % 314:2.2 %	textil:28.6pp proceso_seco_ explicito:23.2pp maquila:19.1pp

10. Explorador interactivo

[outputs/parte_2/14_segunda_pasada/explorador_interactivo_clusters.html](#) es autocontenido: selecciona y compara dos clusters, ordena señales, alterna conteo/porcentaje, filtra señales presentes y cambia entre etiquetas compactas/ampliadas; muestra n , municipio, localidad, SCIAN, rasgos sobrerrepresentados, estabilidad, probabilidad y borde.

11. Actividad dispersa, limitaciones y cierre

Los 578 puntos interiores no asignados son una categoría dependiente de escala, no un cluster equivalente. DENUE puede omitir actividad informal; la coordenada no prueba precisión predial; SCIAN 812210 no separa lavandería comercial de industrial; las etiquetas pueden correlacionarse. Concentración y coexistencia no prueban vínculos empresariales, consumo, descarga ni impacto. La relación hidrológica pertenece a Parte 3.

12. Glosario metodológico permanente

Métrica	Definición/fórmula	Rango y lectura	Uso y advertencia
ARI	Acuerdo entre todos los pares de observaciones, corregido por azar: $(RI - E[RI]) / (\max(RI) - E[RI])$.	1 idéntico; cerca de 0 acuerdo esperable por azar; puede ser negativo.	Particiones completas; global, no identifica qué cluster cambia y puede estar dominado por grupos grandes.
Jaccard	$ A \cap B / A \cup B $.	0–1; alto indica mayor solapamiento.	Empareja clusters entre escenarios; no es estabilidad individual ni cohesión geométrica.
Estabilidad de membresía	$s_i = \frac{1}{5} \sum_k I[z_i^{(k)} = m_k(z_i)]$, donde m_k es el cluster alternativo de máximo Jaccard.	0–1; sensible 0–.49, estable .50–.79, núcleo robusto .80–1.	Cinco especificaciones, peso .2 cada una. No es persistencia nativa HDBSCAN.
Probabilidad HDBSCAN	Fuerza de pertenencia estimada por HDBSCAN respecto de la estructura de densidad.	0–1; alta=membresía más fuerte.	No es probabilidad causal ni estabilidad entre modelos.
Persistencia HDBSCAN	Estabilidad de un cluster a través de niveles de densidad del árbol condensado.	No comparable directamente con s_i .	Sólo se informa cuando proviene de <code>cluster_persistence_</code> ; no sustituye Jaccard.
Ruido	Etiqueta –1 para puntos no asignados a clusters bajo una especificación.	0–100 %.	Depende de escala y parámetros; no significa irrelevancia.
Cluster mayor	$100 \max_c n_c / N$.	0–100 %.	Diagnóstico de dominancia, no error automático.
Densidad	$n/\text{área convexa en km}^2$.	≥ 0 ; alta=más puntos por área.	Sensible a forma, borde y áreas casi nulas; no equivale a cohesión.
Prevalencia	a/n .	0–1 o porcentaje.	Multilabel: columnas no suman 100 %.
Diferencia de prevalencias	$p_c - p_U$ (en tablas, puntos porcentuales).	$[-1, 1]$.	Efecto absoluto descriptivo.
Lift / $\log_2$ lift	p_c/p_U ; $\log_2(p_c/p_U)$.	Lift > 0 ; $\log_2=0$ igualdad, > 0 sobre-, < 0 subrepresentación.	No implica causalidad; inestable con base rara.
Odds ratio e IC95	$ad/(bc)$; IC con corrección Haldane–Anscombe de 0.5.	OR=1 sin asociación; IC que cruza 1 es compatible con nulo.	Comparación cluster/resto, no riesgo causal.
Fisher / BH	Prueba exacta 2x2; BH controla tasa esperada de falsos descubrimientos.	$p \in [0, 1]$; filtro $p_{BH} \leq .05$.	Significancia no sustituye tamaño de efecto.
Cosine similarity/distance	$s = (x \cdot y) / (\ x\ \ y\)$; $d = 1 - s$.	En vectores no negativos, 0–1 para distancia.	Vector de 18 prevalencias; compara patrón, no volumen.
Jensen–Shannon divergence/distance	$JSD = \frac{1}{2} KL(P \ M) + \frac{1}{2} KL(Q \ M)$; distancia $\sqrt{JSD}$, base 2.	0–1.	Distribuciones SCIAN a 3 dígitos normalizadas por cluster; se usa distancia de SciPy.
Distancia combinada	$d = .5d_{cos} + .5d_{JS}$.	0–1; bajo=perfiles similares.	Pesos analíticos iguales; no usa geografía ni personal ocupado.
Centroide / medoi-de	Media de coordenadas / punto observado que minimiza suma de distancias.	Coordenadas métricas EPSG:32614.	Centroide puede no coincidir con un establecimiento; medoi-de sí.
KDE	Suma suavizada de kernels sobre puntos.	Intensidad relativa dependiente del ancho de banda.	Diagnóstico exploratorio; no define membresías.

Métrica	Definición/fórmula	Rango y lectura	Uso y advertencia
Perturbación espacial	A cada coordenada se suma ruido independiente $N(0, 25^2)$ m por eje y se reajusta el modelo.	3 repeticiones, semilla 20260921.	Evalúa sensibilidad posicional local, no error geodésico completo.

A. Las 57 configuraciones exploradas

escenario_id	metodo	n_clusters	pct_ruido	pct_cluster_mayor	ari_top5_mismo_metodo	ari_perturbacion_25m
hdbscan__min__cluster_size-30__min__samples-5__cluster__selection__method-eom	HDBSCAN	19	6.117	52.921	0.928	0.942
dbscan__eps__m-1200__min__samples-10	DBSCAN	24	3.276	50.790	0.950	0.999
dbscan__eps__m-800__min__samples-10	DBSCAN	25	8.683	46.575	0.915	0.996
dbscan__eps__m-1200__min__samples-25	DBSCAN	13	11.684	46.964	0.910	0.979
dbscan__eps__m-1200__min__samples-15	DBSCAN	20	6.300	48.866	0.929	0.991
dbscan__eps__m-1600__min__samples-15	DBSCAN	17	3.322	51.409	0.945	0.978
dbscan__eps__m-600__min__samples-5	DBSCAN	51	5.361	45.750	0.896	0.984
dbscan__eps__m-1200__min__samples-5	DBSCAN	27	1.168	53.081	0.932	1.000
dbscan__eps__m-800__min__samples-5	DBSCAN	44	2.428	49.255	0.916	0.989
dbscan__eps__m-1600__min__samples-10	DBSCAN	16	1.856	55.785	0.907	0.998
dbscan__eps__m-1600__min__samples-5	DBSCAN	22	0.619	56.403	0.896	1.000
hdbscan__min__cluster_size-75__min__samples-10__cluster__selection__method-eom	HDBSCAN	9	9.576	51.226	0.944	0.994
hdbscan__min__cluster_size-75__min__samples-20__cluster__selection__method-eom	HDBSCAN	9	11.959	49.301	0.921	0.980
dbscan__eps__m-800__min__samples-15	DBSCAN	25	12.234	38.007	0.732	0.976
hdbscan__min__cluster_size-50__min__samples-20__cluster__selection__method-eom	HDBSCAN	10	10.745	49.301	0.923	0.981
hdbscan__min__cluster_size-75__min__samples-5__cluster__selection__method-eom	HDBSCAN	9	6.964	52.921	0.942	0.999

escenario_id	metodo	n_clusters	pct_ruido	pct_cluster_mayor	ari_top5_mismo_metodo	ari_perturbacion_25m
hdbscan_min_cluster_size-50_min_min_samples-10_selection_method-eom	HDBSCAN	13	8.408	51.226	0.932	0.979
hdbscan_min_cluster_size-50_min_min_samples-5_selection_method-eom	HDBSCAN	10	5.750	52.921	0.943	0.999
dbscan_eps_m-600_min_min_samples-15	DBSCAN	34	25.727	22.451	0.602	0.902
dbscan_eps_m-800_min_min_samples-25	DBSCAN	23	27.858	22.199	0.575	0.968
hdbscan_min_cluster_size-20_min_min_samples-20_selection_method-leaf	HDBSCAN	40	51.019	5.132	0.659	0.818
hdbscan_min_cluster_size-30_min_min_samples-20_selection_method-leaf	HDBSCAN	34	51.088	5.132	0.651	0.813
dbscan_eps_m-600_min_min_samples-10	DBSCAN	40	13.356	27.491	0.612	0.922
hdbscan_min_cluster_size-20_min_min_samples-10_selection_method-leaf	HDBSCAN	57	43.184	2.566	0.622	0.765
hdbscan_min_cluster_size-30_min_min_samples-10_selection_method-leaf	HDBSCAN	42	41.581	2.566	0.615	0.765
dbscan_eps_m-400_min_min_samples-25	DBSCAN	12	71.775	7.652	0.709	0.970
dbscan_eps_m-250_min_min_samples-10	DBSCAN	31	66.071	7.491	0.698	0.921
dbscan_eps_m-250_min_min_samples-15	DBSCAN	14	74.044	7.331	0.696	0.959
dbscan_eps_m-400_min_min_samples-15	DBSCAN	29	58.190	7.675	0.643	0.927
hdbscan_min_cluster_size-30_min_min_samples-5_selection_method-leaf	HDBSCAN	47	32.692	3.024	0.557	0.680
hdbscan_min_cluster_size-10_min_min_samples-20_selection_method-leaf	HDBSCAN	53	55.281	2.291	0.590	0.839
dbscan_eps_m-600_min_min_samples-25	DBSCAN	27	52.027	7.698	0.574	0.953
dbscan_eps_m-400_min_min_samples-10	DBSCAN	69	36.724	7.698	0.534	0.877

escenario_id	metodo	n_clusters	pct_ruido	pct_cluster_mayor	ari_top5_mismo_metodo	ari_perturbacion_25m
hdbscan_min_cluster_size-20_min_min_samples-5_selection_method-leaf	HDBSCAN	70	33.906	2.360	0.525	0.649
hdbscan_min_cluster_size-10_min_min_samples-5_selection_method-eom	HDBSCAN	99	21.879	7.789	0.479	0.762
hdbscan_min_cluster_size-50_min_min_samples-20_cluster_selection_method-leaf	HDBSCAN	19	45.590	7.721	0.664	0.909
hdbscan_min_cluster_size-10_min_min_samples-10_cluster_selection_method-eom	HDBSCAN	73	29.187	7.721	0.487	0.609
hdbscan_min_cluster_size-20_min_min_samples-5_selection_method-eom	HDBSCAN	55	22.108	7.789	0.525	0.388
hdbscan_min_cluster_size-75_min_min_samples-10_cluster_selection_method-leaf	HDBSCAN	18	40.802	7.721	0.616	0.854
hdbscan_min_cluster_size-75_min_min_samples-20_cluster_selection_method-leaf	HDBSCAN	15	50.584	7.721	0.633	0.908
dbscan_eps_m-400_min_min_samples-5	DBSCAN	91	14.502	16.655	0.479	0.801
hdbscan_min_cluster_size-10_min_min_samples-10_cluster_selection_method-leaf	HDBSCAN	94	45.109	2.131	0.505	0.701
dbscan_eps_m-250_min_min_samples-25	DBSCAN	8	81.672	5.773	0.542	0.952
hdbscan_min_cluster_size-75_min_min_samples-5_cluster_selection_method-leaf	HDBSCAN	17	44.536	7.789	0.573	0.778
hdbscan_min_cluster_size-50_min_min_samples-10_cluster_selection_method-leaf	HDBSCAN	27	41.764	4.834	0.577	0.721
hdbscan_min_cluster_size-50_min_min_samples-5_cluster_selection_method-leaf	HDBSCAN	29	38.877	5.109	0.524	0.710

escenario_id	metodo	n_clusters	pct_ruido	pct_cluster_mayor	ari_top5_mismo_metodo	ari_perturbacion_25m
hdbscan__min__cluster_size-10__min__samples-5__cluster_selection__method-leaf	HDBSCAN	134	32.875	1.787	0.439	0.624
dbscan__eps__m-250__min__samples-5	DBSCAN	149	39.038	7.606	0.463	0.852
optics__min__samples-20__xi-0p05__min__cluster_size__frac-0p01	OPTICS	21	62.085	7.789	0.560	nan
optics__min__samples-30__xi-0p05__min__cluster_size__frac-0p01	OPTICS	18	61.512	7.789	0.531	nan
optics__min__samples-10__xi-0p05__min__cluster_size__frac-0p01	OPTICS	28	60.206	2.131	0.415	nan
hdbscan__min__cluster_size-10__min__samples-20__cluster_selection__method-eom	HDBSCAN	22	13.379	45.750	0.937	0.926
dbscan__eps__m-1600__min__samples-25	DBSCAN	13	7.537	49.897	0.933	0.996
hdbscan__min__cluster_size-20__min__samples-20__cluster_selection__method-eom	HDBSCAN	21	13.700	45.750	0.936	0.926
hdbscan__min__cluster_size-30__min__samples-20__cluster_selection__method-eom	HDBSCAN	18	14.800	45.750	0.933	0.921
hdbscan__min__cluster_size-20__min__samples-10__cluster_selection__method-eom	HDBSCAN	24	10.309	47.308	0.928	0.972
hdbscan__min__cluster_size-30__min__samples-10__cluster_selection__method-eom	HDBSCAN	20	10.080	47.308	0.928	0.973

B. Diccionario de variables analíticas

etiqueta_ canonica	grupo	diccionario_ origen	terminos_ que activan	conteo_global	prevalencia_ global	heatmap_ principal	razon
textil	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	996	0.2483790523690	False	reservada para heatmap ampliado para evitar redundancia visual
mezclilla	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	74	0.018453865336655	False	lectura sustantiva compacta central
humedo_ explicito	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	370	0.092269326683297	True	lectura sustantiva compacta central
lavado_ generico	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	1200	0.29925187032418	False	reservada para heatmap ampliado para evitar redundancia visual
produccion	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	489	0.12194513715716	False	reservada para heatmap ampliado para evitar redundancia visual
maquila	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	589	0.146882793017457	False	lectura sustantiva compacta central
proceso_seco_ explicito	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	644	0.160598503740643	False	lectura sustantiva compacta central
scian_textil	SCIAN	regla agregada a partir de codigo SCIAN	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	2424	0.604488778054862	False	reservada para heatmap ampliado para evitar redundancia visual

etiqueta_ canonica	grupo	diccionario_ origen	terminos_ que activan	conteo_global	prevalencia_ global	heatmap_ principal	razon
scian_ acabado_ humedo	SCIAN	regla agregada a partir de codigo SCIAN	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	34	0.008478802992518	False	reservada para heatmap ampliado para evitar redundancia visual
scian_ lavanderia	SCIAN	regla agregada a partir de codigo SCIAN	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	1586	0.395511221945137	False	reservada para heatmap ampliado para evitar redundancia visual
actividad_ lavanderia_ tintoreria	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	1586	0.395511221945137	True	lectura sustantiva compacta central
actividad_ acabado_textil	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	34	0.008478802992518	False	lectura sustantiva compacta central
actividad_ confeccion	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	1562	0.389526184538653	False	lectura sustantiva compacta central
actividad_ fabricacion_ telas	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	155	0.038653366583541	True	lectura sustantiva compacta central
actividad_ tejido_hilado	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	359	0.089526184538653	False	reservada para heatmap ampliado para evitar redundancia visual
actividad_ bordado_ deshilado	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	179	0.044638403990024	False	reservada para heatmap ampliado para evitar redundancia visual

etiqueta_ canonica	grupo	diccionario_ origen	terminos_ que_activan	conteo_global	prevalencia_ global	heatmap_ principal	razon
senal_pantalon	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	147	0.0366583541147	False	reservada para heatmap ampliado para evitar redundancia visual
senal_mezclilla_o_ pantalon	senal_ multilabel	etiqueta canonica derivada de gi- ro/diccionario	Consultar scripts/03_ text_filter.py y 201_ construir_ matriz_ maestra.py; regla versionada en codigo	183	0.0456359102244	False	reservada para heatmap ampliado para evitar redundancia visual

C. Índice de resultados completos

- `diagnostico_ari_variantes.csv` y `componentes_estabilidad_por_cluster.csv`.
- `subnucleos_mega_cluster_documentados.csv`.
- `sobrerrepresentacion_completa.csv` y `top_rasgos_por_cluster.csv`.
- Tres matrices de distancia y `explicacion_pares_similares.csv`.
- `registro_documentacion_figuras.csv` responde las siete preguntas de cierre por figura.