

Diagnostico preliminar de unidades economicas y concentracion espacial

para la planeacion de infraestructura de colectores

Cuenca del Alto Atoyac

Naturaleza del documento: reporte tecnico maestro de trazabilidad

Funcion: documentar el diagnostico preliminar de unidades economicas, el analisis espacial realizado y su alcance como insumo de preseleccion para estudios posteriores de colectores.

No sustituye: aforo de descargas, muestreo de calidad, levantamiento de red, modelacion hidraulica, estudio de factibilidad ni proyecto ejecutivo.

Autor/a:	[PENDIENTE]
Institucion:	[PENDIENTE]
Version:	0.1 – estructura maestra
Fecha de corte:	24 de septiembre de 2026
Repositorio/directorio:	[PENDIENTE]
Responsable de revision:	[PENDIENTE]

Índice

1. Control documental y trazabilidad de versiones	4
1.1. Ficha de control	4
2. Resumen ejecutivo	4
3. Contexto de decision, proposito y alcance	5
3.1. Problema de decision	5
3.2. Objetivo general	5
3.3. Objetivos especificos	6
3.4. Alcance y exclusiones	6
4. Antecedentes ambientales y territoriales	6
5. Area de estudio y unidades territoriales	6
5.1. Delimitacion de la cuenca	7
5.2. Red hidrografica y contexto territorial	7
5.3. Sistemas de referencia	7
6. Fuentes de datos y gobierno de informacion	7
6.1. Inventario maestro de fuentes	7
7. Construccion del universo economico	8
7.1. Universo de partida	8
7.2. Filtro SCIAN	8
7.3. Filtro textual y diccionarios	8
7.4. Separacion entre sector textil y evidencia de proceso humedo	9
7.5. Reglas de inclusion/exclusion	9
8. Auditoria manual y evidencia externa	9
8.1. Protocolo de revision	9
9. Integracion de fuentes complementarias y comparacion historica	10
9.1. Integracion MH	10
9.2. Universos legacy	10
10.Modalidades analiticas de la primera fase	10
11.Analisis espacial descriptivo de unidades economicas	11
11.1. Distribucion territorial	11
11.2. Distancia a hidrografia	11
12.Diagnostico previo de estructura espacial	11
13.Clustering espacial: diseño de experimentos	11
13.1. Universo de deteccion vs. universo de interpretacion	11
13.2. Algoritmos evaluados	12

14. Selección de la solución espacial y robustez	12
14.1. Criterios de selección	12
14.2. Glosario mínimo de métricas	12
15. Materialización de clusters, borde y ruido	13
16. Perfil económico y productivo posterior al clustering	13
17. Sobrerepresentación de señales	14
17.1. Base comparativa	14
18. Similitud entre clusters y tipologías productivas	14
19. Mega-cluster y subnucleos exploratorios	15
20. Resultados principales por territorio	15
20.1. Resultados a escala de cuenca	15
20.2. Resultados por municipio	15
20.3. Resultados por localidad/corredor	15
20.4. Huejotzingo y Santa Ana Xalmimilulco	15
21. De diagnóstico económico a priorización preliminar de colectores	16
21.1. Lo que este análisis sí puede aportar	16
21.2. Lo que falta antes de justificar inversión	16
21.3. Matriz de priorización de siguiente etapa	16
22. Marco de priorización multicriterio: propuesta para etapa posterior	17
23. Validación, control de calidad y pruebas de integridad	17
24. Incertidumbre, sesgos y limitaciones	18
24.1. Registro de incertidumbres	18
25. Reproducibilidad computacional	18
25.1. Estructura del pipeline	19
25.2. Orden de ejecución	19
25.3. Entorno	19
26. Matriz maestra de trazabilidad de afirmaciones	19
27. Conclusiones	21
28. Plan de siguientes pasos	21
A. Anexo A. Inventario de scripts y productos	21
B. Anexo B. Diccionario de datos de la matriz maestra	22
C. Anexo C. Diccionarios SCIAN y texto	22
D. Anexo D. Bitácora de auditoría manual	22

E. Anexo E. Catalogo de figuras, mapas y tablas	22
F. Anexo F. Glosario metodologico	22
G. Anexo G. Registro de decisiones metodologicas	22
H. Anexo H. Registro de cambios	22
I. Anexo I. Checklist previo a publicacion	22
J. Anexo J. Fuentes y antecedentes a incorporar	23

1 Control documental y trazabilidad de versiones

1.1 Ficha de control

Campo	Contenido
Titulo oficial	[PENDIENTE]
Identificador del documento	[PENDIENTE]
Version	0.1
Fecha de corte de datos	[PENDIENTE]
Fecha de generacion	24 de septiembre de 2026
Responsable tecnico	[PENDIENTE]
Revisor metodologico	[PENDIENTE]
Ruta del repositorio	[PENDIENTE]
Commit/tag de Git	[PENDIENTE] (actualmente no identificado en el inventario)
Ejecutor reproducible	scripts/219_ejecutar_parte2_completa.py + 220-222 + recompilacion
Estado	Borrador estructural

Preguntas guía

- ¿Quien puede reproducir, revisar y aprobar formalmente cada version?
- ¿Cual es la fecha exacta de corte de DENUÉ, capas territoriales y fuentes complementarias?
- ¿Existe una version congelada del repositorio asociada al reporte?
- ¿Que productos quedan invalidados si cambia el universo, la geometria de cuenca o los diccionarios de clasificacion?

Requisitos de trazabilidad

Cada version publicada deberia conservar: (1) copia de fuentes o identificadores de descarga; (2) hash SHA-256; (3) entorno de software; (4) parametros; (5) scripts ejecutados; (6) manifiesto de salidas; (7) fecha y responsable; y (8) lista de cambios respecto de la version anterior.

2 Resumen ejecutivo

Objetivo de esta seccion: permitir que una persona que no lea el resto del documento entienda que se hizo, que se encontro, que tan confiable es y que decision puede apoyar.

Preguntas guía

- ¿Cual fue el problema operativo que motivo el analisis?
- ¿Que universo de unidades economicas se estudio y por que?

- ¿Que metodos se usaron para clasificar, mapear y detectar concentraciones?
- ¿Cuales son los 5–10 hallazgos que cambian la comprension territorial del problema?
- ¿Que zonas aparecen como candidatas para una segunda etapa de validacion?
- ¿Que no puede concluirse a partir de DENUÉ, proximidad a rios o clustering?
- ¿Cuales son los siguientes estudios indispensables antes de hablar de inversion en colectores?

Informacion y evidencia minima requerida

Incluir una tabla de una pagina con: universo inicial, universo sectorial, universo dentro de cuenca, numero de escenarios de clustering, solucion seleccionada, numero de clusters, ruido, principales zonas de concentracion, nivel de incertidumbre y recomendacion de siguiente paso.

Hechos ya identificados en el repositorio

El inventario actual reporta: 15,956 registros estatales en la descarga acotada; 4,365 establecimientos en el universo sectorial ampliado de deteccion; 4,010 dentro de cuenca para interpretacion; 57 escenarios de clustering; solucion principal HDBSCAN; 22 clusters sobre el universo ampliado; 584 registros de ruido; y un cluster mayor de 1,997 registros. Estas cifras deben verificarse contra los archivos finales antes de publicarse.

3 Contexto de decision, proposito y alcance

3.1 Problema de decision

Explicar la cadena de decision que conecta este diagnostico con etapas posteriores de infraestructura:

Unidades economicas → concentraciones espaciales → hipotesis de generacion/descarga → validacion en campo → delimitacion de subcuencas/redes → aforos y calidad → modelacion hidraulica → alternativas de colectores → factibilidad tecnica/economica/social → priorizacion de inversion.

Preguntas guía

- ¿Quien tomara la decision final de inversion y que necesita saber?
- ¿El objetivo inmediato es ubicar actividad potencialmente relevante, priorizar visitas, identificar corredores, estimar demanda de saneamiento o preseleccionar trazos?
- ¿Cual es la unidad de decision futura: cluster, localidad, municipio, subcuenca, tramo de drenaje o colector?
- ¿Que horizonte temporal de planeacion se contempla?

3.2 Objetivo general

[PENDIENTE] Redactar en una sola frase, distinguiendo claramente *diagnostico preliminar* de *diseño de infraestructura*.

3.3 Objetivos específicos

1. Construir un universo auditable de unidades economicas potencialmente relevantes.
2. Caracterizar su distribucion territorial y su relacion espacial con la cuenca y la red hidrografica.
3. Detectar concentraciones espaciales sin utilizar variables productivas para forzar los grupos.
4. Perfilar la composicion economica de los agrupamientos una vez fijada la solucion espacial.
5. Identificar zonas que ameriten validacion de campo y estudios hidraulicos posteriores.
6. Documentar incertidumbres, sesgos, decisiones y productos para garantizar reproducibilidad.

3.4 Alcance y exclusiones

Limite de interpretacion

Este reporte no debe presentar la presencia de una unidad economica, su giro, su cercania a un cauce o su pertenencia a un cluster como prueba de descarga, incumplimiento, contaminacion o caudal generado. Tampoco debe interpretar el clustering como una red de drenaje existente ni como un trazo de colector.

4 Antecedentes ambientales y territoriales

Funcion: establecer por que la Cuenca del Alto Atoyac requiere una lectura territorial integrada y como el presente diagnostico se inserta en trabajos previos sobre degradacion ambiental, descargas y salud ambiental.

Preguntas guia

- ¿Cuales son los principales procesos historicos de urbanizacion, industrializacion y deterioro hidrico documentados para la cuenca?
- ¿Que sectores productivos han sido señalados en literatura o registros oficiales como relevantes para cargas contaminantes?
- ¿Que antecedentes existen especificamente para textiles, confeccion, lavanderias, acabado, teñido u otros procesos humedos?
- ¿Que municipios/localidades han sido priorizados en estudios anteriores y por que?
- ¿Que vacio de informacion busca cubrir este trabajo respecto de esos antecedentes?

Informacion y evidencia minima requerida

Separar siempre: **antecedentes documentados** (literatura, informes, RETC, CONAGUA, INEGI, academia) de **resultados propios**. El libro *Salud ambiental en la Cuenca del Alto Atoyac* puede usarse como referencia contextual y para identificar temas/territorios a documentar, pero no sustituye la verificacion de fuentes oficiales o tecnicas para una decision de infraestructura.

5 Area de estudio y unidades territoriales

5.1 Delimitacion de la cuenca

Preguntas guia

- ¿De que fuente proviene el poligono de cuenca y cual es su fecha/escala?
- ¿Que definicion de “Alto Atoyac” se utiliza y coincide con otras instituciones?
- ¿Que municipios intersectan la cuenca y cuales se incorporan solo como apoyo para controlar borde?
- ¿Como se tratan unidades economicas justo fuera del poligono pero potencialmente conectadas hidrologica o urbanamente?

5.2 Red hidrografica y contexto territorial

Documentar fuente, escala, CRS, fecha, topologia conocida, atributos, limitaciones y si la capa representa cauces, corrientes perennes/intermitentes, barrancas, canales o una mezcla.

5.3 Sistemas de referencia

Informacion y evidencia minima requerida

Registrar CRS geografico de publicacion y CRS metrico de analisis. El pipeline actual identifica EPSG:4326 y EPSG:32614. Verificar que todas las distancias y algoritmos de densidad se ejecuten en coordenadas metricas.

6 Fuentes de datos y gobierno de informacion

6.1 Inventario maestro de fuentes

Fuente	Archivo/ID	Fecha	Cobertura	Uso y limitacion principal
DENUE	INEGI_DENUE_11092026	[PENDIENTE]	Puebla / SCIAN seleccionados	Base de unidades economicas; no prueba procesos reales ni descargas.
DENUE local	INEGI_DENUE_04092026	[PENDIENTE]	Hejotzingo/Xaltocan	Trabajo local inicial.
Cuenca	caaresa_cuenca_alto_atoyac_21_feb_2019.gpkg	[PENDIENTE]	Región	Delimitacion espacial.
Municipios	caaresa_division_municipal_20_enero_2019.gpkg	[PENDIENTE]	Región	Contexto administrativo.
Red hidrografica	caaresa_red_hidro_digital_16_ago_2019.gpkg	[PENDIENTE]	Región	Distancia/priorizacion; no implica conectividad de descarga.
MH	data/processed/mh/	[PENDIENTE]	Local	Fuente complementaria; documentar origen, metodo y confianza.

Legacy	data/processed/legalhistorico	Variable	Comparacion/trazabilidad; no mezclar sin documentar diferencias.
--------	-------------------------------	----------	--

Preguntas guía

- ¿Quien produjo cada fuente, con que metodo y con que licencia?
- ¿Que fecha representa: descarga, levantamiento o vigencia?
- ¿Que campos se usan y cuales se descartan?
- ¿Que errores posicionales o de geocodificacion son esperables?
- ¿Como se identifican duplicados, establecimientos cerrados o cambios de giro?
- ¿Que fuente es “autoridad” cuando dos registros se contradicen?

Requisitos de trazabilidad

Para cada fuente conservar: ruta relativa, nombre original, URL o mecanismo de obtencion, fecha, tamaño, hash, CRS, numero de registros, campos clave, responsable de descarga y notas de transformacion.

7 Construcción del universo economico

7.1 Universo de partida

Explicar por que la descarga estatal acotada a SCIAN 313, 314, 315 y 81 es el punto de partida y que actividades quedan potencialmente fuera.

7.2 Filtro SCIAN

Preguntas guía

- ¿Que codigos completos y prefijos se incluyen?
- ¿Que logica sustantiva justifica cada codigo?
- ¿Que codigos son de manufactura, servicios, acabado, lavado o comercio?
- ¿Que codigos generan mayor riesgo de falsos positivos?
- ¿Como se documentan cambios de SCIAN entre versiones?

7.3 Filtro textual y diccionarios

Documentar normalizacion, campos explorados, expresiones regulares, prioridad de frases largas, terminos positivos, negativos y ambiguos, asi como version del diccionario.

Informacion y evidencia minima requerida

Adjuntar como anexo los diccionarios completos, no solo ejemplos. Cada termino deberia tener: categoria, significado, razon de inclusion, posible ambigüedad y version de alta/modificacion.

7.4 Separacion entre sector textil y evidencia de proceso humedo**Limite de interpretacion**

El universo sectorial debe distinguirse de la evidencia de proceso humedo. Una empresa puede pertenecer al sector textil y no mostrar en DENUe evidencia explicita de lavado/teñido/acabado; a la inversa, la ausencia de palabras clave no demuestra ausencia de uso de agua.

7.5 Reglas de inclusion/exclusion**Preguntas guía**

- ¿Como se excluye comercio simple de prendas?
- ¿Como se tratan “maquila”, “pantalon”, “mezclilla”, “planchado”, “deshebrado”, “recta/presilla/formador”, “fabrica de tela” y lavanderias?
- ¿Que condiciones producen Alta, Media, Revisar o No incluir?
- ¿Que reglas son automaticas y cuales requieren revision humana?
- ¿Como se registra el motivo exacto de cada decision?

8 Auditoria manual y evidencia externa**8.1 Protocolo de revision****Preguntas guía**

- ¿Que registros entran a auditoria manual y por que?
- ¿Que fuentes externas se permiten: Google Maps, Street View, sitio web, Facebook, directorios, anuncios de empleo, imagen satelital?
- ¿Que jerarquia de evidencia se aplica?
- ¿Como se documenta un establecimiento no encontrado, clausurado, con coordenadas dudosas o sin Street View?
- ¿Que fecha tiene la observacion y cuanto puede degradarse con el tiempo?

Informacion y evidencia minima requerida

Cada revision manual debe conservar, cuando sea posible: ID DENUe, nombre, coordenadas, fecha de consulta, URL, tipo de evidencia, captura/archivo, observacion normalizada, decision, nivel de confianza, revisor y segunda revision si existe conflicto.

Requisitos de trazabilidad

La auditoria humana debe ser reproducible en el sentido documental aunque una pagina web cambie. Conviene guardar evidencias permitidas, fecha de consulta y una nota factual separada de la interpretacion.

9 Integracion de fuentes complementarias y comparacion historica

9.1 Integracion MH

Explicar procedencia, criterio de matching, manejo de coincidencias, filas sinteticas y campos de procedencia.

9.2 Universos legacy

Describir para que se conservan los universos historicos y por que no deben mezclarse silenciosamente con la version actual.

Preguntas guia

- ¿Que registros se agregaron solo por MH?
- ¿Que porcentaje de la seleccion depende de fuentes no DENU?
- ¿Que diferencias entre versiones son altas reales, bajas, cambios de criterio o cambios de fuente?

10 Modalidades analiticas de la primera fase

Hechos ya identificados en el repositorio

El inventario documenta cinco modalidades: amplia + MH; amplia sin MH; estricta + MH; estricta sin MH; y todos los SCIAN. La ultima contiene 4,365 establecimientos en el universo municipal y 4,010 dentro de cuenca, y es la base de la Parte 2.

Preguntas guia

- ¿Que pregunta responde cada modalidad?
- ¿Por que es metodologicamente importante mantenerlas separadas?
- ¿Cuales son los cambios de conteo y distribucion entre ellas?
- ¿Que resultados son robustos a la modalidad y cuales dependen fuertemente del filtro?

Informacion y evidencia minima requerida

Incluir una tabla comparativa con: definicion formal, N municipal, N dentro de cuenca, MH agregados, ventajas, sesgos esperados y uso recomendado de cada modalidad.

11 Analisis espacial descriptivo de unidades economicas

11.1 Distribucion territorial

Mapas de puntos, conteos por municipio/localidad, densidad simple, estratos de personal, composicion sectorial y distancia a red hidrografica.

11.2 Distancia a hidrografia

Limite de interpretacion

La distancia geometrica a un cauce es un criterio de priorizacion espacial, no evidencia de que exista una descarga a ese cauce. Sin red de drenaje, topografia, punto de descarga y conectividad hidraulica no puede inferirse la ruta del agua residual.

Preguntas guia

- ¿Que estadistico de distancia se reporta y en que CRS?
- ¿Se mide a cualquier linea hidrografica o se diferencian cauces principales/secundarios?
- ¿Que umbrales se usan y por que?
- ¿Como afectan errores posicionales del DENUE a distancias cortas?

12 Diagnostico previo de estructura espacial

Principio: explorar la geometria de los puntos antes de elegir un algoritmo o usar atributos economicos.

Preguntas guia

- ¿Que muestran las distancias a k vecinos sobre escalas espaciales naturales?
- ¿Que patrones aparecen en KDE y malla hexagonal?
- ¿Hay heterogeneidad de densidad suficiente para preferir HDBSCAN/OPTICS sobre DBSCAN?
- ¿Como se detecta el efecto de borde de la cuenca?

Informacion y evidencia minima requerida

Documentar k , bandwidths, tamaño de hexagonos, unidades, reglas de visualizacion y como estos diagnosticos informaron el espacio de parametros sin “optimizar” con variables productivas.

13 Clustering espacial: diseño de experimentos

13.1 Universo de deteccion vs. universo de interpretacion

Explicar por que se usan 4,365 puntos para detectar agrupamientos y 4,010 dentro de cuenca para interpretarlos.

13.2 Algoritmos evaluados

DBSCAN, HDBSCAN y OPTICS, usando exclusivamente coordenadas metricas.

Preguntas guía

- ¿Que parametros se recorrieron para cada algoritmo?
- ¿Por que esos rangos son plausibles dadas las distancias observadas?
- ¿Cuantos escenarios se evaluaron y con la misma semilla/configuracion?
- ¿Como se almacenan las membresias de todos los escenarios?
- ¿Como se garantiza que SCIAN, proceso, municipio o evidencia hidrica no influyan en la formacion de clusters?

Hechos ya identificados en el repositorio

El inventario registra 57 escenarios y una semilla comun 20260921. La solucion principal reportada es HDBSCAN con `min_cluster_size=10`, `min_samples=20` y `cluster_selection_method=eom`.

14 Selecccion de la solucion espacial y robustez

14.1 Criterios de seleccion

La solucion principal debe justificarse por estabilidad y coherencia espacial, no porque produzca perfiles economicos “atractivos”.

Preguntas guía

- ¿Como se utilizaron ARI, Jaccard, continuidad, efecto de borde y perturbaciones espaciales?
- ¿Que mide cada metrica y cual es su limitacion?
- ¿Que escenarios se consideran principal, sensibilidad y referencia?
- ¿Que establecimientos cambian frecuentemente de cluster o ruido?
- ¿Cuales clusters son estables y cuales dependen del escenario?

Informacion y evidencia minima requerida

Incluir: matriz ARI entre escenarios seleccionados; Jaccard de correspondencia de clusters; persistencia por establecimiento; sensibilidad al ruido posicional; y tabla de justificacion de la solucion elegida.

14.2 Glosario minimo de metricas

Metrica	Que responde	Precaucion interpretativa
---------	--------------	---------------------------

ARI	¿Que tan similares son dos particiones completas, corrigiendo coincidencias esperadas por azar?	No dice que particion sea “verdadera” ni explica por si sola donde cambian las membresias.
Jaccard	¿Que tanto se solapan dos conjuntos/clusters comparables?	Requiere criterio de emparejamiento entre etiquetas arbitrarias.
Persistencia de membresia	¿Con que frecuencia un punto conserva una asignacion equivalente?	Depende del conjunto de escenarios comparados.
Proporcion de ruido	¿Que fraccion no es asignada a clusters bajo un escenario?	Mas ruido no es necesariamente peor; puede reflejar dispersion real.
Continuidad/compacidad	¿Que tan coherente es el cluster en el espacio?	Debe definirse exactamente la formula utilizada.
Efecto de borde	¿Cuanto cambia la estructura cerca del limite de estudio?	Un limite administrativo/hidrologico puede cortar una concentracion real.

15 Materializacion de clusters, borde y ruido

Preguntas guía

- ¿Cuantos clusters existen en el universo ampliado y cuantos intersectan/estan dentro de cuenca?
- ¿Como se definen las envolventes de cluster y que implicaciones tiene usar convex hull?
- ¿Cuantos establecimientos del mismo cluster quedan fuera de cuenca?
- ¿Donde se concentra el ruido y presenta patrones territoriales propios?

Limite de interpretacion

Un poligono envolvente de cluster es una abstraccion geometrica para visualizar concentracion; no representa una zona de servicio, una subcuenca de drenaje ni un area juridica.

16 Perfil economico y productivo posterior al clustering

Principio: primero se fija la geografia; despues se pregunta que contiene cada agrupamiento.

Preguntas guía

- ¿Como se distribuyen SCIAN, municipios, localidades y estratos de personal por cluster?
- ¿Que señales productivas aparecen: confeccion, lavanderia, acabado, tela, mezcilla, otros?
- ¿Que porcentaje de cada cluster tiene evidencia hidrica SI, REVISAR o ausencia de evidencia explicita?
- ¿Que clusters parecen especializados y cuales diversificados?
- ¿Que diferencias existen entre cluster y ruido disperso?

Informacion y evidencia minima requerida

Para cada cluster publicar una ficha estandar: N, superficie/envolvente, municipio/localidad dominante, top SCIAN, distribucion de personal, señales productivas, evidencia hidrica, distancia a red hidrografica, estabilidad y notas de incertidumbre.

17 Sobrerrepresentacion de señales

17.1 Base comparativa

Definir explícitamente contra que universo se compara cada cluster: idealmente los 4,010 establecimientos dentro de cuenca, salvo analisis particular debidamente justificado.

Preguntas guía

- ¿Que significa que una señal este sobrerrepresentada?
- ¿Cual es la proporcion dentro del cluster y cual la proporcion base?
- ¿Cual es el lift y el odds ratio?
- ¿La diferencia es estadisticamente compatible con algo mas que fluctuacion muestral segun Fisher?
- ¿Se corrigio por multiples pruebas mediante Benjamini–Hochberg?
- ¿Cual es el tamaño absoluto? Un lift grande con muy pocos casos puede ser poco operativo.

Informacion y evidencia minima requerida

Nunca presentar solo significancia. Reportar para cada señal: n cluster, n señal, proporcion cluster, proporcion base, diferencia absoluta, lift, odds ratio, intervalo si se calcula, p , q ajustado y una nota de relevancia practica.

18 Similitud entre clusters y tipologias productivas

Preguntas guía

- ¿Que variables entran al vector de perfil?
- ¿Como se escalan o ponderan variables con naturalezas distintas?
- ¿Que distancia se usa y por que?
- ¿La tipologia jerarquica representa similitud productiva, no proximidad espacial?
- ¿Que pares de clusters son mas parecidos y en que dimensiones?

Requisitos de trazabilidad

Conservar matrices de distancia por familia de variables y una matriz combinada. Asi puede auditarse si la similitud es impulsada por SCIAN, señales, personal o composicion territorial.

19 Mega-cluster y subnucleos exploratorios

Hechos ya identificados en el repositorio

El inventario reporta un cluster mayor de 1,997 establecimientos. La segunda pasada estudia subnucleos de forma diagnostica, sin reemplazar la membresia principal congelada.

Preguntas guía

- ¿Por que el mega-cluster aparece como una sola estructura con la configuracion principal?
- ¿Que subnucleos espaciales se observan internamente y cuantos establecimientos contiene cada uno?
- ¿Cuales son sus municipios/localidades, composicion productiva y señales hídricas?
- ¿Son los subnucleos estables a parametros razonables o solo una particion ilustrativa?
- ¿Alguno coincide con barreras/continuidades urbanas o hidrologicas que deban estudiarse posteriormente?

Limite de interpretacion

Los subnucleos diagnosticos no deben convertirse automaticamente en “proyectos de colector”. Son hipotesis de concentracion que necesitan contrastarse con topografia, drenaje existente, puntos de descarga y caudales.

20 Resultados principales por territorio

Esta seccion debe traducir el pipeline a hallazgos espaciales concretos, evitando repetir metodologia.

20.1 Resultados a escala de cuenca

[PENDIENTE] mapas y tabla de concentraciones principales.

20.2 Resultados por municipio

[PENDIENTE] ranking con N, densidad, clusters, señales, evidencia hidrica y estabilidad.

20.3 Resultados por localidad/corredor

[PENDIENTE] fichas territoriales donde exista suficiente concentracion o interes operativo.

20.4 Huejotzingo y Santa Ana Xalmimilulco

Incluir como caso detallado porque fueron parte de la primera fase de auditoria y cartografia local.

Preguntas guía

- ¿Que hallazgos sobreviven a cambios de filtro y parametros?
- ¿Cuales dependen de registros dudosos o revisiones manuales?

- ¿Que concentraciones tienen evidencia suficiente para visita de campo prioritaria?

21 De diagnostico economico a priorizacion preliminar de colectores

Objetivo: especificar exactamente como este trabajo puede alimentar una siguiente etapa de ingenieria sin saltarse pasos de validacion.

21.1 Lo que este analisis si puede aportar

- Localizar concentraciones de actividad economica potencialmente relevante.
- Identificar zonas donde conviene concentrar inspeccion, entrevistas, aforos o muestreo.
- Comparar sensibilidad de una prioridad territorial ante definiciones amplias/estrictas.
- Señalar concentraciones robustas que merecen cruzarse con red sanitaria, topografia y descargas.
- Generar una base georreferenciada auditable para incorporar nueva evidencia.

21.2 Lo que falta antes de justificar inversion

1. **Validacion de establecimientos:** operacion actual, proceso real, horarios, volumen de produccion.
2. **Caracterizacion de agua residual:** caudal medio/maximo, variabilidad, DQO/DBO, SST, color, temperatura, pH, sales, metales u otros parametros pertinentes al proceso.
3. **Puntos y forma de descarga:** alcantarillado, descarga directa, infiltracion, transporte, recirculacion, tratamiento propio.
4. **Infraestructura existente:** colectores, atarjeas, diametros, pendientes, capacidad residual, condiciones fisicas, plantas de tratamiento.
5. **Topografia e hidraulica:** cotas, subcuencas de drenaje, bombeo, cruces, servidumbres, riesgos.
6. **Demanda futura:** crecimiento urbano/industrial y escenarios de conexion.
7. **Compatibilidad de tratamiento:** efecto del efluente industrial sobre el tren de tratamiento previsto/existente.
8. **Factibilidad economica:** CAPEX, OPEX, costo por m³, costo por usuario/establecimiento atendido, alternativas.
9. **Marco regulatorio e institucional:** competencias, permisos, responsabilidades, descarga y pretratamiento.
10. **Dimension social y ambiental:** poblacion beneficiada, exposicion, conflictos, equidad, impactos de obra.

21.3 Matriz de priorizacion de siguiente etapa

Criterio	Estado	Fuente prevista	Uso
Concentracion espacial de unidades	Disponible	Clustering	Priorizar zonas, no diseñar trazo.

Señal de proceso humedo	Parcial	DENUE + auditoria	Priorizar validacion.
Tamaño/personal	Parcial	DENUE	Proxy debil de escala; no equivale a caudal.
Distancia a hidrografia	Disponible	GIS	Contexto/priorizacion, no conectividad.
Red sanitaria existente	[PENDIENTE]	Organismo operador/levantamiento	Determinar posibilidad de conexion.
Topografia	[PENDIENTE]	DEM/levantamiento	Delimitar drenaje por gravedad.
Caudal real	[PENDIENTE]	Aforo	Dimensionamiento.
Calidad de descarga	[PENDIENTE]	Muestreo	Diseño de pretratamiento/tratamiento.
Poblacion beneficiada/expuesta	[PENDIENTE]	INEGI/salud/territorio	Beneficio social y prioridad.
Costo de alternativa	[PENDIENTE]	Ingenieria conceptual	Comparacion economica.

22 Marco de priorizacion multicriterio: propuesta para etapa posterior

Limite de interpretacion

No asignar pesos ni producir un ranking de inversion hasta que los criterios faltantes tengan datos comparables y exista una gobernanza explicita de la decision. El analisis actual puede producir un ranking de *prioridad de investigacion/validacion*, no de inversion definitiva.

Preguntas guia

- ¿Que resultado se quiere priorizar: visita, muestreo, anteproyecto, obra?
- ¿Quien define pesos: equipo tecnico, organismo operador, autoridad, comunidad?
- ¿Que criterios son de beneficio, costo, riesgo o restriccion dura?
- ¿Como se incorporara incertidumbre y sensibilidad a pesos?
- ¿Que umbrales descalifican una alternativa independientemente del puntaje?

23 Validacion, control de calidad y pruebas de integridad

Preguntas guia

- ¿Los IDs DENUE son unicos en cada universo esperado?
- ¿Se conserva el conteo al hacer joins que no deberian multiplicar filas?
- ¿Hay geometrias nulas, invalidas o fuera de rango?
- ¿Las capas estan en el CRS esperado antes de medir distancias?
- ¿Los perfiles se calculan exactamente sobre 4,010 registros dentro de cuenca?

- ¿Las variables productivas estan ausentes del paso de clustering?
- ¿Los PDFs/figuras corresponden al ultimo estado de datos y codigo?

Informacion y evidencia minima requerida

Adjuntar la validacion automatizada, manifiesto de archivos y hashes. El inventario actual señala que `218_validar_cierre_parte2.py` genera `validacion_final.csv` e `inventario_cierre.csv`.

24 Incertidumbre, sesgos y limitaciones

24.1 Registro de incertidumbres

Fuente	Posible efecto	Severidad	Mitigacion/documentacion
Cobertura DENUÉ	Omision de informales/no registrados	Alta	Fuentes complementarias y campo.
Giro declarado	No refleja todos los procesos internos	Alta	Auditoria y entrevistas.
Coordenada	Error posicional afecta distancias/cluster local	Media/Alta	Validar casos sensibles y perturbacion espacial.
Fecha de registro	Cierres/cambios de actividad	Media	Fecha de consulta y verificacion.
Filtro textual	Falsos positivos/negativos	Media	Diccionarios versionados y auditoria.
Limite de cuenca	Efecto de borde	Media	Universo ampliado de deteccion.
Clustering	Sensibilidad a parametros y densidad	Media	Escenarios, ARI/Jaccard/persistencia.
Proxy personal	No equivale a produccion ni caudal	Alta para ingenieria	No usar para dimensionamiento.
Distancia a rio	No equivale a ruta de descarga	Alta	Requiere red/topografia/descarga.

Preguntas guia

- ¿Que incertidumbres pueden cambiar una prioridad territorial?
- ¿Cuales solo afectan detalle, no la conclusion general?
- ¿Que incertidumbre puede reducirse barato mediante una visita o una nueva fuente?

25 Reproducibilidad computacional

25.1 Estructura del pipeline

Documentar scripts 00–10, 99, 100–102 y 200–222 por fase, entradas, salidas y dependencias.

25.2 Orden de ejecucion

```
python scripts/101_main_cuenca_puebla.py --todos-scian
python scripts/219_ejecutar_parte2_completa.py
python scripts/220_segunda_pasada_analitica.py
python scripts/221_figuras_interactivo_segunda_pasada.py
python scripts/222_documentar_segunda_pasada.py
python scripts/217_compilar_documentos_parte2.py
```

25.3 Entorno

Preguntas guia

- ¿Version exacta de Python?
- ¿Versiones de pandas, geopandas, shapely, scikit-learn, scipy, matplotlib, plotly y HDBSCAN utilizado?
- ¿Sistema operativo y versiones de GDAL/PROJ?
- ¿Existe `requirements.txt`, `pyproject.toml` o `environment.yml`?
- ¿Puede reconstruirse el reporte desde una maquina limpia?

Limite de interpretacion

El inventario actual indica que no se encontro archivo explicito de entorno ni repositorio Git en la raiz. Para una cadena de decision de inversion, conviene corregir ambos puntos antes de congelar el reporte final.

26 Matriz maestra de trazabilidad de afirmaciones

Uso: cada afirmacion relevante del resumen ejecutivo y conclusiones debe poder seguirse hasta su evidencia.

Afirmacion	Fuente primaria	Transformacion/salida	Salida que la demuestra	Validacion	Caveat
El universo ampliado contiene 4,365 establecimientos	DENUE + regla sectorial	101/201	resumen de universo / matriz maestra	conteo + unicidad	Depende de cobertura y criterio sectorial.
4,010 se ubican dentro de cuenca	capa cuenca + puntos	101/201/202	matriz/geopackage	interseccion espacial	Depende de delimitacion y precision posicional.
La solucion principal tiene 22 clusters	matriz XY	204-206	resumen escenario + membresia	reproducibilidad parametros	No equivale a zonas de servicio.
[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]

27 Conclusiones

Preguntas guía

- ¿Que aprendimos sobre la distribucion del sector que no era visible antes?
- ¿Que patrones son robustos y cuales permanecen inciertos?
- ¿Que territorios justifican una segunda etapa de verificacion?
- ¿Que evidencia adicional es la mas valiosa para reducir incertidumbre?
- ¿Cual es la decision concreta que se recomienda tomar ahora, y cual aun no?

Informacion y evidencia minima requerida

Las conclusiones deben estar clasificadas como: **resultado observado**, **inferencia razonable**, **hipotesis de trabajo** o **recomendacion**. Evitar mezclar categorias.

28 Plan de siguientes pasos

1. Congelar y versionar el repositorio actual.
2. Crear archivo de entorno reproducible.
3. Cerrar diccionarios y reglas de clasificacion con version.
4. Completar auditoria manual de registros prioritarios.
5. Generar fichas por cluster/subnucleo con incertidumbre.
6. Cruzar zonas prioritarias con red sanitaria y topografia.
7. Diseñar campaña de campo: verificacion, aforo y muestreo.
8. Construir balance preliminar de caudales/cargas por zona validada.
9. Desarrollar alternativas conceptuales de colectores.
10. Evaluar tecnica, economica, ambiental y socialmente las alternativas.

A Anexo A. Inventario de scripts y productos

Incorporar el inventario completo del repositorio con, al menos: script, version/hash, objetivo, entradas, salidas, parametros, dependencia anterior, uso actual y estatus (activo/historico/deprecado).

Informacion y evidencia minima requerida

El inventario actual documenta 38 scripts Python y 15 carpetas/etapas de resultados en **outputs/parte_2/**. Conviene convertir ese inventario en una tabla generada automaticamente para que no quede obsoleta.

B Anexo B. Diccionario de datos de la matriz maestra

Para cada variable: nombre, tipo, unidad, fuente, transformacion, valores validos, nulos, significado, version y uso en analisis. Marcar explicitamente si la variable entra al clustering, al perfilado o solo a visualizacion.

C Anexo C. Diccionarios SCIAN y texto

Publicar los catalogos completos utilizados en cada version, incluyendo terminos positivos, negativos, ambiguos, categorias de proceso y justificacion.

D Anexo D. Bitacora de auditoria manual

Tabla por establecimiento con evidencia, URL, fecha, revisor, nota factual, interpretacion, decision y confianza.

E Anexo E. Catalogo de figuras, mapas y tablas

Registrar titulo, archivo, script generador, fuente, fecha de creacion, universo, CRS y mensaje analitico. Incluir tanto mapas PNG como HTML interactivos.

F Anexo F. Glosario metodologico

Incluir como minimo: SCIAN, DENU, universo sectorial ampliado, evidencia hidrica, proceso humedo, CRS, UTM, efecto de borde, DBSCAN, HDBSCAN, OPTICS, ruido, min_cluster_size, min_samples, EOM, ARI, Jaccard, persistencia, KDE, k-NN, lift, odds ratio, Fisher exacta, Benjamini-Hochberg, distancia de perfiles, linkage y subnucleo diagnostico.

G Anexo G. Registro de decisiones metodologicas

Para cada decision: ID, fecha, pregunta, opciones consideradas, decision, justificacion, evidencia, responsable, consecuencias, archivos afectados y condicion que obligaria a revisarla.

H Anexo H. Registro de cambios

Version	Fecha	Responsable	Cambio
0.1	24 de septiembre de 2026	[PENDIENTE]	Estructura maestra y guia de evidencia.

I Anexo I. Checklist previo a publicacion

- ☐ Todas las cifras del resumen ejecutivo se reproducen desde salidas finales.
- ☐ Todas las figuras indican universo, fuente, fecha y CRS cuando aplica.
- ☐ Ninguna distancia geografica fue calculada en grados.

- ☐ El clustering usa exclusivamente variables espaciales declaradas.
- ☐ Se conserva el ruido y se explica su interpretacion.
- ☐ Sobrerrepresentacion reporta base, tamaño absoluto y correccion multiple.
- ☐ El mega-cluster no fue reemplazado silenciosamente por subclusters exploratorios.
- ☐ El reporte distingue presencia economica de evidencia de descarga.
- ☐ El reporte distingue prioridad de investigacion de prioridad de inversion.
- ☐ Existen entorno reproducible y version congelada del codigo.
- ☐ Los hashes de fuentes y productos finales estan archivados.
- ☐ Existe una ruta de trazabilidad para cada conclusion principal.

J Anexo J. Fuentes y antecedentes a incorporar

- INEGI – DENUÉ y diccionario de datos de la version utilizada.
- Fuente oficial de poligono de cuenca, division municipal y red hidrografica.
- Informes tecnicos de CONAGUA/SEMARNAT/autoridades estatales pertinentes.
- Registros de emisiones/transferencias y descargas cuando sean aplicables.
- Literatura academica y tecnica sobre contaminacion, actividad textil y salud ambiental en la Cuenca del Alto Atoyac.
- *Salud ambiental en la Cuenca del Alto Atoyac: situacion, peligros ambientales y acciones para reducir el riesgo de enfermedades cronicas no transmisibles*, como antecedente contextual a revisar y citar formalmente en la version final.