

Diagnostico preliminar de unidades economicas y concentracion espacial

para la planeacion de infraestructura de colectores

Cuenca del Alto Atoyac

Naturaleza del documento: reporte tecnico maestro de trazabilidad

Funcion: documentar el diagnostico preliminar de unidades economicas, el analisis espacial realizado y su alcance como insumo de preseleccion para estudios posteriores de colectores.

No sustituye: aforo de descargas, muestreo de calidad, levantamiento de red, modelacion hidraulica, estudio de factibilidad ni proyecto ejecutivo.

Autor/a:	No consignado en los metadatos del documento
Institucion:	No consignada en los metadatos del documento
Version:	0.1 – estructura maestra
Fecha de corte:	24 de septiembre de 2026
Repositorio/directorio:	Repositorio del proyecto Alto Atoyac
Responsable de revision:	Por designar antes de la entrega institucional

Índice

1. Resumen ejecutivo	4
2. Contexto de decision, proposito y alcance	7
2.1. Problema de decision: Alcance del diagnóstico y relación con decisiones posteriores . . .	7
2.2. Objetivo general	8
2.3. Objetivos especificos	9
3. Antecedentes ambientales y territoriales	9
3.1. Transformación territorial e industrialización de la cuenca	9
3.2. Industria textil y procesos asociados con la mezclilla	10
3.3. Territorios de interés dentro de la cuenca	11
3.4. Vacío de información y posición del presente diagnóstico	11
4. Area de estudio y unidades territoriales	12
4.1. Delimitacion de la cuenca	12
4.2. Red hidrografica y contexto territorial	13
4.3. Sistemas de referencia	14
5. Fuentes de datos y gobierno de informacion	15
5.1. Inventario maestro de fuentes	15
6. Construcción del universo economico	18
6.1. Universo de partida	18
6.2. Filtro SCIAN	19
6.3. Filtro textual y diccionarios	19
6.4. Separacion entre sector textil y evidencia de proceso humedo	20
6.5. Reglas de inclusion/exclusion	20
7. Auditoria manual y evidencia externa	22
7.1. Protocolo de revision	22
8. Alcance inicial y transicion al analisis regional	24
8.1. Version 1: Huejotzingo y Santa Ana Xalmimilulco	24
8.2. Transicion metodologica	25
8.3. Parte 1 regional: flujo automatico para los municipios de la cuenca	26
9. Modalidades analiticas de la primera fase	27
9.1. Decisiones comunes y denominadores	27
9.2. Regla amplia, regla estricta y efecto de la decision	28
9.3. Integracion de MH como variante separada	28
9.4. Lectura individual de cada modalidad	28
9.5. Consecuencias para la interpretacion	31
10. Analisis espacial descriptivo de unidades economicas	31
10.1. Tamaño y sensibilidad del universo	31
10.2. Concentracion municipal y participacion territorial	31
10.3. Efecto espacial de MH	33
10.4. Lavanderias sensibles al criterio estricto	34

10.5. Estratos de personal ocupado	35
10.6. Distancia a hidrografia	36
11. Diagnostico previo de estructura espacial	38
11.1. Distancias a vecinos y escalas espaciales	38
11.2. KDE y malla hexagonal en la cuenca	39
11.2.1. Estimación de densidad por kernel	39
11.2.2. Malla hexagonal	40
11.3. Heterogeneidad de densidad y eleccion de familia algoritmica	43
11.4. Lectura multiescala del mega-cluster	43
11.5. Efecto de borde de la cuenca	45
12. Clustering espacial: diseño de experimentos	45
12.1. Universo de deteccion vs. universo de interpretacion	45
12.2. Algoritmos evaluados	45
12.3. Configuracion reproducible y almacenamiento	46
13. Seleccion de la solucion espacial y robustez	47
13.1. Criterios de seleccion	47
13.2. Escenarios seleccionados e identificacion de la particion	49
13.3. Justificacion de la solucion seleccionada	51
13.4. ARI entre particiones seleccionadas	53
13.5. Jaccard, persistencia y establecimientos sensibles	53
13.6. Perturbacion posicional y limites de la seleccion	54
13.7. Glosario minimo de metricas	55
14. Materializacion de clusters, borde y ruido	55
14.1. Envoltentes y efecto de borde	56
14.2. Distribucion territorial del ruido	58
15. Perfil economico y productivo posterior al clustering	59
15.1. Lectura territorial de los perfiles	59
15.2. Evidencia hidrica y escala laboral	61
15.3. Atlas: contraste de casos representativos	62
15.4. Clusters frente a actividad dispersa	63
16. Sobrerrepresentacion de señales	64
16.1. Base comparativa	64
16.2. Prueba estadistica y criterio de reporte	65
16.3. Resultados de sobrerrepresentacion	65
17. Similitud entre clusters y tipologias productivas	69
17.1. Construccion del vector y distancia combinada	69
17.2. Tipologia jerarquica y resultados	69
18. Mega-cluster y subnucleos exploratorios	72
18.1. Por que aparece una sola estructura	72
18.2. Segunda pasada y subnucleos observados	72
18.3. Estabilidad y relacion con barreras territoriales	74

19.Resultados principales por territorio	74
19.1. Resultados a escala de cuenca	75
19.2. Resultados por municipio	75
19.3. Resultados por localidad/corredor	75
19.4. Huejotzingo y Santa Ana Xalmimilulco	76
20.Siguientes pasos y aportaciones	77
20.1. Que se gana con el analisis	77
20.2. Como acceder a los resultados en este reporte	78
20.3. Donde estan guardados los datos relevantes	78
20.4. Integracion con hidrologia, drenaje y plantas de tratamiento	80
20.5. Siguietes pasos inmediatos	81
A. Anexo A. Inventario de scripts y productos	81
B. Anexo B. Diccionario de datos de la matriz maestra	82
C. Anexo C. Diccionarios SCIAN y texto	84
D. Anexo D. Bitacora de auditoria manual	86
E. Anexo E. Catalogo de figuras, mapas y tablas	86
F. Anexo F. Glosario metodologico	87
G. Anexo G. Registro de decisiones metodologicas	88
H. Anexo J. Fuentes y antecedentes a incorporar	89

Resumen

Este proyecto desarrolla un diagnóstico territorial y económico de las unidades productivas potencialmente relacionadas con actividades textiles, de confección, lavandería y tintorería dentro de la cuenca del Alto Atoyac, Puebla. El objetivo es identificar patrones de concentración espacial y caracterizar zonas donde existe una presencia relevante de establecimientos cuya actividad declarada puede estar asociada con procesos de consumo de agua o generación de descargas. El análisis se plantea como una herramienta de priorización: busca reducir y ordenar el universo de observación para orientar verificaciones en campo, monitoreo ambiental y análisis posteriores de infraestructura, sin interpretar la información económica disponible como evidencia directa de contaminación o de la existencia, magnitud o destino de una descarga.

La construcción del universo parte del Directorio Estadístico Nacional de Unidades Económicas (DENUE), complementado con información territorial de la cuenca, límites municipales, red hidrográfica y fuentes auxiliares e históricas. A partir de estos insumos se desarrolló un proceso auditable de selección basado en recortes territoriales, códigos SCIAN y reglas textuales aplicadas a nombres, razones sociales y descripciones de actividad. Para estudiar la sensibilidad de esta delimitación se construyeron cinco modalidades con distintos niveles de restricción, incluyendo criterios amplios y estrictos, con y sin fuentes complementarias, además de un universo sectorial ampliado que conserva todos los establecimientos pertenecientes a las actividades seleccionadas. Este último comprende 4,365 unidades económicas dentro de los municipios utilizados para el análisis espacial, de las cuales 4,010 se localizan dentro de la cuenca.

Sobre este universo se realizó una exploración sistemática de métodos de clustering espacial por densidad mediante DBSCAN, HDBSCAN y OPTICS. La construcción de los agrupamientos utilizó exclusivamente las coordenadas de los establecimientos proyectadas en un sistema métrico, manteniendo fuera del proceso de clustering las variables económicas y productivas. Esta separación permite que la estructura espacial sea identificada primero y que su interpretación sectorial ocurra únicamente después. Se evaluaron 57 configuraciones considerando número y tamaño de clusters, proporción de ruido, continuidad espacial, sensibilidad al efecto de borde, similitud entre particiones y estabilidad frente a perturbaciones posicionales. A partir de esta comparación se seleccionó como solución principal una configuración HDBSCAN que identifica 22 agrupamientos y conserva 584 establecimientos como actividad espacialmente dispersa.

Una vez fijada la solución espacial, los clusters fueron caracterizados según su composición municipal y local, actividad SCIAN, tamaño de los establecimientos, señales textuales asociadas con procesos potencialmente hídricos y coexistencia de actividades manufactureras con servicios de lavandería o tintorería. El análisis se complementó con medidas de sobrerrepresentación, similitud entre perfiles productivos, persistencia de membresía y una exploración de la estructura interna del agrupamiento de mayor tamaño. Los resultados fueron organizados en tablas auditables, capas geográficas, mapas estáticos e interactivos, un atlas de clusters y productos documentales reproducibles.

En conjunto, el proyecto construye una base trazable para reconocer concentraciones territoriales de actividad económica potencialmente relevantes dentro de la problemática ambiental del Alto Atoyac. Sus resultados no identifican por sí mismos establecimientos contaminantes ni sustituyen aforos, muestreos, inspecciones o estudios hidráulicos. Su principal aportación consiste en pasar de un universo amplio y heterogéneo de unidades económicas a una estructura territorial interpretable, que permite reconocer dónde se concentra la actividad, qué tipos de procesos aparecen juntos y qué zonas requieren una revisión más profunda. Con ello se genera una base preliminar para priorizar trabajo de campo y análisis posteriores sobre descargas, colectores, tratamiento y gestión ambiental.

1 Resumen ejecutivo

Objetivo de esta sección: permitir que una persona que no lea el resto del documento entienda que se hizo, que se encontró, que tan confiable es y que decisión puede apoyar.

1. **¿Cuál fue el problema operativo que motivó el análisis?** La información disponible no permitía saber con suficiente precisión donde se concentran territorialmente las unidades económicas textiles, de confección, lavandería y tintorería potencialmente relevantes para la problemática del

Alto Atoyac. Antes de realizar verificaciones de campo o discutir infraestructura era necesario construir un universo consistente y auditable, separar la actividad declarada de la evidencia de procesos humedos y reducir el territorio a zonas de observacion defendibles.

2. **¿Que universo de unidades economicas se estudio y por que?** Se partio de 15,956 registros de la descarga estatal DENUe acotada a las actividades SCIAN seleccionadas. De ellos se definio un universo sectorial ampliado de 4,365 establecimientos ubicados en 26 municipios de referencia. Este universo se utilizo para detectar concentraciones sin cortar artificialmente los agrupamientos en el limite de la cuenca y reducir el efecto de borde. Para la interpretacion sustantiva se conservaron los 4,010 establecimientos que intersectan el poligono de la cuenca del Alto Atoyac. Esta delimitacion incluye actividades textiles, confeccion y servicios de lavanderia o tintoreria potencialmente relevantes, pero no supone que todos los establecimientos utilicen procesos humedos o descarguen contaminantes.
3. **¿Que metodos se usaron para clasificar, mapear y detectar concentraciones?** La clasificacion combino recorte territorial, codigos SCIAN, normalizacion y busqueda de expresiones en nombre, razon social y descripcion de actividad, reglas auditables de inclusion y evidencia hidrica, y comparaciones con fuentes MH y universos historicos. El mapeo se realizo mediante intersecciones espaciales con la cuenca y los municipios, calculo metrico de distancias a la red hidrografica y produccion de capas GeoPackage, mapas PNG y mapas HTML. Para detectar concentraciones se exploraron 57 configuraciones de DBSCAN, HDBSCAN y OPTICS utilizando exclusivamente coordenadas proyectadas en EPSG:32614. La seleccion considero estructura de la particion, ruido, continuidad, efecto de borde, ARI, Jaccard, persistencia y sensibilidad a perturbaciones posicionales. Las caracteristicas economicas se incorporaron solamente despues de fijar la solucion espacial.
4. **¿Cuales son los hallazgos que cambian la comprension territorial del problema?**
 - La actividad potencialmente relevante no se distribuye de manera uniforme: presenta nucleos locales y corredores diferenciados, junto con actividad dispersa que no debe eliminarse del diagnostico.
 - De los 4,365 establecimientos usados para la deteccion, 4,010 se encuentran dentro de la cuenca; el contexto exterior inmediato resulta necesario para controlar el efecto de borde.
 - La solucion principal identifica 22 clusters en el universo ampliado; 18 intersectan la cuenca y se documentan como concentraciones interiores.
 - Un mega-cluster de 1,997 establecimientos articula principalmente Puebla y el continuo urbano asociado con Cholula y Cuautlancingo. Su escala exige interpretarlo como una estructura heterogenea y no como una unica zona operativa.
 - Existen concentraciones claramente localizadas fuera del nucleo metropolitano, entre ellas Santa Ana Xalmimilulco, Huejotzingo, San Matias Tlalancalca, San Rafael Ixtapalucan, San Rafael Tlanalapan, Santa Maria Moyotzingo, San Martin Texmelucan, San Miguel Xoxtla y Amozoc de Mota.
 - Santa Ana Xalmimilulco forma un cluster de 337 establecimientos, mientras San Matias Tlalancalca registra otro de 224 y San Rafael Ixtapalucan uno de 142; por tanto, la concentracion sectorial no se explica solamente por Puebla capital.
 - Los perfiles productivos difieren entre clusters: algunos se asocian principalmente con confeccion o manufactura textil y otros presentan mayor participacion de lavanderias y tintorerias. La cercania espacial no implica homogeneidad productiva.
 - Ninguno de los seis escenarios principal, de referencia o de sensibilidad genera un cluster interior compuesto por al menos 80 % de lavanderias; la problematica territorial es de coexistencia de

actividades, no de enclaves exclusivamente dedicados a ese servicio.

- La solución conserva 584 registros como ruido espacial, equivalentes al 13.38 % del universo de detección. Estos representan actividad dispersa y no establecimientos irrelevantes.
- La estabilidad de las concentraciones no es uniforme; por ello la priorización debe combinar tamaño, composición, persistencia y verificación territorial, y no depender solamente de la etiqueta de cluster.

5. **¿Que zonas aparecen como candidatas para una segunda etapa de validación?** Por tamaño, persistencia o perfil económico aparecen como candidatas el continuo Puebla–Cholula–Cuautlancingo; Santa Ana Xalmimilulco y Huejotzingo; San Matías Tlalancalca; las concentraciones de Tlahuapan, particularmente San Rafael Ixtapalucan; el corredor de San Martín Texmelucan, San Rafael Tlanalapan y Santa María Moyotzingo; San Miguel Xoxtla–Coronango; y Amozoc de Mota. La candidatura significa prioridad para contrastar el directorio con procesos reales, descargas e infraestructura; no constituye una declaración de contaminación ni una recomendación directa de obra.
6. **¿Que no puede concluirse a partir de DENUE, proximidad a ríos o clustering?** DENUE informa ubicación y actividad económica declarada, pero no demuestra que un establecimiento se encuentre activo, ejecute procesos húmedos, consuma determinado volumen de agua, genere una descarga, vierta contaminantes o incumpla una norma. La proximidad cartográfica a un río no demuestra conexión hidráulica, ruta de descarga ni afectación del cauce. Un cluster expresa densidad y continuidad espacial bajo parámetros específicos; no equivale a una cuenca sanitaria, zona de servicio, red de colectores, fuente causal de contaminación ni prioridad automática de inversión. Tampoco pueden inferirse caudales, cargas contaminantes, capacidad de tratamiento o costos de infraestructura a partir de estos resultados.
7. **¿Cuales son los siguientes estudios indispensables antes de hablar de inversión en colectores?** Se requieren verificación de actividad y proceso en campo; identificación de puntos, horarios y rutas reales de descarga; aforos y muestreo físico-químico por estratos productivos; inventario georreferenciado de atarjeas, colectores, pozos de visita y conexiones; delimitación de áreas realmente tributarias con topografía y modelos de elevación; evaluación de capacidad, tecnología y compatibilidad de las plantas de tratamiento existentes; y estimaciones de caudal, carga, CAPEX, OPEX, riesgo, permisos y gobernanza para alternativas comparables. Solo al integrar estas evidencias puede pasarse de una priorización territorial a escenarios de conducción y tratamiento.

Cuadro 1: Síntesis ejecutiva del universo, la solución espacial y su uso recomendado

Indicador	Resultado e interpretación
Universo inicial	15,956 registros de la descarga estatal DENUÉ acotada a las actividades SCIAN consideradas.
Universo sectorial	4,365 establecimientos en 26 municipios; universo ampliado empleado para detectar concentraciones y reducir el efecto de borde.
Universo dentro de cuenca	4,010 establecimientos usados para interpretar los perfiles y resultados dentro del polígono del Alto Atoyac.
Escenarios de clustering	57 configuraciones de DBSCAN, HDBSCAN y OPTICS evaluadas exclusivamente con coordenadas métricas.
Solución seleccionada	HDBSCAN con <code>min_cluster_size=10</code> , <code>min_samples=20</code> y selección eom.
Número de clusters	22 en el universo ampliado; 18 intersectan la cuenca y se documentan como concentraciones interiores.
Ruido	584 establecimientos, 13.38 % del universo de detección; se interpretan como actividad espacialmente dispersa y se conservan en el análisis.
Principales zonas de concentración	Puebla–Cholula–Cauhtlancingo; Santa Ana Xalmimilulco y Huejotzingo; San Matías Tlalancalca; Tlahuapan; corredor de San Martín Texmelucan–San Rafael Tlanalapan–Santa María Moyotzingo; San Miguel Xoxtla–Coronango; y Amozoc de Mota.
Nivel de incertidumbre	Medio–alto para inferir procesos, descargas o necesidades de infraestructura; menor para describir localización y densidad de establecimientos registrados. Depende de cobertura y vigencia de DENUÉ, precisión posicional, reglas sectoriales, parámetros y efecto de borde.
Siguiente paso recomendado	Validación territorial priorizada: censo y entrevistas, verificación de procesos y descargas, aforos y muestreo, catastro y capacidad de la red, topografía y análisis técnico–económico de alternativas antes de proponer colectores.

2 Contexto de decisión, propósito y alcance

2.1 Problema de decisión: Alcance del diagnóstico y relación con decisiones posteriores

El presente análisis corresponde a una etapa diagnóstica y de priorización preliminar. Su objetivo inmediato es localizar actividad económica potencialmente relevante, reconocer concentraciones espaciales y corredores productivos, y ordenar territorialmente aquellas zonas que requieren una revisión más profunda. En este sentido, los resultados buscan reducir un universo amplio de unidades económicas a un conjunto de áreas y patrones que puedan ser estudiados con mayor detalle mediante visitas de campo, censos, entrevistas, aforos y muestreos.

El análisis no pretende determinar directamente necesidades de infraestructura ni definir trazos de colectores. Las fuentes utilizadas permiten conocer la localización y actividad declarada de los establecimientos, así como estudiar la forma en que éstos se concentran en el territorio, pero no contienen información suficiente sobre consumo de agua, puntos efectivos de descarga, caudales, cargas contaminantes o condiciones de conexión a la infraestructura existente. Por esta razón, la presencia de una concentración de unidades económicas debe interpretarse como un criterio para priorizar investigación adicional y no como evidencia suficiente para justificar una intervención hidráulica.

Dentro de esta etapa, los clusters funcionan como unidades exploratorias que permiten organizar y comparar concentraciones de establecimientos. Su utilidad consiste en identificar estructuras espaciales que no necesariamente son evidentes al observar cada unidad económica de manera independiente. Sin

embargo, estos agrupamientos no constituyen por sí mismos unidades de planeación de infraestructura. Conforme avance la validación, será necesario trasladar el análisis hacia escalas compatibles con el comportamiento real del sistema de saneamiento. Dependiendo de la evidencia disponible, éstas podrán corresponder a localidades o corredores productivos para organizar el trabajo de campo, áreas de aportación o subcuencas para comprender los flujos territoriales, y posteriormente tramos de drenaje, sistemas de saneamiento o alternativas específicas de conducción para la evaluación técnica.

De la misma manera, en esta fase no se establece un horizonte temporal formal de diseño o inversión. Antes de definirlo será necesario contar con una línea base territorial e hidráulica validada y considerar variables que actualmente se encuentran fuera del alcance del diagnóstico, como crecimiento urbano y productivo, variación temporal de los caudales, capacidad disponible y futura de las redes y sistemas de tratamiento, vida útil de la infraestructura, requerimientos de mantenimiento y escenarios de demanda.

En consecuencia, cualquier evaluación posterior de inversión requerirá integrar evidencia adicional sobre la localización y estado de la infraestructura existente, conexiones y descargas verificadas, caudales y cargas contaminantes, capacidad residual de redes y plantas de tratamiento, topografía, población beneficiada y expuesta, restricciones territoriales, costos de ciclo de vida y viabilidad jurídica y social. También será necesario comparar alternativas que no se limiten a la construcción de infraestructura de conducción, sino que consideren opciones de prevención, pretratamiento, tratamiento, reúso y manejo localizado de las descargas.

La función de esta etapa es, por tanto, anterior a la evaluación de infraestructura. Primero se busca establecer dónde se concentra la actividad económica potencialmente relevante y qué características presentan dichas concentraciones; posteriormente deberá verificarse qué ocurre realmente en esos territorios y cómo se relacionan las unidades productivas con el sistema hídrico y sanitario. Sólo a partir de esa evidencia será posible avanzar hacia la comparación de alternativas técnicas y, eventualmente, hacia decisiones de inversión.

Posible conexión con etapas posteriores

La conexión inmediata de este diagnóstico con una etapa posterior consiste en transformar las concentraciones identificadas en una estrategia de levantamiento territorial. Los clusters, sus perfiles productivos, su estabilidad y la actividad dispersa permiten decidir donde iniciar verificaciones, pero la siguiente unidad de trabajo debe construirse mediante evidencia de campo. Al contrastar los establecimientos registrados con procesos reales, puntos de descarga, volúmenes, calidad del agua, redes existentes y condiciones topográficas, será posible determinar si las concentraciones económicas coinciden o no con áreas funcionales de aportación y con problemas de saneamiento observables.

Solo después de esa validación podrá establecerse una conexión justificable con la planeación de infraestructura. Los resultados económicos y espaciales podrían incorporarse como una capa de demanda potencial dentro de estudios de subcuencas, modelación hidráulica y evaluación multicriterio de alternativas. Esa integración permitiría comparar intervenciones como control en la fuente, pretratamiento industrial, rehabilitación de redes, ampliación de tratamiento, soluciones descentralizadas o nuevos colectores. Por tanto, el proyecto aporta un criterio para ordenar la investigación posterior, pero no define trazos, dimensiones, costos ni decisiones de inversión.

2.2 Objetivo general

Construir un diagnóstico territorial, económico y espacial auditable de las unidades económicas potencialmente relevantes para la problemática hídrica de la cuenca del Alto Atoyac, con el fin de identificar concentraciones y priorizar zonas para su validación en campo y estudios posteriores, sin asumir que sus resultados constituyen evidencia directa de descargas ni una propuesta de infraestructura.

2.3 Objetivos específicos

1. Construir un universo auditable de unidades económicas potencialmente relevantes.
2. Caracterizar su distribución territorial y su relación espacial con la cuenca y la red hidrográfica.
3. Detectar concentraciones espaciales sin utilizar variables productivas para forzar los grupos.
4. Perfilar la composición económica de los agrupamientos una vez fijada la solución espacial.
5. Identificar zonas que ameriten validación de campo y estudios hidráulicos posteriores.
6. Documentar incertidumbres, sesgos, decisiones y productos para garantizar reproducibilidad.

3 Antecedentes ambientales y territoriales

La problemática ambiental de la Cuenca del Alto Atoyac no puede entenderse como el resultado de una única fuente de contaminación ni como un fenómeno localizado únicamente en el cauce principal del río. La configuración actual de la cuenca es producto de varias décadas de crecimiento urbano, expansión industrial, transformación del uso de suelo y desarrollo de infraestructura que han modificado simultáneamente la ocupación del territorio y la relación entre los centros de población, las unidades productivas y la red hídrica. Por esta razón, cualquier aproximación al problema requiere una lectura territorial que permita relacionar la distribución de la actividad económica con los sistemas urbanos, los cauces y las localidades donde se concentra la producción.

3.1 Transformación territorial e industrialización de la cuenca

Los antecedentes recopilados para la Cuenca del Alto Atoyac sitúan un punto importante de transformación territorial a partir de la segunda mitad del siglo XX. Pérez Castresana et al. describen el inicio del proceso de deterioro socioambiental durante la década de 1960, asociado con la construcción de la autopista México–Puebla y el establecimiento de corredores industriales. Posteriormente, durante la década de 1990, la expansión de la actividad industrial se aceleró y con ella se profundizaron las presiones ambientales sobre el territorio Pérez Castresana et al. (2023). En paralelo, la urbanización ocupó progresivamente superficies anteriormente agrícolas o con cobertura natural, generando una estructura territorial en la que zonas industriales, localidades, áreas agrícolas y cuerpos de agua se encuentran estrechamente vinculados.

Esta transformación ocurrió sobre una cuenca que actualmente concentra una parte importante de la población y de la actividad económica de Puebla y Tlaxcala. El diagnóstico de salud ambiental elaborado por la Universidad Iberoamericana Puebla señala que las principales zonas metropolitanas de ambos estados se encuentran dentro de la cuenca y que, para 2020, alrededor de 3.86 millones de habitantes residían en ella Pérez Castresana et al. (2023). El mismo trabajo identifica a Puebla, Cuautlancingo, Huejotzingo, San Pedro Cholula, San Andrés Cholula, Amozoc, San Martín Texmelucan, San Gregorio Atzompa y Coronango entre los municipios con mayor presencia industrial de la región poblana. Esta coincidencia entre concentración de población, expansión urbana y actividad industrial es relevante porque las presiones sobre el sistema hídrico no se distribuyen de manera homogénea, sino que se acumulan en corredores y localidades específicas.

La degradación de los ríos constituye una de las expresiones más visibles de este proceso. La Declaratoria de Clasificación de los ríos Atoyac y Xochiac o Hueyapan, publicada en el Diario Oficial de la Federación en 2011, reconoce que la calidad de estos cuerpos de agua ha sido modificada por descargas procedentes tanto de procesos industriales como de asentamientos humanos. La declaratoria estimó aportaciones diarias de materia orgánica, sólidos suspendidos, nutrientes, metales pesados, compuestos orgánicos tóxicos y contaminación microbiológica, y concluyó que el cumplimiento de los

límites generales de descarga existentes en ese momento no era suficiente por sí solo para alcanzar la calidad requerida en estos cuerpos de agua [Comisión Nacional del Agua \(2011\)](#).

Los antecedentes muestran, por tanto, un problema de carácter acumulativo. A las descargas industriales se suman las aguas residuales municipales, el crecimiento urbano, las actividades agrícolas y otras fuentes de presión ambiental. El reporte *Salud ambiental en la Cuenca del Alto Atoyac* señala que una proporción importante de municipios descargaba aguas residuales sin tratamiento previo y que menos del 30 % de las industrias medianas y grandes reportaban emisiones al Registro de Emisiones y Transferencia de Contaminantes (RETC) en el periodo analizado [Pérez Castresana et al. \(2023\)](#). Estas cifras deben entenderse como antecedentes correspondientes a las fuentes y fechas utilizadas por dicho estudio y no como una estimación actual generada en el presente proyecto.

3.2 Industria textil y procesos asociados con la mezclilla

Dentro de la diversidad productiva de la cuenca, la industria textil resulta especialmente relevante para el presente estudio. Los antecedentes disponibles la identifican tanto por su importancia económica como por las características de algunos de sus procesos productivos. El diagnóstico de la Universidad Iberoamericana Puebla señala que las actividades textiles se encuentran entre los giros industriales más numerosos de la cuenca y ubica al sector textil, junto con los sectores químico, metalúrgico, automotriz y de plásticos, entre aquellos de mayor relevancia para la problemática de contaminación industrial [Pérez Castresana et al. \(2023\)](#).

Sin embargo, “industria textil” comprende procesos con requerimientos y perfiles ambientales muy diferentes. Actividades como corte, costura, confección, bordado o planchado pueden realizarse principalmente como procesos secos, mientras que el descruce, blanqueo, teñido, lavado, acabado y ciertos tratamientos de la tela requieren agua y pueden incorporar detergentes, colorantes, agentes de fijación y otras sustancias químicas. La literatura resumida en *Salud ambiental en la Cuenca del Alto Atoyac* destaca precisamente el uso de sustancias para blanquear, teñir, impermeabilizar y fijar colores en la producción textil, así como la posible presencia de colorantes, metales y otros compuestos en los efluentes asociados con estos procesos [Pérez Castresana et al. \(2023\)](#). Esta diferencia entre actividades textiles es fundamental para el presente diagnóstico, ya que la pertenencia al sector textil no implica automáticamente el mismo consumo de agua ni el mismo potencial de descarga.

La producción de mezclilla introduce un antecedente todavía más específico. La Recomendación 10/2017 de la Comisión Nacional de los Derechos Humanos documentó la presencia de más de treinta maquiladoras textiles descritas como *lavanderías de mezclilla* en localidades de la zona del Alto Atoyac, principalmente San Rafael Tenanyecac, Villa Alta, San Mateo Ayecac y Santa Ana Xalmimilulco. El documento señala que, en los antecedentes analizados por la Comisión, varios de estos establecimientos descargaban sus aguas residuales directamente al río o a la red de alcantarillado sin tratamiento previo [Comisión Nacional de los Derechos Humanos \(2017\)](#). La misma recomendación documentó talleres familiares relacionados con confección y tratamiento de mezclilla y discutió de manera específica las descargas procedentes de pequeños establecimientos dedicados al proceso de teñido.

Este antecedente es central para la delimitación del problema abordado en este trabajo. La actividad relacionada con mezclilla no necesariamente ocurre en grandes instalaciones industriales claramente identificables. Parte de la cadena puede encontrarse fragmentada entre fábricas, maquilas, talleres, lavanderías y establecimientos de menor tamaño, algunos de los cuales pueden aparecer registrados bajo distintas actividades económicas. Como consecuencia, un inventario basado únicamente en grandes empresas o en registros de emisiones puede dejar fuera una parte del tejido productivo territorial que resulta relevante para comprender dónde se realizan los procesos.

La relevancia institucional del sector textil tampoco se limita a antecedentes históricos. En 2022, la Comisión Nacional del Agua y el Gobierno de Puebla establecieron un convenio de colaboración con empresas textiles para contribuir al mejoramiento de la calidad del agua del río Atoyac, reconociendo

al ramo textil como un sector que históricamente ha realizado descargas al cuerpo de agua Comisión Nacional del Agua (2022). Esto refuerza la necesidad de estudiar no solamente instalaciones individuales, sino la distribución territorial del conjunto de actividades que componen la cadena textil.

3.3 Territorios de interés dentro de la cuenca

Los antecedentes revisados tampoco distribuyen la problemática de forma homogénea sobre la cuenca. Determinados municipios y localidades aparecen reiteradamente asociados con concentración industrial, descargas, infraestructura de saneamiento insuficiente o presencia de actividades textiles.

En la región poblana, Huejotzingo y San Martín Texmelucan aparecen de manera recurrente entre los municipios de elevada presencia industrial. Esta relevancia no surge únicamente de indicadores generales de actividad económica. La Recomendación 10/2017 de la CNDH se refiere específicamente a afectaciones relacionadas con la contaminación de los ríos Atoyac, Xochiac y sus afluentes para habitantes de San Martín Texmelucan y Huejotzingo, en Puebla, así como Tepetitla de Lardizábal, Nativitas e Ixtacuixtla de Mariano Matamoros, en Tlaxcala Comisión Nacional de los Derechos Humanos (2017).

Dentro de este corredor territorial, Santa Ana Xalmimilulco adquiere especial interés para el estudio de la cadena de mezcilla. La CNDH identificó el corredor industrial de Huejotzingo al este de esta localidad y documentó la presencia de lavanderías de mezcilla en la propia Xalmimilulco y en localidades próximas. También registró antecedentes relacionados con infraestructura de tratamiento de aguas residuales en la comunidad y con las condiciones de operación de plantas existentes en el municipio. Estos elementos hacen que Xalmimilulco no constituya únicamente un punto con presencia económica textil, sino parte de un territorio donde coinciden antecedentes de actividad productiva, procesos húmedos, red de drenaje, cuerpos de agua y problemas históricos de saneamiento.

San Martín Texmelucan constituye otro punto relevante dentro de esta estructura. Además de su carácter industrial, el municipio se encuentra conectado territorialmente con corredores productivos que continúan hacia Tlaxcala y presenta antecedentes tanto de industria textil como química y petroquímica. Estudios recientes que utilizan información del RETC continúan identificando emisiones a cuerpos de agua asociadas con actividades textiles en San Martín Texmelucan, incluyendo compuestos de níquel, cromo y plomo Svarch Pérez et al. (2025). Estos registros no permiten atribuir las emisiones al conjunto del sector ni localizar todas las unidades productivas involucradas, pero muestran que la relación entre actividad textil y presión sobre el sistema hídrico continúa siendo un objeto pertinente de investigación.

En conjunto, estos antecedentes sugieren que el problema tiene una estructura territorial más amplia que la de establecimientos individuales. Las cadenas de producción pueden distribuirse entre localidades; las unidades pequeñas pueden encontrarse próximas a otras actividades complementarias; las descargas pueden incorporarse al alcantarillado antes de llegar a un cuerpo receptor; y los cauces conectan espacios productivos que administrativamente pertenecen a municipios distintos. Por ello, estudiar exclusivamente una lista de empresas previamente identificadas resulta insuficiente para reconocer la organización territorial de la actividad.

3.4 Vacío de información y posición del presente diagnóstico

Los antecedentes descritos permiten establecer que existe una problemática histórica de contaminación en el Alto Atoyac, que las descargas industriales forman parte de ella y que la industria textil, incluyendo actividades relacionadas con lavado y tratamiento de mezcilla, ha sido señalada de manera específica en documentos técnicos, institucionales y académicos. Sin embargo, estos antecedentes no resuelven una pregunta operativa necesaria para las etapas posteriores del proyecto: *¿cómo se distribuye actualmente en el territorio el universo de unidades económicas potencialmente relacionadas con esta cadena productiva y dónde se forman concentraciones que justifiquen una investigación más detallada?*

Los registros de emisiones como el RETC permiten documentar determinadas sustancias y establecimientos sujetos a reporte, pero no constituyen un censo completo de la actividad productiva. Los documentos de saneamiento y las investigaciones previas, por su parte, identifican industrias, localidades y problemas específicos, pero fueron elaborados con distintos objetivos, periodos, escalas territoriales y criterios de selección. Esto dificulta utilizarlos directamente para construir un universo espacial homogéneo de establecimientos que incluya tanto unidades grandes como pequeñas y permita analizar su distribución conjunta.

El presente trabajo se ubica en ese vacío. Su propósito no es volver a demostrar que el río Atoyac se encuentra contaminado ni atribuir contaminación a una unidad económica a partir de su giro. Parte de esos antecedentes para formular una pregunta diferente: dónde se localizan las actividades potencialmente relacionadas con la cadena textil y de mezclilla, qué tan concentradas se encuentran, qué combinaciones de actividades aparecen en un mismo territorio y qué zonas requieren ser estudiadas con mayor detalle.

Para ello se utiliza al DENUÉ como punto de partida para construir un universo territorial amplio, complementado posteriormente con información adicional y reglas de clasificación. La decisión de conservar inicialmente actividades textiles que no pueden identificarse de manera directa como procesos húmedos responde precisamente a la fragmentación de la cadena productiva: una unidad registrada como confección, maquila o fabricación no permite inferir por sí sola qué procesos ocurren dentro del establecimiento, si parte de ellos se subcontrata o cómo se manejan los residuos y aguas generados durante la producción. La clasificación económica funciona entonces como evidencia de actividad, no como evidencia de descarga.

De manera análoga, la cercanía a un río, la pertenencia a un cluster o la coincidencia con un territorio previamente señalado tampoco constituyen pruebas de contaminación. Estas variables se utilizan para organizar espacialmente la información y reconocer zonas donde la combinación de antecedentes y concentración económica hace razonable profundizar la investigación.

En este sentido, los resultados presentados en las secciones posteriores deben distinguirse de los antecedentes aquí expuestos. Los datos históricos de contaminación, las observaciones sobre lavanderías de mezclilla, los registros del RETC y los señalamientos sobre municipios prioritarios provienen de literatura y documentos anteriores. Los conteos de establecimientos, su clasificación, los clusters, las medidas de concentración y los perfiles territoriales que se presentan posteriormente corresponden al análisis desarrollado específicamente para este proyecto.

Esta separación es necesaria porque el objetivo del diagnóstico no es convertir los antecedentes ambientales en una presunción sobre cada establecimiento, sino utilizarlos para formular y ordenar una investigación territorial reproducible. El resultado esperado de esta etapa es identificar dónde conviene mirar con mayor detalle. La confirmación de procesos productivos, puntos de descarga, volúmenes, cargas contaminantes y conexiones con la infraestructura sanitaria requiere una segunda etapa de verificación en campo, aforos, muestreos y análisis hidráulico.

4 Area de estudio y unidades territoriales

4.1 Delimitación de la cuenca

Preguntas guía

- ¿De qué fuente proviene el polígono de cuenca y cuál es su fecha/escala?
- ¿Qué definición de “Alto Atoyac” se utiliza y coincide con otras instituciones?
- ¿Qué municipios intersectan la cuenca y cuáles se incorporan solo como apoyo para controlar

borde?

- ¿Como se tratan unidades economicas justo fuera del poligono pero potencialmente conectadas hidrologica o urbanamente?

Respuesta a las preguntas guía

1. **¿De que fuente proviene el poligono de cuenca y cual es su fecha y escala?** El poligono utilizado corresponde al conjunto *Cuenca del Alto Atoyac 2021*, preparado en el marco del Ecosistema Nacional Informatico de Agentes Toxicos y Procesos Contaminantes. De acuerdo con sus metadatos, el insumo original procede del Sistema Nacional de Informacion del Agua de la Comision Nacional del Agua y corresponde a la capa de disponibilidad de cuencas hidrologicas 2021. El recurso fue creado como producto geoespacial en 2023 mediante la seleccion de la cuenca con identificador 1801, denominada Rio Alto Atoyac. Los metadatos disponibles no consignan una escala cartografica nominal para este poligono; por ello no se atribuye una precision superior a la documentada por la fuente.
2. **¿Que definicion de “Alto Atoyac” se utiliza y coincide con otras instituciones?** El proyecto adopta la delimitacion hidrologica contenida en la capa de Conagua/SINA, retomada y distribuida por el ENI. Sus metadatos señalan que la organizacion espacial de la cuenca sigue la propuesta de Conagua empleada en la Declaratoria de Clasificacion de los rios Atoyac y Xochiac o Hueyapan de 2011. Esta coincidencia proporciona continuidad con una referencia institucional federal, pero no significa que todas las dependencias, estudios ambientales, organismos operadores o delimitaciones sanitarias utilicen exactamente el mismo limite. Cualquier comparacion con otra fuente debe revisar definicion, fecha, escala y proposito antes de combinar geometrías.
3. **¿Que municipios intersectan la cuenca y cuales se incorporan solo como apoyo para controlar borde?** El universo de deteccion considera 26 municipios solicitados. La matriz maestra contiene establecimientos en 24 de ellos: 19 aportan al menos un registro dentro del poligono y cinco aparecen exclusivamente como apoyo exterior en los datos observados: Chignahuapan, Ixtacamaxtitlan, Domingo Arenas, Tepatlaxco de Hidalgo y Tzicatlacoyan. Cuautinchan y San Jeronimo Tecuanipan forman parte de la lista territorial solicitada, pero no aportan registros al universo sectorial construido. Amozoc, Ocoyucan y San Pedro Cholula presentan establecimientos tanto dentro como fuera del limite; los demas municipios con registros interiores quedan representados por los puntos que intersectan la cuenca. Esta clasificacion describe la relacion de los establecimientos con el poligono, no sustituye una tabla oficial de municipios pertenecientes a la cuenca.
4. **¿Como se tratan las unidades economicas justo fuera del poligono?** Las unidades exteriores no se descartan durante la deteccion. Los 4,365 establecimientos de los municipios de referencia se utilizan para ajustar el clustering y evitar que el limite de la cuenca corte artificialmente concentraciones continuas. Una vez fijada la solucion espacial, la interpretacion principal se restringe a los 4,010 establecimientos que intersectan el poligono. La permanencia de puntos exteriores permite medir el efecto de borde y reconocer continuidades urbanas o productivas, pero no se interpreta como prueba de conectividad hidrologica. Una posible conexion mediante drenaje, canales, escurrimiento o infraestructura debe comprobarse posteriormente con informacion de redes, topografia y trabajo de campo.

4.2 Red hidrografica y contexto territorial

Fuente, cobertura y contenido

La red utilizada corresponde al conjunto *Red hidrografica de la Cuenca del Alto Atoyac y su area de influencia 2006*. El insumo de origen es la Red Hidrografica Digital de Mexico, escala 1:250,000, edicion 1.0, elaborada por el INEGI en 2006. El producto fue revisado en 2023 y distribuido por el Ecosistema Nacional Informatico en formatos GeoPackage y GeoJSON. Su cobertura no se limita al poligono estricto del Alto Atoyac: tambien incorpora su area de influencia, formada por las cuencas contiguas Bajo Atoyac, Nexapa y Rio Salado. La capa contiene 3,136 objetos lineales y se publica originalmente en coordenadas geograficas EPSG:4326.

La capa representa una mezcla de rios, corrientes y canales. El campo **orden** permite una clasificacion general: el valor cero corresponde a canales y los valores uno a siete representan ordenes de corrientes fluviales. Tambien contiene identificadores de nodo inicial y final, longitud, nombre de la corriente, codigo de rasgo y atributos de desaparicion o continuidad. Los metadatos advierten que los objetos con **g_id** 867 y 3136 corresponden a canales subterranos digitalizados mediante fotointerpretacion y conocimiento local, por lo que no proceden directamente de la red hidrografica original del INEGI.

Uso dentro del proyecto

En la primera fase, la red se recorta al contexto de la cuenca y se utiliza para representar la relacion espacial entre establecimientos y elementos hidrograficos, asi como para calcular la distancia geometrica minima de cada punto a la linea mas cercana. Para ese calculo la informacion se transforma a un sistema metrico. La distancia resultante es una medida de proximidad cartografica: no incorpora direccion del flujo, conectividad de alcantarillado, parteaguas locales, barreras, elevacion, capacidad de conduccion ni ruta real de una descarga.

Limitaciones de interpretacion

La escala 1:250,000 es adecuada para contexto regional, pero no para inventariar con detalle drenajes menores, conexiones privadas, colectores, atarjeas o descargas puntuales. La antigüedad del insumo base y la frecuencia de actualizacion no programada tambien obligan a verificar cambios, rectificaciones y obras posteriores. Aunque existen campos de nodos y orden, este proyecto no realizo una validacion topologica integral ni una modelacion de conectividad hidraulica. Tampoco se dispone en esta capa de una clasificacion completa y validada de permanencia para distinguir sistematicamente corrientes perennes e intermitentes. Por estas razones, la red sirve para contextualizacion y priorizacion preliminar, no para diseñar trazos ni atribuir descargas a un cauce.

4.3 Sistemas de referencia

Informacion y evidencia minima requerida

Registrar CRS geografico de publicacion y CRS metrico de analisis. El pipeline actual identifica EPSG:4326 y EPSG:32614. Verificar que todas las distancias y algoritmos de densidad se ejecuten en coordenadas metricas.

CRS de publicacion e intercambio

Las capas fuente de cuenca, municipios y red hidrografica, asi como las coordenadas de los establecimientos DENU, se armonizan en **EPSG:4326 (WGS 84)**. Este sistema expresa longitud y latitud en grados y se utiliza para intercambio, almacenamiento de productos de publicacion y visualizacion

en mapas web. No se emplea para calcular distancias, densidades o vecindades, porque una diferencia angular no representa una distancia constante sobre el territorio.

CRS metrico de analisis

Para las operaciones espaciales cuantitativas se utiliza **EPSG:32614 (WGS 84 / UTM zona 14N)**, cuyas unidades son metros y cuya zona cubre el area de estudio. Los 4,365 puntos de la matriz maestra fueron transformados a este CRS antes del diagnostico de vecinos, KDE, mallas hexagonales, perturbaciones posicionales y ejecucion de DBSCAN, HDBSCAN y OPTICS. El archivo de control de geometrías registra coordenadas finitas para todos los puntos y limites UTM entre 543,299.88 y 624,121.21 metros al Este, y entre 2,082,873.65 y 2,197,531.96 metros al Norte.

Verificacion y regla de uso

La separacion entre ambos sistemas esta implementada en la configuracion comun del pipeline: EPSG:4326 se declara como CRS geografico y EPSG:32614 como CRS metrico. Las capas analiticas se materializan en ambos sistemas y los scripts de diagnostico y clustering leen expresamente la geometria UTM. La auditoria final confirma que los pasos 204 y 205 utilizan exclusivamente coordenadas **x/y** en EPSG:32614; por tanto, parametros como radios, distancias de vecinos, **eps** y perturbaciones de 25 m se interpretan en metros. Como regla de reproducibilidad, cualquier analisis adicional de distancia o densidad debe transformar primero sus insumos a EPSG:32614 y registrar el CRS en la salida.

5 Fuentes de datos y gobierno de informacion

5.1 Inventario maestro de fuentes

El inventario maestro identifica los insumos que sostienen cada etapa del analisis y separa las fuentes institucionales de los materiales complementarios y derivados historicos. Su funcion no es solamente enumerar archivos, sino registrar para cada uno su procedencia, temporalidad, cobertura, uso analitico y principal limite de interpretacion. Esta distincion permite reconstruir la cadena que va desde los registros económicos y las geometrías territoriales hasta la matriz maestra, y evita tratar como equivalentes fuentes que fueron producidas con objetivos, escalas y niveles de verificacion diferentes.

Fuente	Archivo/ID	Fecha	Cobertura	Uso y limitacion principal
DENUE estatal, INEGI	INEGI_DENUE_11092026.*	Archivo/descarga: 11-09-2026	Puebla; SCIAN 313, 314, 315 y 812210	Base de 15,956 unidades economicas. Aporta ID, actividad declarada, ubicacion, personal y coordenadas; no demuestra operacion actual, procesos reales ni descargas.
DENUE local, INEGI	INEGI_DENUE_04092026.*	Archivo/descarga: 04-09-2026	Huejotzingo y Santa Ana Xalmimilulco	Fuente del trabajo local inicial, auditables y comparaciones. Sus fechas identifican el corte del archivo, no la fecha de verificacion de cada establecimiento.
Cuenca, SINA–Conagua / ENI	caaresa_cuenca_alto_atoyac_21_reg_a.gpkg	Insumo 2021; producto 2023	Cuenca Rio Alto Atoyac, ID 1801	Delimitacion para interseccion y contexto. EPSG:4326; libre uso MX. No equivale a una cuenca sanitaria ni define conexiones de drenaje.
Municipios, INEGI / ENI	caaresa_division_municipal_20_mun_a.gpkg	Insumo 2020; producto 09-2023	Alto Atoyac y contexto regional	Limites del Marco Geoestadistico 2020 para agregacion y cartografia. EPSG:4326; libre uso MX. Los limites administrativos no representan areas de aportacion hidraulica.
Red hidrografica, INEGI / ENI	caaresa_red_hidro_digital_06_reg_1.gpkg	Insumo 2006; revision 09-2023	Alto Atoyac y area de influencia	Red 1:250,000 de 3,136 lineas, rios y canales. EPSG:4326; libre uso MX. Se usa para proximidad regional; no prueba conectividad ni incluye toda la infraestructura sanitaria.
MH, investigacion de campo	data/processed/mh/	Fecha formal no documentada	Huejotzingo y Xalmimilulco	Fuente independiente producida por Mary Helen Figueroa y Mayra Jaqueline Ramirez mediante investigacion de campo. Sus hallazgos se enlazaron, cuando fue posible, con IDs unicos DENUE; fecha, protocolo detallado y condiciones de uso deben incorporarse a su ficha de fuente.
Universos legacy	data/processed/legacy/	Historico; fecha no documentada	Cobertura variable	Universos preliminares y cola de revision usados solo para comparacion y trazabilidad. No se consideran autoridad vigente ni se mezclan sin registrar diferencias de reglas y cobertura.

Preguntas guía

- ¿Quien produjo cada fuente, con que metodo y con que licencia?
- ¿Que fecha representa: descarga, levantamiento o vigencia?
- ¿Que campos se usan y cuales se descartan?
- ¿Que errores posicionales o de geocodificacion son esperables?
- ¿Como se identifican duplicados, establecimientos cerrados o cambios de giro?
- ¿Que fuente es “autoridad” cuando dos registros se contradicen?

Respuesta a las preguntas guía

1. **¿Quien produjo cada fuente, con que metodo y con que licencia?** El DENUe es producido por el INEGI como directorio estadístico de establecimientos y se obtuvo en formatos tabular y vectorial; su uso en este proyecto se limita a los atributos publicados y a la localización registrada. El polígono de cuenca proviene del SINA de Conagua y fue seleccionado y redistribuido por el ENI; la división municipal procede del Marco Geoestadístico del INEGI; y la red hidrográfica procede de la Red Hidrográfica Digital de México del INEGI y fue recortada por el ENI al Alto Atoyac y su área de influencia. Los metadatos de las tres capas territoriales declaran licencia de libre uso MX. MH constituye una fuente distinta de DENUe: proviene de la investigación de campo realizada por las compañeras del proyecto Mary Helen Figueroa y Mayra Jaqueline Ramirez. Al entregar sus resultados, ellas asociaron sus hallazgos, en la medida de lo posible, con los identificadores únicos de los establecimientos en DENUe. Ese enlace facilita la integración y evita duplicados, pero no convierte MH en un derivado de DENUe: conserva procedencia, método y valor evidencial propios. El repositorio debe completar para esta fuente su fecha, protocolo detallado y condiciones de uso. Los archivos legacy son derivados históricos internos y se usan solamente para comparación.
2. **¿Que fecha representa cada registro de la tabla?** En los archivos DENUe, las fechas 04-09-2026 y 11-09-2026 se interpretan como fecha o corte identificado en el nombre de la descarga, no como visita individual ni garantía de vigencia de cada unidad. Para la cuenca, 2021 corresponde al insumo de disponibilidad hidrológica y 2023 a la creación del producto distribuido. En municipios, 2020 corresponde al Marco Geoestadístico y septiembre de 2023 al producto preparado. En la red, 2006 es la fecha del insumo cartográfico y septiembre de 2023 la revisión. MH y legacy no cuentan con fecha documental suficiente y quedan señalados expresamente como pendientes de procedencia, no como fechas inferidas.
3. **¿Que campos se usan y cuales se descartan?** Del DENUe se utilizan principalmente el identificador `d_llave`, CLEE, nombre del establecimiento, razón social, código y descripción SCIAN, entidad, municipio, localidad, estrato de personal, latitud y longitud. A partir de nombre, razón social y descripción se construyen señales textuales; el código SCIAN alimenta la clasificación sectorial, y las coordenadas generan la geometría. Los demás campos de domicilio y contacto se conservan en tablas auditables cuando están disponibles, pero no intervienen en el clustering. De la cuenca se usa la geometría y su identificación; de municipios, geometría, claves y nombres; de la red, geometría y atributos como nombre, orden, nodos y tipo de rasgo para contexto. Los valores auxiliares sin función analítica no se usan para definir grupos. Ninguna variable productiva, textual, hídrica o de personal entra en el clustering espacial.
4. **¿Que errores posicionales o de geocodificación son esperables?** Las coordenadas DENUe representan la ubicación publicada del establecimiento, pero pueden corresponder al acceso, centroide

del predio, domicilio administrativo o una posición geocodificada con precisión variable. También pueden existir desplazamientos por actualización incompleta, errores de captura o cambios de domicilio. En las capas territoriales, la escala, generalización y fecha de cada insumo introducen diferencias de borde; la red 1:250,000 no representa todos los cauces menores ni redes sanitarias. Por ello, una intersección cercana al límite o una distancia corta a una línea debe interpretarse con tolerancia y verificarse en campo, no como coincidencia física exacta.

5. **¿Como se identifican duplicados, establecimientos cerrados o cambios de giro?** Los scripts verifican que `d_llave` no este duplicado en cada descarga DENUe y detienen la ejecución si encuentran duplicados. La integración se realiza por identificador y, para MH, mediante una auditoría que distingue coincidencias, revisiones y registros agregados, conservando la fuente. Sin embargo, el proyecto no cuenta con una serie temporal DENUe ni con una verificación censal que permita identificar de manera concluyente cierres, reaperturas o cambios de giro. Esos estados deben confirmarse mediante una descarga posterior, consulta individual y validación en campo; la ausencia de un registro en una comparación no se clasifica automáticamente como cierre.
6. **¿Que fuente es autoridad cuando dos registros se contradicen?** No se aplica una autoridad única para todos los atributos. El DENUe se toma como referencia primaria para identificadores y actividad económica oficialmente publicada; la capa de Conagua/SINA para la delimitación hidrológica adoptada; el Marco Geoestadístico del INEGI para límites administrativos; y la Red Hidrográfica Digital del INEGI para el contexto fluvial regional. MH puede complementar o cuestionar un registro, pero no lo sustituye silenciosamente: la discrepancia debe conservarse con procedencia, fecha y nota de auditoría. Para estado operativo, proceso productivo, consumo de agua o descarga, ninguna de estas fuentes es concluyente; prevalece la evidencia primaria obtenida mediante verificación documentada y trabajo de campo.

Requisitos de trazabilidad

Para cada fuente conservar: ruta relativa, nombre original, URL o mecanismo de obtención, fecha, tamaño, hash, CRS, número de registros, campos clave, responsable de descarga y notas de transformación.

6 Construcción del universo económico

6.1 Universo de partida

La descarga estatal acotada a los SCIAN 313, 314, 315 y 812210 constituye el punto de partida porque reúne, bajo un criterio reproducible, la fabricación de insumos y productos textiles, la confección de prendas y los servicios de lavandería y tintorería que pueden estar relacionados con la cadena productiva estudiada. Este recorte permite construir un universo amplio antes de aplicar señales textuales o criterios de evidencia hídrica y evita seleccionar establecimientos a partir de una presunción previa de descarga. Su cobertura, sin embargo, depende de la clasificación declarada en DENUe: pueden quedar fuera establecimientos registrados bajo otros códigos, actividades informales, unidades sin registro vigente, procesos auxiliares realizados por terceros y comercios o servicios que oculten en su nombre o clase una operación productiva relevante. Por ello, el universo debe entenderse como una base sectorial auditable y no como un censo exhaustivo de generadores de aguas residuales.

6.2 Filtro SCIAN

Preguntas guía

- ¿Que codigos completos y prefijos se incluyen?
- ¿Que logica sustantiva justifica cada codigo?
- ¿Que codigos son de manufactura, servicios, acabado, lavado o comercio?
- ¿Que codigos generan mayor riesgo de falsos positivos?
- ¿Como se documentan cambios de SCIAN entre versiones?

El filtro SCIAN incluye por prefijo las familias 313, 314 y 315, además del codigo completo 812210. El prefijo 313 incorpora la fabricacion de insumos textiles y el acabado de productos textiles; dentro de este grupo, el codigo 313310 se identifica de manera especifica como señal de acabado humedo. El prefijo 314 comprende la fabricacion de productos textiles distintos de prendas, mientras que 315 reúne la fabricacion de prendas y actividades de confeccion. El codigo 812210 incorpora lavanderias y tintorerias como servicios potencialmente relacionados con lavado o tratamiento de prendas. Esta seleccion responde a una logica de cobertura de la cadena textil: manufactura de insumos, fabricacion de productos, confeccion y servicios de lavado. El filtro se implementa con coincidencia por prefijo para 313, 314 y 315, y con coincidencia exacta para 812210 al construir las señales analiticas; el comercio de prendas no forma parte del filtro SCIAN sectorial. Los codigos 313–315 se interpretan como actividad manufacturera, 313310 como señal particularmente vinculada con acabado, y 812210 como servicio. Ninguno de ellos demuestra por si solo uso de agua o descarga.

El mayor riesgo de falsos positivos se concentra en 812210, porque incluye lavanderias y tintorerias de distinta escala y finalidad, incluidas actividades de servicio que no necesariamente realizan procesos textiles industriales; por esa razon el proyecto conserva una modalidad amplia y otra estricta que exige señales textuales o productivas adicionales. Tambien pueden producirse inclusiones demasiado amplias en 314 y 315 cuando la actividad corresponde a productos textiles o confeccion mediante procesos principalmente secos, así como falsos negativos cuando un establecimiento con proceso humedo aparece registrado bajo una clase general o una descripcion poco informativa. La version actual normaliza el codigo como texto, elimina terminaciones decimales espurias y registra por establecimiento las banderas `scian_textil`, `scian_acabado_humedo` y `scian_lavanderia`, lo que permite auditar el motivo de inclusion. El repositorio no contiene todavía una tabla de correspondencia entre versiones del SCIAN; por ello, cualquier actualización deberá congelar la version empleada, comparar altas, bajas y reclasificaciones mediante una tabla oficial de equivalencias y conservar tanto el codigo original como el armonizado, sin reemplazar silenciosamente la clasificación usada en esta corrida.

6.3 Filtro textual y diccionarios

El filtro textual se ejecuta sobre una cadena formada por `nom_est` y `raz_soc`. Aunque `desc_scian` se valida como columna requerida, la implementacion actual no incorpora su contenido a `texto_filtro`; las lineas correspondientes se encuentran desactivadas en el script. Cada valor se convierte a minusculas, se eliminan espacios exteriores y diacriticos mediante normalizacion Unicode NFKD, y las secuencias de espacios se reducen a uno. Los terminos del catalogo tambien se normalizan, se eliminan duplicados y se ordenan de mayor a menor longitud antes de construir expresiones regulares. Las frases permiten uno o mas espacios entre palabras y se rodean de limites negativos alfanumericos para evitar coincidencias dentro de otras palabras.

El archivo `data/processed/catalogs/giro_textil.csv` contiene pares `palabra-senal`. Las señales positivas se organizan en `textil`, `mezclilla`, `humedo_explicito`, `lavado_generico`, `produccion`

y **maquila**; adicionalmente se conserva **proceso_seco_explicito** para distinguir expresiones como costura, corte, confeccion, bordado, deshebrado y planchado. La categoria **no_textil_explicito** contiene expresiones de actividades ajenas, como autolavado, agua potable, alimentos, herreria, muebles y comercio simple, y tiene prioridad negativa dentro del filtro textual. Una expresion ambigua no produce por si sola evidencia hidrica: señales generales como lavado, tratamiento, pantalon o mezclilla se interpretan en combinacion con el contexto textil y productivo.

El filtro devuelve solamente registros con al menos una señal positiva y sin evidencia no textil explicita. Para cada candidato conserva el texto normalizado y columnas booleanas que permiten reconstruir las coincidencias. El catalogo actual es el archivo operativo efectivamente utilizado, pero no incluye campos de version, fecha de alta, justificacion o ambigüedad por termino. En consecuencia, debe preservarse junto con cada corrida y complementarse en el anexo con una version fechada; cualquier modificacion futura debe registrar terminos añadidos, eliminados o reclasificados y volver a ejecutar la comparacion de universos.

Informacion y evidencia minima requerida

Adjuntar como anexo los diccionarios completos, no solo ejemplos. Cada termino deberia tener: categoria, significado, razon de inclusion, posible ambigüedad y version de alta/modificacion.

6.4 Separacion entre sector textil y evidencia de proceso humedo

Limite de interpretacion

El universo sectorial debe distinguirse de la evidencia de proceso humedo. Una empresa puede pertenecer al sector textil y no mostrar en DENUE evidencia explicita de lavado/teñido/acabado; a la inversa, la ausencia de palabras clave no demuestra ausencia de uso de agua.

La separacion se implementa mediante dos variables de decision distintas. **sector_textil** determina si el establecimiento pertenece al universo economico y toma los valores **INCLUIR** o **REVISAR**; se apoya en los prefijos **SCIAN** textiles, en la combinacion de contexto productivo con señales textiles o de mezclilla, y en evidencia de acabado humedo. Por su parte, **evidencia_hidrica** clasifica la fuerza de la señal relacionada con procesos potencialmente humedos como **SI**, **REVISAR** o **SIN_EVIDENCIA**. De esta forma, un taller de confeccion puede pertenecer legitimamente al universo sectorial y, al mismo tiempo, quedar sin evidencia hidrica.

La categoria **SI** se asigna al codigo 313310 o a una expresion de proceso humedo acompañada por contexto textil; **REVISAR** se asigna a lavanderias admisibles, lavado generico con contexto textil o mezclilla acompañada por lavado, proceso humedo, produccion o maquila. Las demas unidades sectoriales permanecen como **SIN_EVIDENCIA**. Cuando coexisten señales secas y humedas, la evidencia humeda tiene prioridad, pero esto sigue siendo una clasificacion documental y no una confirmacion fisica. Los productos finales conservan el universo textil completo y generan por separado los subconjuntos **SI** y **SI+REVISAR**, lo que evita confundir pertenencia sectorial con evidencia de uso de agua.

6.5 Reglas de inclusion/exclusion

Preguntas guia

- ¿Como se excluye comercio simple de prendas?
- ¿Como se tratan “maquila”, “pantalon”, “mezclilla”, “planchado”, “deshebrado”, “rec-

ta/presilla/formador”, “fabrica de tela” y lavanderias?

- ¿Que condiciones producen Alta, Media, Revisar o No incluir?
- ¿Que reglas son automaticas y cuales requieren revision humana?
- ¿Como se registra el motivo exacto de cada decision?

Respuesta a las preguntas guía

1. **¿Como se excluye el comercio simple de prendas?** El recorte SCIAN no incorpora codigos comerciales, sino manufactura textil, confeccion y el servicio 812210. En el filtro textual, expresiones como *comercio al por menor de ropa*, *comercio al por menor de telas* y *comercio al por menor de articulos usados* se etiquetan como `no_textil_explicito` y anulan la candidatura obtenida solamente por texto. Esta exclusion depende de que la actividad comercial aparezca en los campos analizados; por ello los casos ambiguos deben conservarse para revision y no asumirse automaticamente como produccion.
2. **¿Como se tratan las expresiones productivas ambiguas?** *Maquila* se registra como contexto productivo y, cuando aparece con textil o mezcilla, favorece la inclusion sectorial. *Pantalon* aporta señal textil, pero no demuestra por si solo produccion ni proceso humedo. *Mezcilla* sola tampoco demuestra lavado: solo pasa a evidencia `REVISAR` cuando coexiste con lavado, proceso humedo, produccion o maquila. *Planchado* se clasifica como proceso seco explicito. *Deshebrado* aporta señales de mezcilla, produccion y textil, ademas de proceso seco, por lo que puede apoyar la inclusion sectorial sin convertirse automaticamente en evidencia confirmada de humedad. Las palabras *recta*, *presilla* y *formador* no figuran en el catalogo operativo actual y no generan una señal automatica. *Fabrica de tela* puede activar por separado *fabrica* como produccion y *tela* como textil. Las lavanderias 812210 se admiten directamente en la modalidad amplia; en la estricta requieren ademas una señal textil, de mezcilla, humedad, produccion o maquila.
3. **¿Que condiciones producen Alta, Media, Revisar o No incluir?** La implementacion vigente no genera categorias denominadas `Alta`, `Media` o `No incluir`; utilizar esos nombres implicaria describir una regla que no existe en el codigo. Las salidas reales son `sector_textil=INCLUIR/REVISAR` y `evidencia_hidrica=SI/REVISAR/SIN_EVIDENCIA`. `INCLUIR` se obtiene por SCIAN textil, por contexto productivo combinado con textil o mezcilla, o por evidencia humeda; los demas candidatos quedan en revision sectorial. `SI` corresponde a evidencia humeda explicita, `REVISAR` a señales compatibles pero ambiguas y `SIN_EVIDENCIA` a pertenencia sectorial sin señal humeda observable. Los registros que no coinciden ni con el filtro SCIAN ni con el textual no entran al auditable candidato. Si se desean niveles `Alta` y `Media`, deberan definirse formalmente y programarse como una version nueva, sin reinterpretar retroactivamente estas salidas.
4. **¿Que reglas son automaticas y cuales requieren revision humana?** La normalizacion, coincidencia por SCIAN, busqueda de patrones, combinacion de señales y asignacion de las dos variables de decision son automaticas y reproducibles. La revision humana se requiere para los casos clasificados como `REVISAR`, contradicciones entre fuentes, establecimientos MH, ambigüedades no cubiertas por el diccionario y cualquier inferencia sobre operacion real, escala, proceso, consumo o descarga. La regla automatica prioriza consistencia; la auditoria humana aporta evidencia externa y no debe sobrescribir el resultado sin registrar fuente, fecha y justificacion.
5. **¿Como se registra el motivo exacto de cada decision?** Cada fila auditable conserva `coincide_filtro_scian`, `coincide_filtro_texto`, las señales textuales booleanas, las banderas `scian_textil`, `scian_acabado_humedo` y `scian_lavanderia`, y las decisiones finales `sector_textil`

y `evidencia_hidrica`. Esta combinacion permite reconstruir la regla aplicada, aunque actualmente no existe una columna unica con una frase de motivo. Las integraciones MH añaden procedencia y una tabla de auditoria de acciones. Para una auditoria manual completa conviene agregar en la siguiente version un identificador de regla, evidencia consultada, URL, fecha, revisor y nota factual por establecimiento.

7 Auditoria manual y evidencia externa

Esta etapa corresponde al inicio preliminar y localizado del proyecto, cuando el area de estudio se concentro en Huejotzingo y, con mayor profundidad, en Santa Ana Xalmimilulco. La seleccion no fue arbitraria: de esta zona provenian las muestras de agua previstas para etapas posteriores del proyecto y, por ello, era necesario comprender con mayor detalle el tejido economico que podia guardar relacion con actividades textiles, productivas y potencialmente hidricas. El proposito era reunir y contrastar todas las señales disponibles para determinar con la mayor certeza documental posible si cada establecimiento pertenecia o no a un universo textil-productivo-hidrico. Esta pertenencia se entendia como una clasificacion para orientar la investigacion, no como prueba de que una unidad generara o descargara contaminantes.

El trabajo local produjo tablas auditables con 100 registros para Huejotzingo y 359 para Santa Ana Xalmimilulco, ademas de universos hidricos preliminares y comparaciones con MH. En Xalmimilulco se obtuvieron 359 registros sectoriales, 68 con evidencia SI o REVISAR y seis con evidencia SI; en Huejotzingo se registraron 100 unidades sectoriales, 37 con evidencia SI o REVISAR y ninguna con evidencia SI bajo las reglas actuales. En la version 1, el desarrollo llego hasta la implementacion de las tablas auditables y se realizo manualmente la auditoria de Xalmimilulco. El archivo legacy `universo_hidrico_preliminar.csv` conserva 55 registros seleccionados: 33 atribuidos a rutas de auditoria manual y 22 a reglas automaticas de maquila, produccion de mezcilla o proceso humedo confirmado. La posterior `cola_revision_manual_314.csv`, cuyos 314 registros aparecen como PENDIENTE, corresponde a una ampliacion o reorganizacion posterior de casos por revisar y no debe utilizarse para negar la auditoria manual efectivamente realizada en la version 1.

7.1 Protocolo de revision

Preguntas guia

- ¿Que registros entran a auditoria manual y por que?
- ¿Que fuentes externas se permiten: Google Maps, Street View, sitio web, Facebook, directorios, anuncios de empleo, imagen satelital?
- ¿Que jerarquia de evidencia se aplica?
- ¿Como se documenta un establecimiento no encontrado, clausurado, con coordenadas dudosas o sin Street View?
- ¿Que fecha tiene la observacion y cuanto puede degradarse con el tiempo?

Respuesta a las preguntas guia

1. **¿Que registros entran a auditoria manual y por que?** En la version 1 entraron a auditoria manual los registros de Xalmimilulco cuya pertenencia al universo textil-productivo-hidrico no podia resolverse suficientemente mediante el codigo SCIAN y las señales textuales, en particular maquilas con descripciones generales, actividades de mezcilla sin evidencia clara de lavado, posibles

procesos secos, contradicciones entre DENUÉ y MH y unidades cercanas al contexto territorial de las muestras de agua. La revisión manual no buscaba atribuir contaminación, sino decidir si existía evidencia suficiente para retener o descartar la pertenencia al universo de investigación. La cola posterior de 314 casos conserva una agenda ampliada de revisión, pero es distinta del conjunto efectivamente auditado para construir el universo preliminar de la versión 1.

2. **¿Que fuentes externas se permiten?** La estructura legacy contempla consultas a Google Maps por dirección y coordenadas, OpenStreetMap y el registro de las fuentes efectivamente consultadas. Como evidencia complementaria pueden emplearse Street View, sitio web oficial, perfiles empresariales o de redes sociales, directorios, anuncios de empleo, notas institucionales e imagen satelital, siempre que se guarden URL, fecha y una descripción factual de lo observado. Estas fuentes sirven para verificar existencia, nombre, giro aparente, escala o indicios de actividad; no sustituyen una visita de campo ni demuestran procesos internos, consumo de agua o descarga.
3. **¿Que jerarquía de evidencia se aplica?** La mayor fuerza corresponde a evidencia primaria y fechada: visita de campo, entrevista documentada, observación directa autorizada, permisos, registros oficiales o documentos del propio establecimiento que describan el proceso. En un segundo nivel se ubican sitios empresariales, comunicaciones institucionales y materiales donde la unidad declara su actividad. En un tercer nivel se consideran fachadas y señalamientos visibles en cartografía de calle, directorios, redes sociales y anuncios de empleo; finalmente, la imagen satelital y la proximidad espacial funcionan solo como contexto. La coincidencia de varias fuentes independientes aumenta la confianza, mientras que una señal aislada o ambigua conserva el caso en revisión. La ausencia de evidencia en internet nunca se interpreta como evidencia de ausencia.
4. **¿Como se documenta un establecimiento no encontrado, clausurado, con coordenadas dudosas o sin Street View?** El registro debe conservarse y marcarse con un estado descriptivo, no eliminarse ni reclasificarse automáticamente. La tabla legacy ya dispone de campos para estado de revisión, establecimiento encontrado, nombre y giro observado, evidencia de proceso humedo o mezclilla, decisión, confianza, fuentes, fecha, revisor y notas. Un caso no encontrado debe indicar consultas realizadas y resultado; una posible clausura requiere fuente y fecha; una coordenada dudosa debe conservar tanto el punto original como la ubicación alternativa y su justificación; y la falta de Street View se registra como limitación de la fuente. Si no existe evidencia suficiente, la decisión correcta es NO DETERMINADO o REVISAR, no una exclusión definitiva.
5. **¿Que fecha tiene la observación y cuanto puede degradarse con el tiempo?** La fecha relevante es la de consulta o levantamiento de cada evidencia y debe distinguirse de la fecha de incorporación al DENUÉ, de la captura de la imagen y del corte del archivo. La información web, los directorios, la rotulación y Street View pueden quedar obsoletos cuando un negocio cambia de nombre, giro, domicilio, escala o estado operativo; incluso una observación de campo representa solamente el momento en que fue realizada. Por ello, cada conclusión debe asociarse con su fecha y nivel de confianza, y los casos prioritarios deben revalidarse antes de relacionarlos con muestras, campañas de monitoreo o decisiones posteriores.

Alcance alcanzado y transición al análisis regional

La intención de esta fase era llegar, mediante la acumulación de señales SCIAN, textuales, territoriales, MH y evidencia externa, a un dictamen defendible de pertenencia al universo textil-productivo-hídrico para Huejotzingo y Xalmimilulco. En la versión 1 ese objetivo se concretó para Xalmimilulco mediante la implementación de tablas auditables y una revisión manual realizada por el responsable de este análisis. El resultado se conserva en `universo_hidrico_preliminar.csv`, donde las rutas de inclusión distinguen decisiones apoyadas por auditoría manual de inclusiones obtenidas automáticamente.

`universo_combinado_tentativo_mh.csv` registra después la comparación e integración tentativa con los hallazgos de campo de Mary Helen Figueroa y Mayra Jaqueline Ramirez. La existencia de una cola posterior de 314 casos pendientes muestra que el universo de revisión se amplió, no que la auditoría de versión 1 no se hubiera realizado.

Posteriormente, el proyecto cambió de escala y se concentró en todos los municipios poblanos seleccionados en relación con la cuenca. Ese desplazamiento no invalida el trabajo local: Huejotzingo y Xalmimilulco funcionaron como laboratorio para construir las reglas, reconocer ambigüedades, realizar la primera auditoría manual y separar pertenencia textil de evidencia hídrica. No obstante, el análisis regional posterior utiliza un universo sectorial ampliado y procedimientos homogéneos de clasificación y clustering, por lo que conserva las decisiones de versión 1 como antecedente y trazabilidad, no como regla manual extrapolada automáticamente a todos los municipios. La fase local aporta la experiencia metodológica y el enlace con las futuras muestras de agua; la fase regional pasa a ser el marco principal para estudiar la distribución y concentración espacial en la cuenca poblana.

Información y evidencia mínima requerida

Cada revisión manual debe conservar, cuando sea posible: ID DENUÉ, nombre, coordenadas, fecha de consulta, URL, tipo de evidencia, captura/archivo, observación normalizada, decisión, nivel de confianza, revisor y segunda revisión si existe conflicto.

Requisitos de trazabilidad

La auditoría humana debe ser reproducible en el sentido documental aunque una página web cambie. Conviene guardar evidencias permitidas, fecha de consulta y una nota factual separada de la interpretación.

8 Alcance inicial y transición al análisis regional


Esta sección documenta, en cambio, el cambio de escala entre la versión 1, intensiva y localizada, y la Parte 1 regional, automatizada para los municipios poblanos seleccionados en relación con la cuenca. Los universos legacy se conservan precisamente para reconstruir esa transición y no deben mezclarse silenciosamente con las salidas regionales, porque responden a coberturas, reglas y grados de intervención manual diferentes.

8.1 Versión 1: Huejotzingo y Santa Ana Xalmimilulco

La versión 1 se desarrolló con un alcance territorial preliminar en Huejotzingo y Santa Ana Xalmimilulco. En estas localidades se buscaba comprender a profundidad el universo económico asociado con el contexto de las muestras de agua que se utilizarían posteriormente. El procedimiento combinaba el recorte local de DENUÉ, reglas SCIAN y textuales, revisión manual de Xalmimilulco y contraste con la investigación de campo de Mary Helen Figueroa y Mayra Jaqueline Ramirez. MH se trató como fuente independiente: cuando sus hallazgos contaban con una correspondencia razonable se vincularon mediante ID DENUÉ; cuando no existía equivalencia directa se conservaron con su propia procedencia para evitar perder evidencia de campo.

Esta fase tenía una meta de clasificación intensiva: decidir, después de acumular señales, si cada caso podía pertenecer al universo textil-productivo-hídrico. El resultado no era una afirmación de descarga, sino una selección razonada para relacionar posteriormente la actividad territorial con las muestras y orientar nuevas verificaciones. La versión 1 culminó en tablas auditables locales y en un universo legacy construido manualmente para Xalmimilulco, con apoyo del contraste de campo. Este universo manual

es distinto del universo hidrico preliminar automatizado: el segundo resulta de aplicar en la localidad el filtro estricto que posteriormente se utilizaria, de manera homogenea, en el nivel regional. Los archivos legacy conservan la primera historia de decision y permiten compararla con la aplicacion posterior de las reglas automaticas.



8.2 Transicion metodologica

La experiencia local permitio reconocer tres problemas que debian resolverse antes de ampliar la escala: las palabras asociadas con actividad textil no equivalen necesariamente a procesos humedos; las fuentes de campo y DENUÉ pueden coincidir, complementarse o contradecirse; y una auditoria manual exhaustiva no puede trasladarse sin cambios a miles de establecimientos. Por ello se conservaron las lecciones de la version 1, pero se reemplazo la dependencia de decisiones caso por caso por reglas explicitas, columnas auditables y modalidades comparables. El cambio regional no consistio solamente en agregar municipios: implicó pasar de una investigacion local de alta profundidad a una clasificacion automatica y homogenea, capaz de reproducirse sobre toda la base seleccionada.

La Figura 1 muestra precisamente ese cambio de metodo. El conjunto denominado *legacy observado* corresponde al universo manual construido durante la version 1; no debe confundirse con una ejecucion temprana del filtro regional. El conjunto *actual* corresponde al universo hidrico preliminar obtenido al aplicar el filtro estricto sobre Santa Ana Xalmimilulco como localidad. Esta aplicacion local funciono como prueba del criterio que despues se automatizo y extendio al conjunto de municipios del analisis regional.

La coincidencia parcial confirma que ambos productos responden a logicas distintas. El universo manual incorporo juicio de auditoria y evidencia disponible caso por caso; el universo hidrico preliminar aplico reglas reproducibles sobre la base de la localidad. Por ello, los 24 registros exclusivos del legacy y los 42 exclusivos del filtro deben revisarse como diferencias de clasificacion y cobertura. Esta comparacion sirvio para reconocer que se perdia o incorporaba al automatizar el procedimiento antes de trasladarlo a la escala regional.

La integracion MH se mantuvo como una modalidad separada para medir su efecto sin confundirla con la fuente DENUÉ. En la modalidad amplia, la fuente de campo agrego 38 registros a un universo




Figura 1: Comparación entre el universo legacy manual de la versión 1 y el universo hídrico preliminar generado mediante el filtro estricto en Santa Ana Xalmimilulco. El archivo legacy disponible contiene 55 registros, frente a 73 del universo automatizado: 31 identificadores aparecen en ambos, 24 solo en el legacy y 42 solo en el resultado del filtro. La diferencia expresa un cambio de procedimiento y no altas o bajas de establecimientos.


municipal final de 1,756; en la modalidad estricta agrego 41 a un total de 517. Estas diferencias no deben interpretarse automáticamente como altas o bajas temporales: pueden provenir de cobertura de campo, ausencia de correspondencia DENUÉ, cambios de criterio, reglas distintas o diferencias de fecha. Por esa razón existen resultados con y sin MH y se conserva una auditoría específica de la integración.

8.3 Parte 1 regional: flujo automático para los municipios de la cuenca

El flujo regional parte de la descarga estatal de 15,956 registros acotada a los SCIAN seleccionados. Las mismas funciones normalizan campos, verifican IDs, aplican filtros y generan señales para todos los establecimientos, sin utilizar decisiones manuales locales como regla general. Después se seleccionan los 26 municipios de referencia, se materializa un universo sectorial de 4,365 establecimientos y se intersecta con el polígono de la cuenca, donde permanecen 4,010. La automatización produce tablas, capas, distancias, mapas y resúmenes bajo cinco modalidades que conservan por separado el efecto de la regla amplia o estricta, la inclusión de MH y el universo completo de los SCIAN descargados.

Este flujo constituye la Parte 1 regional del proyecto Alto Atoyac. Su finalidad es establecer universos comparables y cartografía territorial antes del análisis de concentraciones. La sección 9 examina las cinco modalidades y sus cambios de conteo y distribución; posteriormente, la modalidad de todos los SCIAN funciona como universo sectorial ampliado para el clustering y el perfilado de concentraciones.

Diagrama 2. Flujo automatico de la Parte 1 regional



9 Modalidades analíticas de la primera fase

Esta sección presenta las cinco modalidades construidas sobre un mismo marco territorial: sectorial, amplia DENUE, amplia + MH, estricta DENUE y estricta + MH. Su comparación permite separar el efecto de tres decisiones: conservar todo el contexto económico seleccionado, exigir distintos grados de evidencia hídrica e incorporar una fuente de campo localizada. La modalidad sectorial contiene 4,365 establecimientos en los municipios seleccionados y 4,010 dentro de la cuenca; funciona como denominador contextual y como base de la Parte 2. Las demás modalidades son escenarios metodológicos para observar cuánto cambian el tamaño y la distribución del universo al modificar las reglas, no estimaciones rivales de una población verdadera.

9.1 Decisiones comunes y denominadores

Las cinco corridas parten de la misma descarga sectorial de DENUE, normalizan nombres municipales y retienen los 26 municipios solicitados. En las tablas de cobertura, 24 presentan candidatos. Primero se construye el universo sectorial mediante la unión de los identificadores recuperados por SCIAN y por texto; después se aplican las reglas de evidencia hídrica y, cuando corresponde, se integra MH. Finalmente, los puntos se intersectan con el polígono de cuenca. Esta secuencia obliga a distinguir el universo municipal del universo dentro de cuenca: las comparaciones principales utilizan siempre el segundo.

La modalidad denominada *sectorial* conserva los 4,365 candidatos de los municipios, incluidos los casos clasificados como *SIN_EVIDENCIA*; *todos los SCIAN* no significa un censo de todas las actividades económicas, sino todos los registros recuperados dentro de la descarga sectorial trabajada. En cambio, las modalidades amplia y estricta conservan solamente *SI* y *REVISAR*. La asignación *SI* tiene precedencia sobre *REVISAR*, pero ninguna de las dos acredita descarga, consumo de agua o carácter industrial.

9.2 Regla amplia, regla estricta y efecto de la decision

La diferencia decisiva se concentra en el SCIAN 812210. La regla amplia admite toda lavandería con ese código como caso por revisar, aunque su nombre o razón social no aporte otra señal. La regla estricta exige, además, una señal textual de contexto textil, mezclilla, proceso humedo, producción o maquila. En ambas modalidades permanecen las demás vías de admisión: evidencia húmeda explícita, lavado genérico con contexto textil y mezclilla relevante. Por tanto, el modo estricto modifica una vía concreta de entrada y no sustituye todo el clasificador.

Conceptualmente, la modalidad amplia puede entenderse como una primera separación entre candidatos con alguna señal de posible relación hídrica y actividades exclusivamente secas: un registro cuya única señal es `proceso_seco_explicito` permanece como `SIN_EVIDENCIA` y no entra al universo hídrico. Sin embargo, el código no utiliza la señal seca como exclusión absoluta; si el mismo establecimiento presenta evidencia húmeda, lavado contextualizado o cumple la regla de lavandería, permanece en el universo. De forma semejante, la modalidad estricta se aproxima a un universo de mayor plausibilidad hídrica, pero no contiene solamente casos con proceso humedo explícito. En las lavanderías 812210 también acepta como señal adicional el contexto textil, la mezclilla, la producción o la maquila. Esta precisión es importante: describirla como “solo explícitamente hídrica” sería más restrictivo que la regla realmente aplicada y no correspondería con los conteos reportados.

La elección produce el mayor efecto cuantitativo de esta fase. Dentro de la cuenca, el universo amplio DENUE contiene 1,679 registros y el estricto DENUE 469: la diferencia es de 1,210 establecimientos, equivalente al 72.1 % del universo amplio. Estos casos son principalmente lavanderías 812210 sin señal adicional suficiente. Se les trata como *posibles comerciales* para diagnosticar la sensibilidad del filtro, pero la ausencia de palabras industriales no demuestra que su operación sea comercial. El modo amplio favorece cobertura frente a nombres poco descriptivos; el estricto reduce ambigüedad, a costa de posibles falsos negativos.

9.3 Integración de MH como variante separada

MH procede de la investigación de campo de Mary Helen Figueroa y Mayra Jacqueline Ramírez y se integra como fuente independiente, no como una propiedad derivada de DENUE. El procedimiento conserva `evidencia_hidrica_original`, `fuentes_universo_hidrico`, `fuentes_evidencia_hidrica` e `id_denue_origen_mh`. Se procesan 53 registros: 46 de Xalmimilulco y siete de Huejotzingo. Cuando existe correspondencia se mantiene o recupera la fila DENUE; cuando no existe en el conjunto auditable se crea un registro suplementario con procedencia MH y campos DENUE desconocidos vacíos.

En Xalmimilulco la correspondencia aprovecha el ID DENUE proporcionado. En Huejotzingo el identificador de la fuente es local, por lo que se busca el candidato DENUE más cercano y se exige una distancia no mayor a 35 m y similitud de nombre no menor a 0.45. Esta regla solo evalúa el vecino más cercano y sus umbrales no cuentan con validación estadística; por ello la tabla de auditoría conserva distancia, similitud, acción e identificador de salida.

MH no se suma mecánicamente al universo previo. En la modalidad amplia, 15 de sus 53 registros ya estaban presentes, 31 se recuperaron desde DENUE y siete fueron suplementarios: el incremento neto fue 38. En la estricta, 12 ya estaban presentes, 34 se recuperaron y siete fueron suplementarios: el incremento neto fue 41. Además, los casos coincidentes se reclasifican como SI. Por eso el total SI pasa de 41 a 91 y no a 94: tres de los 41 SI automáticos también aparecen en MH y cambian de procedencia.

9.4 Lectura individual de cada modalidad

Modalidad sectorial. Este filtro conserva la unión de los establecimientos recuperados por los prefijos SCIAN seleccionados y por el diccionario textual, sin exigir que presenten evidencia hídrica. Entran los registros clasificados como SI, REVISAR y SIN_EVIDENCIA. Se mantiene porque ofrece el

contexto completo de las actividades textiles, de confeccion, lavanderia y actividades relacionadas disponibles en la descarga; permite conocer el denominador economico y evita que el clustering posterior dependa de una clasificacion hidrica previa.

Modalidad amplia DENUE. Parte del universo sectorial y filtra los registros para conservar solamente SI y REVISAR. Los casos cuya unica evidencia es un proceso seco quedan fuera, pero no existe un veto general contra lo seco cuando coexiste con otra señal admisible. Entran todas las lavanderias con SCIAN 812210, incluso cuando el nombre o la razon social no contienen otra señal, ademas de los establecimientos con evidencia humeda explicita, lavado con contexto textil o mezclilla relevante. Se conserva para proteger cobertura frente a nombres poco informativos y para mostrar el limite superior operativo de candidatos obtenidos solo con DENUE; su costo es incluir numerosas lavanderias posiblemente comerciales.

Modalidad amplia + MH. Primero aplica exactamente el filtro amplio y despues incorpora la investigacion de campo MH. Entran los registros ya seleccionados por DENUE, los casos MH que coinciden con ellos, los registros recuperados desde la tabla auditable y los suplementarios sin correspondencia suficiente. Se genera para medir cuanto cambia el escenario de cobertura amplia al añadir una fuente independiente. No debe interpretarse como una simple suma, porque MH tambien reclasifica como SI casos que ya estaban presentes.

Modalidad estricta DENUE. Parte del mismo universo sectorial, pero una lavanderia SCIAN 812210 solo entra por esa via cuando presenta una señal adicional de contexto textil, mezclilla, proceso humedo, produccion o maquila. Por ello es mas selectiva que la amplia, aunque no equivale a conservar exclusivamente procesos hidricos explicitos. Tambien entran los casos admitidos por las otras reglas de evidencia humeda, lavado contextualizado o mezclilla relevante. Se utiliza para reducir la ambigüedad introducida por lavanderias de posible orientacion comercial y producir una lista regional de priorizacion mas acotada; puede excluir operaciones industriales reales cuyo nombre no describe el proceso.

Modalidad estricta + MH. Aplica el filtro estricto y posteriormente integra MH mediante correspondencias y registros suplementarios auditables. Entran los candidatos estrictos de DENUE y los casos aportados o reclasificados por el trabajo de campo. Se adopta como escenario principal de priorizacion porque combina una regla automatica conservadora con evidencia localizada que recupera omisiones. Sin embargo, su distribucion esta influida por la cobertura de MH en Huejotzingo y Xalmimilulco, por lo que debe presentarse junto con la modalidad estricta sin MH y con la procedencia de cada registro.

Cuadro 3: Definicion, efecto y uso recomendado de las cinco modalidades.

Modalidad	N mun.	En cuenca	SI	REVISAR	Definicion y pregunta	Ventaja y sesgo esperado	Uso recomendado
Sectorial	4,365	4,010	41	1,638	Union SCIAN/texto; incluye 2,331 sin evidencia. ¿Como se distribuye el contexto economico seleccionado?	Maxima cobertura sectorial; incluye numerosos casos sin señal hidrica y no representa toda la economia.	Denominador territorial, contexto y base del clustering.
Amplia DE-NUE	1,718	1,679	41	1,638	Admite SI/REVISAR; toda lavanderia 812210 entra por revisar.	Recupera nombres genericos, pero mezcla lavanderias comerciales y potencialmente industriales.	Contraste de cobertura y cota operativa amplia.
Amplia + MH	1,756	1,717	91	1,626	Regla amplia seguida de integracion MH.	Añade evidencia localizada; puede aumentar desproporcionadamente las zonas cubiertas por trabajo de campo.	Sensibilidad conjunta a regla amplia y fuente complementaria.
Estricto DE-NUE	476	469	41	428	Lavanderia 812210 requiere señal adicional.	Reduce ambigüedad, pero puede perder industrias con nombres poco descriptivos.	Escenario reproducible de priorizacion sin evidencia de campo.
Estricto + MH	517	510	91	419	Regla estricta seguida de integracion MH auditable.	Recupera casos de campo y concentra su efecto en Huejotzingo; la cobertura MH no es regionalmente uniforme.	Escenario principal de priorizacion, siempre acompañado del amplio y de la procedencia.

9.5 Consecuencias para la interpretacion

Los resultados robustos son la persistencia de Puebla y Huejotzingo como espacios relevantes y el predominio de establecimientos con bajo estrato de personal ocupado. Sin embargo, el tamaño total, el peso relativo de Huejotzingo y la jerarquia de municipios cambian con la regla y con MH. En estricto + MH, Huejotzingo pasa de 57 a 98 registros debido a los 41 casos añadidos por MH; su participacion alcanza 19.2%, frente a 9.0% en amplio + MH. Este aumento no prueba mayor presion ambiental: demuestra que la cobertura de campo se concentra territorialmente.

La decision metodologica recomendada es utilizar estricto + MH para priorizar revision, presentar el amplio como analisis de sensibilidad y conservar el sectorial como contexto. Cada cifra debe acompañarse de territorio, modalidad, denominador y fuente. No se dispone todavia de una estimacion validada de sensibilidad o precision del clasificador, por lo que ninguna modalidad debe presentarse como conteo real verificado de industrias contaminantes.

10 Analisis espacial descriptivo de unidades economicas

10.1 Tamaño y sensibilidad del universo

La comparacion de tamaños confirma que la regla de lavanderias domina la incertidumbre clasificatoria. La Figura 2 mantiene constante el recorte espacial y muestra que integrar MH modifica el universo en decenas de casos, mientras pasar de amplio a estricto lo modifica en 1,210. En consecuencia, cualquier resultado territorial debe leerse junto con la modalidad que lo produjo.




Figura 2: Sensibilidad del tamaño del universo a la regla amplia, la regla estricta y la integracion MH. Fuente: presentacion a direccion.

10.2 Concentracion municipal y participacion territorial

La concentracion municipal se obtuvo contando puntos dentro de los poligonos municipales recortados por la cuenca. Todos los mapas de conteo usan la misma extension y una escala comun de 0 a 1,762 registros; de este modo, una modalidad pequeña no parece artificialmente tan intensa como la sectorial. El panel de participacion utiliza como denominador el total dentro de cuenca de cada modalidad. Esta segunda lectura permite comparar estructura relativa, pero no representa densidad por kilometro cuadrado.




Figura 3: Concentracion municipal absoluta de las cinco modalidades con escala comun. Los colores representan conteos, no intensidad hidrica.




Figura 4: Participacion municipal dentro de cada modalidad. El denominador cambia entre columnas y corresponde al total de la modalidad dentro de cuenca.

La matriz de la Figura 5 presenta los conteos observados y usa $\log(1+n)$ solamente para el color, de modo que los municipios pequeños sean visibles. Puebla conserva el mayor conteo: 1,762 en el sectorial, 1,004 en las dos modalidades amplias y 283 en las dos estrictas. Huejotzingo registra 450, 117, 155, 57 y 98, respectivamente. San Martin Texmelucan conserva 460 casos sectoriales, pero cae a 99 en amplio y 11 en estricto. Esto muestra que una alta presencia sectorial no implica igual presencia bajo criterios hidricos.




Figura 5: Matriz comparativa por municipio y modalidad. Las cifras son conteos; la transformación logarítmica se utiliza solo en la escala cromática.

10.3 Efecto espacial de MH

La integración MH introduce 53 registros con evidencia atribuida al trabajo de campo, pero su incremento neto depende de la modalidad: 38 en amplio y 41 en estricto. De los 91 registros SI finales, 53 tienen como fuente MH_TRABAJO_CAMPO y 38 conservan como fuente las reglas DENUÉ. La superposición explica por que no deben sumarse 41 automáticos y 53 MH como si fueran unidades diferentes.

El efecto es espacialmente concentrado. Los 41 registros añadidos por MH al escenario estricto se encuentran en el municipio de Huejotzingo, que incluye Santa Ana Xalmimilulco: el conteo pasa de 57 a 98. En la modalidad amplia pasa de 117 a 155. Por ello MH eleva el peso relativo de Huejotzingo, pero no puede extrapolarse como una tasa de omisión de DENUÉ para los demás municipios. Las Figuras 6 y 7 muestran, respectivamente, la localización de los aportes y el cambio en conteos municipales.




Figura 6: Distribucion comparable entre escenarios con la misma extension y simbologia; los aportes MH se distinguen en rojo.




Figura 7: Cambio de los conteos municipales por modalidad e integracion MH. Son cantidades de registros, no tasas ni volúmenes de descarga.

10.4 Lavanderías sensibles al criterio estricto

Para aislar el efecto de la regla se compararon las modalidades DENUE sin MH. Los 1,210 registros SCIAN 812210 presentes en amplio y ausentes en estricto constituyen el grupo operativo de posibles lavanderías comerciales. Puebla concentra 721, equivalentes al 59.6% del grupo. La etiqueta es una aproximación por falta de señal adicional: puede incluir operaciones industriales con nombres genéricos y no constituye verificación del tipo de establecimiento.




Figura 8: Concentración territorial de lavanderías 812210 admitidas por la regla amplia y excluidas por la estricta.




Figura 9: Municipios con mayor número de registros sensibles a la regla de lavanderías.

10.5 Estratos de personal ocupado

Los estratos DENUE muestran que el universo está compuesto principalmente por establecimientos pequeños. Dentro de cuenca, el grupo de 0 a 5 personas representa 3,332 de 4,010 registros sectoriales (83.1%), 1,595 de 1,679 en amplio DENUE (95.0%) y 441 de 510 en estricto + MH (86.5%). En el estrato de 6 a 10 personas aparecen 333, 55 y 35, respectivamente. Los registros MH sin personal reportado permanecen como desconocidos; no se imputan como pequeños.




Figura 10: Distribucion municipal de establecimientos con estrato reportado de 0 a 5 personas en las cinco modalidades.




Figura 11: Distribucion municipal de establecimientos con estrato reportado de 6 a 10 personas en las cinco modalidades.

La predominancia de estratos bajos describe una estructura de muchas unidades con poca ocupacion reportada, pero no mide capacidad productiva, formalidad, consumo o descarga. Un establecimiento pequeño puede ejecutar procesos intensivos y uno grande puede carecer de proceso humedo. Los mapas sirven para localizar zonas donde conviene investigar servicios compartidos o articulaciones productivas, no para dar esos vinculos por demostrados.

10.6 Distancia a hidrografia

La distancia se calculo despues de reprojectar puntos y red hidrografica recortada a UTM zona 14N (EPSG:32614). Para cada establecimiento se obtuvo la distancia euclidiana minima a cualquier linea de la red suministrada y se agrupo en cinco intervalos: 0–250 m, 250–500 m, 500–1,000 m, 1–2 km y mas de 2 km. Los limites superiores se incluyen en cada intervalo. No se diferenciaron cauces principales y secundarios, por lo que la metrica expresa proximidad a cualquier linea disponible.

Los errores posicionales de DENU afectan especialmente los intervalos cortos: una coordenada desplazada respecto al predio o acceso puede cambiar de categoria sin que cambie la relacion real con el sistema hidrico. Ademas, el calculo no incorpora topografia, drenaje, colectores, tuberias, direccion de flujo ni punto efectivo de descarga. Su uso admisible es priorizar verificacion adicional y describir contexto cartografico.




Figura 12: Proximidad geométrica a la red hidrográfica en el escenario estricto + MH. La distancia no demuestra conectividad ni descarga.

Limite de interpretacion

La distancia geométrica a un cauce es un criterio de priorización espacial, no evidencia de que exista una descarga a ese cauce. Sin red de drenaje, topografía, punto de descarga y conectividad hidráulica no puede inferirse la ruta del agua residual.

Como cierre de esta fase, la principal desventaja del escenario estricto es que puede excluir numerosas lavanderías industriales o unidades dedicadas al deslavado de mezclilla cuya operación es pequeña y cuyo nombre no contiene las señales adicionales requeridas. En el sector textil, clasificar una actividad como seca o descartarla por falta de evidencia húmeda explícita puede no representar por completo la generación potencial de residuos: aun cuando el proceso productivo principal sea corte, confección, bordado o deshebrado, la limpieza de equipos, prendas, superficies o recipientes puede utilizar agua y movilizar colorantes, fibras, detergentes u otros contaminantes de interés. Esta posibilidad no demuestra que cada establecimiento genere o descargue dichos residuos, pero impide considerar la ausencia de señales textuales como evidencia suficiente de ausencia de impacto. Por ello, la etapa siguiente utilizará el universo sectorial completo como universo de detección, sin formar agrupamientos a partir de las etiquetas hídricas. Primero se identificarán concentraciones territoriales exclusivamente por la geometría de los establecimientos y, después, se analizarán sus perfiles sectoriales y productivos para reconocer donde coinciden actividades, escalas y señales que ameriten validación ambiental más detallada.

11 Diagnostico previo de estructura espacial

El diagnostico previo explora exclusivamente la geometria de los 4,365 establecimientos del universo sectorial ampliado. Los puntos se proyectaron a EPSG:32614, por lo que todas las distancias, anchos de banda y tamaños de celda se expresan en metros. En esta etapa no se utilizaron SCIAN, municipio, tamaño, evidencia hidrica ni señales productivas para elegir escalas o formar grupos. El objetivo fue reconocer si existia una sola escala territorial plausible o una combinacion de nucleos locales, corredores urbanos y actividad dispersa que exigiera algoritmos sensibles a densidades variables.

11.1 Distancias a vecinos y escalas espaciales

Se calcularon las distancias desde cada punto hasta sus vecinos de orden $k = 2, 3, 5, 10, 15, 20, 30$ y 50. Para cada k se conservaron los cuantiles 0.10, 0.25, 0.50, 0.75, 0.90, 0.95 y 0.99. La distancia al segundo vecino tiene una mediana de 83 m y un percentil 90 de 280 m; para el quinto vecino estos valores aumentan a 254 y 572 m; para el décimo, a 421 y 971 m; y para el vigesimo, a 656 y 1,587 m. Esta expansion no es uniforme: las colas altas crecen mucho mas rapido que las medianas, hasta alcanzar 4.61 km en el percentil 99 del vecino 20 y 22.95 km para el vecino 50.

Cuadro 4: Distancias seleccionadas al vecino de orden k en el universo de deteccion (metros).

k	P10	P25	P50	P75	P90	P99
2	12	32	83	166	280	727
5	74	138	254	384	572	1,571
10	130	233	421	596	971	2,843
20	208	395	656	928	1,587	4,611
30	270	520	860	1,186	2,013	6,739
50	369	783	1,172	1,677	3,042	22,947

La Figura 13 ordena, para cada valor de k , las 4,365 distancias de menor a mayor y expresa la posicion horizontal como percentil de establecimientos. Si el territorio respondiera a una escala aproximadamente uniforme, se esperaria un cambio de pendiente dominante y relativamente consistente entre curvas. En cambio, se observan inflexiones sucesivas: una primera transicion asociada con los nucleos muy compactos, un crecimiento gradual en las zonas de densidad intermedia y una aceleracion fuerte entre los percentiles 90 y 99, correspondiente a establecimientos perifericos o aislados. Ademas, el nivel vertical del cambio aumenta sistematicamente con k , desde cientos de metros para vecinos cercanos hasta varios kilometros cuando se exige reunir 30 o 50 vecinos.

Curvas k-distancia ordenadas: multiples escalas, sin un codo unico




Figura 13: Curvas k-distancia ordenadas para $k = 2, 5, 10, 20, 30$ y 50 . Las líneas verticales marcan los percentiles 90 y 95 como referencias descriptivas, no como umbrales optimizados. La presencia de cambios de pendiente en niveles distintos sustenta una exploracion multiescala.

Estos resultados muestran simultaneamente proximidad muy alta en los nucleos urbanos y separaciones de kilometros en zonas perifericas. No aparece un unico “codo” que pueda traducirse sin ambigüedad en un radio universal. Las escalas observadas justificaron explorar DBSCAN con `eps` de 250, 400, 600, 800, 1,200 y 1,600 m y distintos valores de `min_samples`; los valores pequeños representan vecindades inmediatas, mientras 1,200–1,600 m examinan continuidad territorial mas amplia. Los ordenes 10, 20 y 30 tambien sustentaron la exploracion de `min_samples` en HDBSCAN y OPTICS. Los parametros no se “optimizaron” contra atributos economicos: se definieron como una bateria multiescala basada en la separacion geometrica observada.

11.2 KDE y malla hexagonal en la cuenca

Antes de construir agrupamientos discretos, se examinó cómo se distribuyen espacialmente los establecimientos y cómo cambia esa estructura al observarla a distintas escalas. Para ello se utilizaron dos diagnósticos complementarios: una estimación de densidad por kernel (*Kernel Density Estimation*, KDE), que genera una superficie continua y suavizada de intensidad espacial, y una malla hexagonal, que conserva un conteo directo de establecimientos dentro de celdas de tamaño fijo.

11.2.1 Estimación de densidad por kernel

El KDE gaussiano se calculó sobre una grilla regular con separación de 250 m entre nodos y con anchos de banda de 500, 1,000 y 2,000 m. La separación de 250 m determina la resolución con la que se evalúa y representa la superficie, mientras que el ancho de banda h determina la escala espacial del suavizado.

Para una ubicación bidimensional $\mathbf{s}$, la densidad estimada es

$$\hat{f}_h(\mathbf{s}) = \frac{1}{nh^2} \sum_{i=1}^n K\left(\frac{\mathbf{s} - \mathbf{s}_i}{h}\right), \quad K(\mathbf{u}) = \frac{1}{2\pi} \exp\left(-\frac{\|\mathbf{u}\|^2}{2}\right),$$

donde n es el número de establecimientos, $\mathbf{s}_i$ corresponde a la coordenada UTM del establecimiento i y h es el *bandwidth*. En términos prácticos, cada establecimiento aporta una superficie de influencia

cuyo valor es máximo cerca de su ubicación y disminuye gradualmente con la distancia. Cuando varios establecimientos se encuentran próximos, sus contribuciones se superponen y producen zonas de mayor intensidad.

El ancho de banda determina cuánto se extiende esta contribución. Con valores pequeños de h se preservan variaciones locales y aparecen focos más definidos; al aumentar h , cada establecimiento distribuye su contribución sobre un área mayor, disminuyen los máximos locales y pueden integrarse estructuras que a escalas menores aparecen separadas. Por esta razón, los tres anchos de banda no representan alternativas entre las que deba elegirse necesariamente una sola, sino diferentes escalas desde las cuales observar la misma distribución espacial.

La implementación utiliza `KernelDensity` con kernel gaussiano. La log-densidad se evalúa en cada nodo de la grilla, se transforma nuevamente mediante la función exponencial y se multiplica por 10^6 para expresar la densidad espacial normalizada tomando el km^2 como unidad de superficie en lugar del m^2 . Debido al factor $1/n$, los valores resultantes representan una distribución espacial relativa normalizada y no deben interpretarse directamente como un número estimado de establecimientos por km^2 .

El kernel gaussiano tiene soporte infinito: su contribución disminuye rápidamente conforme aumenta la distancia, pero matemáticamente nunca se vuelve exactamente cero. Por esta razón, el límite de la cuenca no constituye un límite natural de la superficie estimada. En versiones preliminares de la figura, la representación se encontraba recortada gráficamente al polígono de la cuenca, lo que producía la impresión de que la densidad terminaba de manera abrupta en su límite. En la versión utilizada en este reporte, la superficie se representa de forma continua a ambos lados del polígono y el límite de la cuenca se muestra mediante una línea de referencia.

Esta decisión permite conservar el contexto espacial exterior utilizado en la construcción del diagnóstico y reduce la distorsión visual asociada al efecto de borde. La interpretación sustantiva de los resultados, sin embargo, permanece restringida al interior de la cuenca.

Los mapas KDE deben interpretarse como superficies de **intensidad espacial relativa suavizada**. No representan conteos directos ni asignan establecimientos a un cluster. Además, cada panel utiliza su propia escala visual, ya que el valor máximo de la superficie disminuye conforme aumenta el ancho de banda. Los colores permiten comparar posiciones de mayor y menor intensidad dentro de cada panel, pero los valores cromáticos no deben compararse directamente entre paneles como magnitudes absolutas equivalentes.

Las tres escalas permiten observar distintos niveles de organización territorial. Con $h = 500$ m se distinguen principalmente focos locales de concentración. Con $h = 1,000$ m comienza a observarse la proximidad entre esos focos y aparecen bandas de intensidad de escala intermedia. Con $h = 2,000$ m se hacen visibles estructuras regionales más amplias y algunas concentraciones previamente separadas forman superficies continuas de intensidad. Entre ellas destaca el continuo urbano Puebla–Cholula–Cuautlancingo y, hacia el norponiente, una banda de mayor intensidad coincidente con municipios donde existe una presencia importante de actividades textiles. Esta continuidad debe entenderse como un resultado dependiente de la escala de suavizado y no, por sí sola, como evidencia de un corredor productivo formal.

11.2.2 Malla hexagonal

Como complemento al KDE se construyeron mallas hexagonales con radios r de 250, 500 y 1,000 m. A diferencia del KDE, esta representación no suaviza la distribución espacial: cada establecimiento es asignado directamente al hexágono que contiene su coordenada y posteriormente se contabiliza el número de establecimientos presentes en cada celda.

El área de un hexágono regular de radio r es

$$A_h = \frac{3\sqrt{3}}{2}r^2,$$

lo que equivale aproximadamente a 0.162, 0.650 y 2.598 km² para radios de 250, 500 y 1,000 m, respectivamente.

Para cada establecimiento se realiza una unión espacial mediante el predicado `within` y, para cada hexágono h , se calcula

$$n_h = \sum_i I(\mathbf{s}_i \in h),$$


donde n_h corresponde al número de establecimientos localizados dentro de la celda. Los hexágonos sin establecimientos ($n_h = 0$) no se representan.

En este caso, el valor mostrado es un **conteo directo** y no una estimación de densidad. Dentro de cada panel todas las celdas poseen la misma superficie, por lo que sus conteos pueden compararse espacialmente. Sin embargo, los valores obtenidos para radios distintos no son directamente comparables, ya que el área de los hexágonos aumenta considerablemente con la escala.

La malla de 250 m conserva la heterogeneidad espacial más fina y muestra numerosos hexágonos aislados o con pocos establecimientos. Con 500 m, los puntos próximos comienzan a integrarse en conjuntos locales de mayor tamaño. Con 1,000 m se consolidan las principales masas de concentración territorial y se vuelve más evidente la diferencia entre las grandes áreas urbanas y productivas y las zonas de ocupación más dispersa.

Para mejorar la lectura de los mapas, los conteos se representan mediante una normalización logarítmica. Esta transformación modifica únicamente la escala visual: permite distinguir simultáneamente hexágonos con pocos establecimientos y celdas con conteos elevados, evitando que los valores máximos dominen completamente la representación. No modifica los conteos originales ni la asignación espacial de los establecimientos.

Diagnostico multiescala del universo sectorial en la cuenca



El KDE se muestra continuo a ambos lados del limite; la línea delimita el area de interpretacion. Los hexagonos muestran conteos observados y ninguno de los dos diagnosticos define membresias.

Figura 14: Diagnóstico espacial multiescala del universo sectorial. En la parte correspondiente al KDE se muestran superficies continuas de intensidad espacial relativa con anchos de banda de 500, 1,000 y 2,000 m. Las mallas hexagonales presentan conteos directos de establecimientos utilizando radios de 250, 500 y 1,000 m. La línea de la cuenca indica el límite utilizado para la interpretación y no constituye un recorte matemático del kernel.

Los dos diagnósticos muestran una estructura territorial consistente, aunque representan el fenómeno de forma distinta. Las zonas donde el KDE presenta máximos de intensidad corresponden, en general, con áreas donde la malla hexagonal registra mayores concentraciones de establecimientos. A escalas finas, las zonas menos ocupadas permanecen fragmentadas, mientras que las principales áreas urbanas y productivas conservan concentraciones reconocibles en ambos métodos.

La zona metropolitana del sur no se comporta como un único punto de concentración, sino como una superficie extensa formada por varios máximos locales próximos entre sí. Hacia el norponiente se observan concentraciones de menor tamaño, separadas por espacios de menor ocupación y por discontinuidades que se vuelven más o menos visibles dependiendo de la escala empleada.

Este diagnóstico no define todavía los clusters utilizados en etapas posteriores. Su función es describir la geometría general del universo. El diagnóstico muestra que el universo combina concentraciones compactas con zonas de mayor continuidad espacial. Esta característica motiva evaluar métodos capaces de representar densidades variables y debe considerarse posteriormente al interpretar agrupamientos de gran extensión.

11.3 Heterogeneidad de densidad y eleccion de familia algoritmica


La dispersion de las distancias k-NN y la persistencia de patrones diferentes entre escalas confirman heterogeneidad suficiente para no depender solamente de DBSCAN. DBSCAN aplica un unico *eps* a todo el territorio: un radio apropiado para Puebla puede unir estructuras por encadenamiento, mientras ese mismo radio puede tratar como ruido concentraciones rurales legítimas; un radio menor puede separar adecuadamente los núcleos urbanos, pero fragmentar las zonas menos densas. Por eso DBSCAN se mantuvo como referencia interpretable, no como unica opcion.

HDBSCAN y OPTICS permiten examinar una jerarquía o un ordenamiento de densidades y son mas adecuados cuando los grupos no comparten una escala unica. HDBSCAN fue especialmente pertinente porque combina tamaño minimo, densidad local y seleccion jerarquica EOM o *leaf*; OPTICS se utilizo como contraste de estructura sin fijar un solo radio. Esta preferencia surgio antes del perfilado productivo y no implica que cualquier salida de esos algoritmos sea correcta: las soluciones se compararon posteriormente por ruido, continuidad, tamaño del mayor cluster, estabilidad, borde y perturbaciones espaciales.

11.4 Lectura multiescala del mega-cluster

El mega-cluster 20 contiene 1,997 establecimientos y articula seis municipios y 14 localidades. Su persistencia media es 0.999, pero su gran tamaño no significa homogeneidad interna. Para visualizarla sin modificar la solucion principal se repitieron los diagnosticos dentro de su envolvente: KDE con anchos de 250, 500 y 1,000 m y hexagonos de 250, 500 y 1,000 m. A 250 m aparecen numerosos maximos locales y vacios internos; a 500 m se observan ramas conectadas; a 1,000 m esas ramas se funden en una estructura urbana continua. La malla de 250 m contiene 867 hexagonos ocupados y un maximo de 13 establecimientos por celda.

Diagnostico multiescala interno del mega-cluster 20



El KDE se muestra continuo a ambos lados del limite; la linea delimita el area de interpretacion. Los hexagonos muestran conteos observados y ninguno de los dos diagnosticos define membresias.

Figura 15: Diagnostico multiescala interno del mega-cluster 20. Los subpatrones de KDE y ocupacion hexagonal describen heterogeneidad interna, pero no sustituyen su membresia principal.

La figura explica por que la configuracion principal puede reconocer una sola estructura: entre los maximos locales existe suficiente continuidad de puntos a escalas intermedias para enlazarlos bajo la seleccion EOM. A la vez, justifica una lectura posterior por subnucleos exploratorios. Esa exploracion interna identifico 18 ramas con HDBSCAN `leaf`, pero dejo 44.5 % de los puntos sin rama local bajo esa especificacion; todos continúan siendo miembros del mega-cluster principal. Los subnucleos son una herramienta descriptiva para orientar lectura territorial, no una reclasificacion silenciosa.

11.5 Efecto de borde de la cuenca

El efecto de borde se detecto comparando dos universos. El clustering utiliza los 4,365 establecimientos de los municipios seleccionados, incluidos 355 situados fuera del poligono; la interpretacion se restringe despues a los 4,010 interiores. Así se evita que el limite hidrológico elimine vecinos necesarios o corte artificialmente una concentracion que continua fuera del area de interpretacion. Para cada cluster se registraron `n_dentro_cuenca`, `n_fuera_cuenca`, sus porcentajes y el indicador `cruza_limite_cuenca`.

El control distingue tres situaciones. Los clusters 0–3 se encuentran completamente fuera de la cuenca y no se interpretan como concentraciones interiores. La mayor parte de los clusters analizados esta completamente dentro. El cluster 11 cruza el limite: contiene 48 establecimientos, ocho dentro y 40 fuera, por lo que una deteccion restringida previamente al poligono habria observado solo el 16.7 % de su estructura. Los puntos exteriores no prueban conectividad hidrológica; sirven exclusivamente para estabilizar la geometria de vecindad y hacer visible la continuidad espacial.

En conjunto, el diagnostico previo establecio cuatro decisiones: trabajar en metros con EPSG:32614; explorar escalas locales y regionales en vez de fijar un unico radio; preferir HDBSCAN y OPTICS como familias capaces de representar densidad variable, conservando DBSCAN como referencia; y detectar sobre el universo municipal ampliado antes de interpretar dentro de la cuenca. Estas decisiones se tomaron sin utilizar etiquetas productivas y delimitan el espacio de experimentos descrito en la seccion siguiente.

12 Clustering espacial: diseño de experimentos

12.1 Universo de deteccion vs. universo de interpretacion

La deteccion se ejecuto sobre los 4,365 establecimientos del universo sectorial ubicados en los municipios de referencia. De ellos, 4,010 intersectan la cuenca y 355 quedan fuera. Mantener el contexto exterior durante el ajuste evita que el poligono hidrológico actue como una frontera artificial: un establecimiento interior conserva vecinos exteriores que forman parte de la misma continuidad urbana o productiva. Una vez calculada la membresia completa, la interpretacion sustantiva se restringe a los puntos interiores y se registra, para cada cluster, cuantos miembros quedan dentro y fuera.

La unidad analitica es el establecimiento y la matriz de clustering contiene solamente dos columnas: x y y en EPSG:32614. Todas las distancias son euclidianas y estan expresadas en metros. No se estandarizaron las coordenadas porque comparten unidad y escala; tampoco se agregaron puntos por municipio, localidad o celda. De esta manera, la particion representa proximidad entre ubicaciones registradas y no similitud economica.

12.2 Algoritmos evaluados

Se evaluaron tres familias de clustering por densidad. DBSCAN define como nucleo un punto con al menos `min_samples` observaciones dentro de un radio fijo ϵ y expande componentes conectados desde esos nucleos. Es transparente y facilita relacionar el resultado con las curvas k-distancia, pero obliga a usar el mismo radio en zonas de densidad diferente. HDBSCAN reemplaza el radio unico por

una jerarquia construida a partir de distancias de alcanzabilidad mutua; `min_samples` controla cuan conservadora es la densidad local y `min_cluster_size` el tamaño minimo persistente. OPTICS ordena los puntos por alcanzabilidad y permite observar estructura a traves de densidades variables; en esta bateria se extrajeron clusters mediante $\xi = 0.05$.

Cuadro 5: Espacio de parametros del experimento de clustering espacial.

Metodo	Parametros recorridos	Escenarios	Relacion con el diagnostico
DBSCAN	$\varepsilon = 250, 400, 600, 800, 1,200, 1,600$ m; <code>min_samples</code> =5, 10, 15, 25	24	Recorre desde vecindades locales hasta continuidades regionales observadas en k-NN, KDE y hexagonos.
HDBSCAN	<code>min_cluster_size</code> =10, 20, 30, 50, 75; <code>min_samples</code> =5, 10, 20; seleccion EOM y <i>leaf</i>	30	Contrasta tamaños minimos y conservadurismo local sin imponer un solo radio; EOM favorece ramas persistentes y <i>leaf</i> particiones mas finas.
OPTICS	<code>min_samples</code> =10, 20, 30; $\xi = 0.05$; tamaño minimo = 1 % de los puntos	3	Funciona como contraste de densidad variable mediante el ordenamiento de alcanzabilidad.
Total	Solo coordenadas <code>x_utm14n</code> , <code>y_utm14n</code>	57	Misma matriz espacial y mismo universo de 4,365 establecimientos.

Los radios DBSCAN cubren el intervalo sugerido por las distancias al quinto, decimo y vigesimo vecino: 250–600 m representan nucleos compactos; 800–1,200 m examinan tejido urbano intermedio; y 1,600 m prueba continuidad amplia. Los tamaños HDBSCAN permiten detectar desde concentraciones pequeñas de diez establecimientos hasta estructuras que requieren al menos 75 miembros. No se eligio un unico valor desde el diagnostico: se construyo una bateria capaz de revelar que resultados sobreviven a cambios razonables de escala.

12.3 Configuracion reproducible y almacenamiento

Los 57 escenarios usan exactamente el mismo orden de puntos y la misma metrica euclidiana. DBSCAN, HDBSCAN y OPTICS son deterministas para estas entradas; la semilla comun 20260921 se utiliza en las pruebas posteriores que añaden desplazamientos gaussianos. Para cada ejecucion se almacenan metodo, parametros, numero de clusters, ruido, tamaños minimo, mediano, medio y maximo, peso del cluster mayor y, cuando existe, probabilidad de pertenencia.

Las membresias completas se guardan en `membresias_escenarios.csv.gz`: una fila por combinacion establecimiento–escenario, identificada por `d_llave`, `escenario_id` y etiqueta de cluster. Esto produce 248,805 asignaciones ($4,365 \times 57$) y permite reconstruir cualquier particion sin volver a ajustar el algoritmo. La etiqueta `-1` se conserva como ruido y no se convierte en un cluster adicional. El archivo `resumen_escenarios.csv` concentra las metricas de cada corrida y `espacio_parametros.json` registra la bateria exacta.

La separacion entre deteccion e interpretacion se garantiza en el codigo: el arreglo entregado a los algoritmos se construye exclusivamente con las coordenadas de la geometria UTM. SCIAN, nombre, señales textuales, evidencia hidrica, municipio, localidad y estrato de personal permanecen en la tabla maestra, pero no ingresan al ajuste ni al puntaje de seleccion. Esos atributos se reincorporan solamente despues de fijar la solucion principal.

13 Seleccin de la solucion espacial y robustez

13.1 Criterios de seleccion

La seleccion se realizo sin inspeccionar la composicion economica de los clusters. Primero se excluyeron soluciones degeneradas: menos de tres o mas de 80 clusters, menos de 1 % o mas de 75 % de ruido, o un cluster mayor superior al 60 % del universo. Sobre los escenarios elegibles se calculo un puntaje espacial reproducible que combina estabilidad frente a configuraciones proximas, estabilidad frente a error posicional, probabilidad de pertenencia HDBSCAN, balance de ruido, control del mega-cluster y penalizaciones por particiones extremas o encadenamiento.

En forma abreviada, el puntaje utilizado fue

$$S = 0.40A_5 + 0.15A_{25} + 0.20P + 0.15(1 - R) + 0.15(1 - M) - 0.10E - 0.10C,$$

donde A_5 es el ARI medio de las cinco particiones mas similares del mismo metodo; A_{25} , el ARI medio tras tres perturbaciones gaussianas de 25 m; P , la probabilidad media de pertenencia o un valor neutral para metodos sin ella; R , una penalizacion por alejarse de 25 % de ruido; M , la penalizacion por la fraccion del cluster mayor que excede 35 %; E , la penalizacion por un numero extremo de clusters; y C , la penalizacion de encadenamiento basada en la diagonal de la caja envolvente por raiz del tamaño. El puntaje es una regla operativa documentada, no una demostracion de verdad territorial.




Figura 16: Comparación de los 57 escenarios por proporción de ruido, peso del cluster mayor y número de clusters. La estrella identifica la solución principal.

La Figura 16 muestra por que no se eligio simplemente el escenario con menos ruido. Las configuraciones con ruido minimo suelen concentrar cerca de la mitad o mas del universo en una sola estructura y pueden favorecer encadenamiento; las configuraciones con radios o exigencias muy estrictas elevan el ruido hasta 40–80 %. La solucion principal ocupa una zona intermedia: 13.4 % de ruido, 22 clusters y 45.8 % en el cluster mayor. Conserva concentraciones pequeñas sin fragmentar excesivamente el territorio y reconoce como dispersos los casos que no alcanzan soporte local suficiente.

13.2 Escenarios seleccionados e identificacion de la particion

La solucion principal es HDBSCAN con `min_cluster_size=10`, `min_samples=20` y seleccion EOM. Se conservaron cuatro HDBSCAN cercanos para sensibilidad y el mejor DBSCAN elegible como referencia externa. La Tabla 6 permite identificarlos y reproducir la comparacion.

Cuadro 6: Solucion principal, escenarios de sensibilidad y referencia DBSCAN.

Rol	Configuracion	Clusters	Ruido	Ruido %	Mediana	Max.	Mega %	Prob.	ARI 25 m	Puntaje
Principal	HDBSCAN; mcs=10; ms=20; EOM	22	584	13.38	46.5	1,997	45.75	0.914	0.926	0.963
Sensibilidad	HDBSCAN; mcs=20; ms=20; EOM	21	598	13.70	48.0	1,997	45.75	0.909	0.926	0.962
Sensibilidad	HDBSCAN; mcs=30; ms=20; EOM	18	646	14.80	72.5	1,997	45.75	0.911	0.921	0.962
Sensibilidad	HDBSCAN; mcs=20; ms=10; EOM	24	450	10.31	43.5	2,065	47.31	0.937	0.972	0.957
Sensibilidad	HDBSCAN; mcs=30; ms=10; EOM	20	440	10.08	68.5	2,065	47.31	0.932	0.973	0.956
Referencia	DBSCAN; $\varepsilon = 1,600$ m; ms=25	13	329	7.54	95.0	2,178	49.90	—	0.996	0.924

13.3 Justificacion de la solucion seleccionada

La configuracion principal fue la **mejor puntuada bajo la regla operativa definida** (0.963), no una geografia verdadera unica. Su seleccion responde al compromiso buscado entre estabilidad, resolucion territorial, ruido, pertenencia y control del cluster mayor. Primero, su ARI medio frente a las cinco configuraciones HDBSCAN mas proximas es 0.937. Segundo, su ARI medio ante desplazamientos gaussianos de 25 m es 0.926. Tercero, la probabilidad media de pertenencia es 0.914 y 84.0 % de los puntos agrupados alcanza probabilidad al menos 0.8. Cuarto, conserva 22 grupos, mas resolucion territorial que la referencia DBSCAN de 13 grupos. Quinto, limita el cluster mayor a 45.75 %, frente a 49.90 % en la referencia, sin elevar el ruido a niveles extremos.

DBSCAN presenta un ARI de perturbacion mayor (0.996) y menos ruido (7.54 %), pero esto no lo hace globalmente preferible: utiliza un radio fijo de 1,600 m, forma solo 13 grupos, eleva la mediana de tamaño a 95 y concentra 2,178 establecimientos en el mayor cluster. Su proxy maximo de encadenamiento es 0.908 frente a 1.222 en la principal, pero su menor resolucion y mayor mega-cluster muestran que la estabilidad se obtiene, en parte, fusionando estructuras. Se conserva como referencia precisamente porque ofrece una lectura mas agregada y estable con la cual contrastar HDBSCAN.

Los escenarios de sensibilidad confirman que la seleccion no es fragil y, al mismo tiempo, muestran que no es unica. Dos configuraciones HDBSCAN obtienen 0.962, apenas 0.001 menos que la seleccionada, y producen resultados practicamente equivalentes. Con `min_samples=20`, elevar `min_cluster_size` de 10 a 20 o 30 mantiene intacto el mega-cluster de 1,997 casos y produce ARI de 0.998 y 0.989 frente a la principal. Reducir `min_samples` a 10 aumenta la inclusion, cambia el mega-cluster a 2,065 casos y aun conserva ARI de 0.925 y 0.922. Por tanto, la solucion elegida funciona como referencia reproducible dentro de una familia de configuraciones HDBSCAN muy cercanas; no debe interpretarse como la unica particion territorial admisible.

Robustez de la solución espacial




Figura 17: Robustez de las configuraciones. Izquierda: equilibrio entre ruido y peso del cluster mayor. Derecha: estabilidad frente a parámetros próximos y perturbaciones de 25 m.

13.4 ARI entre particiones seleccionadas

El ARI compara pares de asignaciones completas y corrige la coincidencia esperada por azar. Toma valor 1 cuando las particiones son equivalentes, aunque sus etiquetas numericas sean distintas. La matriz confirma dos bloques HDBSCAN estrechamente relacionados y una referencia DBSCAN mas distante.

Cuadro 7: ARI entre la principal (P), referencia DBSCAN (D) y cuatro escenarios de sensibilidad (S1–S4).

	P	D	S1	S2	S3	S4
P	1.000	0.807	0.998	0.989	0.925	0.922
D	0.807	1.000	0.807	0.806	0.837	0.839
S1	0.998	0.807	1.000	0.992	0.923	0.920
S2	0.989	0.806	0.992	1.000	0.915	0.917
S3	0.925	0.837	0.923	0.915	1.000	0.992
S4	0.922	0.839	0.920	0.917	0.992	1.000

Aqui S1 y S2 corresponden a `min_samples=20` con tamaños minimos 20 y 30; S3 y S4 a `min_samples=10` con tamaños minimos 20 y 30. El ARI alto demuestra estabilidad global, pero puede estar influido por el mega-cluster. Al excluirlo, los ARI frente a S1–S4 son 0.986, 0.936, 0.806 y 0.787: la estructura restante sigue siendo consistente, aunque muestra mayor sensibilidad cuando cambia `min_samples`.

13.5 Jaccard, persistencia y establecimientos sensibles

Como las etiquetas de cluster son arbitrarias, cada cluster principal se emparejo con el cluster alternativo que maximiza

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

El Jaccard mide solapamiento local, complementando al ARI global. A partir de los cinco escenarios de contraste se calculo para cada establecimiento la proporcion de veces que permanecio en el cluster emparejado; para los puntos de ruido, la proporcion de veces que siguio siendo ruido. Se clasifico como **SENSIBLE** si la persistencia fue menor a 0.50, **ESTABLE** entre 0.50 y 0.79 y **NUCLEO_ROBUSTO** entre 0.80 y 1.00.

De los 4,365 establecimientos, 4,107 (94.1 %) son nucleos robustos, 94 (2.2 %) estables y 164 (3.8 %) sensibles. Los sensibles se concentran principalmente en bordes de agrupamientos, corredores de baja densidad y transiciones entre cluster y ruido. Esta localizacion es mas informativa que afirmar solamente un ARI alto: identifica los puntos cuya etiqueta debe tratarse con cautela en cualquier priorizacion posterior.

Persistencia territorial entre especificaciones




Figura 18: Persistencia de membresía entre la solución principal, escenarios de sensibilidad y referencia DBSCAN.

13.6 Perturbación posicional y límites de la selección

La prueba posicional generó tres réplicas desplazando independientemente cada coordenada en x y y mediante ruido normal $N(0, 25^2)$ m y volvió a ajustar el mismo modelo. Los ARI globales fueron 0.895, 0.892 y 0.989; al comparar solo puntos agrupados en ambas particiones aumentaron a 0.979, 0.979 y 1.000. Sin el mega-cluster fueron 0.864, 0.854 y 0.971. Esto indica que la mayor parte de los cambios inducidos por 25 m ocurre en la frontera entre ruido y cluster o en bordes locales, no en el núcleo de los grupos.

La partición seleccionada ofrece el mejor compromiso documentado bajo la regla adoptada, con una ventaja de puntaje mínima respecto de dos alternativas HDBSCAN. El mega-cluster aporta estabilidad global y requiere diagnóstico interno; 584 puntos quedan como actividad dispersa y no deben considerarse irrelevantes; y 164 establecimientos presentan membresía sensible. La solución es adecuada

como referencia operativa para perfilar concentraciones y comparar territorios, siempre conservando los escenarios alternativos y la persistencia por punto.

13.7 Glosario minimo de metricas

Metrica	Que responde	Precaucion interpretativa
ARI	¿Que tan similares son dos particiones completas, corrigiendo coincidencias esperadas por azar?	No dice que particion sea “verdadera” ni explica por si sola donde cambian las membresias.
Jaccard	¿Que tanto se solapan dos conjuntos/clusters comparables?	Requiere criterio de emparejamiento entre etiquetas arbitrarias.
Persistencia de membresia	¿Con que frecuencia un punto conserva una asignacion equivalente?	Depende del conjunto de escenarios comparados.
Proporcion de ruido	¿Que fraccion no es asignada a clusters bajo un escenario?	Mas ruido no es necesariamente peor; puede reflejar dispersion real.
Continuidad/compacidad	¿Que tan coherente es el cluster en el espacio?	Debe definirse exactamente la formula utilizada.
Efecto de borde	¿Cuanto cambia la estructura cerca del limite de estudio?	Un limite administrativo/hidrologico puede cortar una concentracion real.

14 Materializacion de clusters, borde y ruido

Preguntas guia

- ¿Cuantos clusters existen en el universo ampliado y cuantos intersectan/estan dentro de cuenca?
- ¿Como se definen las envolventes de cluster y que implicaciones tiene usar convex hull?
- ¿Cuantos establecimientos del mismo cluster quedan fuera de cuenca?
- ¿Donde se concentra el ruido y presenta patrones territoriales propios?

La solucion principal materializa **22 clusters** en el universo ampliado de 4,365 establecimientos. Cuatro de ellos (0–3) quedan completamente fuera de la cuenca y se conservan unicamente como contexto de deteccion; los **18 clusters 4–21** tienen al menos un integrante dentro del poligono y constituyen el conjunto interpretado. En el interior se asignaron 3,432 establecimientos a clusters y 578 quedaron como ruido: 85.6 % del universo interior fue agrupado y 14.4 % permanecio disperso. La Figura 19 muestra que ruido no equivale a ausencia de actividad, sino a unidades que no alcanzan la persistencia o densidad exigida por la configuracion principal.

Solución espacial principal: clusters dentro de la cuenca




Figura 19: Materialización territorial de la solución principal dentro de la cuenca. Los números identifican los clusters 4–21 y los puntos grises corresponden a actividad dispersa.

14.1 Envoltentes y efecto de borde

Para cada cluster se calculó una envoltente convexa o *convex hull*: el polígono convexo de menor superficie que contiene todos sus puntos. Esta geometría resume extensión y permite obtener una superficie descriptiva y una densidad bruta, pero puede incluir espacios sin establecimientos, unir brazos separados y atravesar municipios, cauces o infraestructura. En grupos casi lineales o con pocos puntos, superficie y densidad son especialmente sensibles a observaciones extremas; por ello el mapa de puntos y la ficha del atlas deben consultarse junto con la envoltente.

El universo ampliado evita cortar vecindades antes de estimar los clusters. De los 355 establecimientos exteriores, 309 integran los cuatro clusters completamente externos, 40 pertenecen al cluster 11 y seis son ruido. El cluster 11 es el unico agrupamiento interpretado que cruza el limite: posee 48 miembros, pero solo ocho estan dentro de la cuenca y 40 fuera. Su porcion interior representa apenas 16.7 % de la estructura detectada y debe leerse como concentracion de borde. Los otros 17 clusters interpretados estan completamente dentro.




Figura 20: Universo de detección (4,365 establecimientos) y universo de interpretación (4,010 dentro de la cuenca). Los 355 puntos exteriores estabilizan relaciones de vecindad, pero no amplían el ámbito sustantivo del estudio.

Cuadro 9: Descomposicion de la solucion principal respecto al limite de la cuenca.

Componente	Clusters	Dentro	Fuera	Total
Clusters 0–3, completamente exteriores	4	0	309	309
Cluster 11, que cruza el limite	1	8	40	48
Clusters interiores restantes	17	3,424	0	3,424
Ruido	—	578	6	584
Total	22	4,010	355	4,365

14.2 Distribucion territorial del ruido

El ruido interior comprende 578 establecimientos distribuidos en 18 municipios y 67 localidades. Su municipio y localidad modales son Puebla y Heroica Puebla de Zaragoza, pero el atlas muestra tambien una franja discontinua hacia el norponiente y puntos perifericos al sur. No conforma un unico vacio aleatorio: combina unidades aisladas, bordes de clusters, corredores demasiado tenues y establecimientos cuya membresia cambia con los parametros. Su persistencia media como ruido es 0.759, inferior a la de los nucleos mas robustos, por lo que una parte corresponde a transiciones cluster–ruido. No debe eliminarse del perfil economico ni interpretarse como actividad irrelevante.




Figura 21: Ficha del atlas para el ruido disperso. El mapa hace visible su patron territorial y el panel derecho confirma que conserva una composicion productiva interpretable.

Limite de interpretacion

Un poligono envolvente de cluster es una abstraccion geometrica para visualizar concentracion; no representa una zona de servicio, una subcuenca de drenaje ni un area juridica.

15 Perfil economico y productivo posterior al clustering

Principio: primero se fija la geografia; despues se pregunta que contiene cada agrupamiento.

Preguntas guia

- ¿Como se distribuyen SCIAN, municipios, localidades y estratos de personal por cluster?
- ¿Que señales productivas aparecen: confeccion, lavanderia, acabado, tela, mezclilla, otros?
- ¿Que porcentaje de cada cluster tiene evidencia hidrica SI, REVISAR o ausencia de evidencia explicita?
- ¿Que clusters parecen especializados y cuales diversificados?
- ¿Que diferencias existen entre cluster y ruido disperso?

El perfilado se aplico despues de congelar la membresia espacial. Para cada cluster y para el ruido se cruzaron actividad SCIAN, municipio, localidad, estrato de personal y etiquetas multilabel: lavanderia/tintoreria, confeccion, fabricacion de telas, tejido/hilado, acabado, maquila, mezclilla o pantalon, proceso humedo explicito y proceso seco explicito. Las etiquetas no son mutuamente excluyentes; un establecimiento puede aportar a varias columnas. Los porcentajes son prevalencias de señales y no deben sumarse como una particion exhaustiva.

15.1 Lectura territorial de los perfiles

El mapa posterior al clustering separa dos patrones dominantes. Doce clusters (4, 5, 6, 8, 9, 10, 11, 12, 13, 16, 17 y 19) se describen como concentraciones de manufactura. Seis (7, 14, 15, 18, 20 y 21) presentan coexistencia mixta entre manufactura y lavanderias. La clasificacion no intervino en la formacion de los grupos: se asigno al observar su contenido una vez fijada la geografia. El corredor norponiente contiene multiples nucleos manufactureros, mientras el sur metropolitano esta dominado por el gran cluster mixto 20.


Composición posterior: manufactura y lavanderías

Figura 22: Tipología productiva asignada despues del clustering. Azul: concentraciones de manufactura; morado: coexistencia de manufactura y lavanderias.

Los clusters mas grandes no son equivalentes. El cluster 8 concentra 337 establecimientos en Santa Ana Xalmimilulco: 92.0 % corresponde a manufactura textil, 85.8 % presenta señal de confeccion, 55.8 % de maquila y 40.7 % de mezclilla o pantalon. Es un nucleo especializado de confeccion y maquila asociado a prendas de mezclilla, aunque solo 8.0 % aparece como lavanderia/tintoreria. El cluster 20 contiene 1,997 establecimientos en seis municipios y 14 localidades: 59.3 % son lavanderias/tintorerias, 40.7 % manufactura y 15.7 % tiene evidencia humeda explicita. Su extension y mezcla justifican tratarlo como sistema metropolitano diversificado, no como un perfil uniforme.

Los clusters 7 y 15 muestran el equilibrio mixto con mayor claridad: en el 7, 44.4 % son lavanderias y 55.6 % manufactura; en el 15, 48.9 % y 51.1 %. Los clusters 18 y 21 tambien son mixtos, aunque menores. En contraste, 8, 12, 13, 17 y 19 superan 76 % en confeccion, mientras 9 y 10 se distinguen por

tejido/hilado. La Figura 23 compara estas especializaciones sin reducir cada cluster a una sola etiqueta.




Figura 23: Composicion multilabel de clusters interiores y ruido. Cada celda es el porcentaje del grupo que presenta la señal indicada; las columnas no son excluyentes.

15.2 Evidencia hidrica y escala laboral

La evidencia hidrica se reporta como variable descriptiva, no como criterio de clustering. En el cluster 20, 1.10 % queda en SI, 59.24 % en REVISAR y 39.66 % en SIN_EVIDENCIA; en el cluster 8 los valores son 1.78 %, 18.40 % y 79.82 %. Los clusters mixtos 7, 15, 18 y 21 presentan, respectivamente, 48.5 %, 48.9 %, 40.6 % y 41.9 % al combinar SI y REVISAR. En cambio, 6 y 9 tienen 100 % sin evidencia explicita y el 10 alcanza 95.8 %. “Sin evidencia” significa que las fuentes disponibles no contienen una señal textual o codificada suficiente; no demuestra ausencia de uso de agua ni de descarga.

En todos los grupos domina el estrato de 0 a 5 personas. Su participacion va de 51.4 % en el cluster 10 a 100 % en el cluster 6; alcanza 79.5 % en el cluster 8, 84.5 % en el 20 y 80.3 % en el ruido. Una concentracion grande puede estar compuesta principalmente por microunidades. Los estratos del DENUE son intervalos, no caudales, capacidad instalada ni volumen de produccion, por lo que no permiten convertir establecimientos en carga contaminante.

Grupo	n	0–5 pers.	Perfil territorial-productivo	Lav./tint.	Confec.	SI+REV.
C7 Huejotzingo	99	75.8 %	Mixto local	44.4 %	31.3 %	48.5 %
C8 Xalmimilulco	337	79.5 %	Confeccion–maquila–mezclilla	8.0 %	85.8 %	20.2 %
C10 Ixtapalucan	142	51.4 %	Tejido/hilado	3.5 %	0.7 %	4.2 %
C12 Tlalancaleca	224	88.8 %	Manufactura y confeccion	7.1 %	83.9 %	15.2 %
C13 Tlanalapan	149	87.9 %	Manufactura y confeccion	8.1 %	81.2 %	8.1 %
C15 Texmelucan	92	92.4 %	Coexistencia casi equilibrada	48.9 %	40.2 %	48.9 %
C20 zona metropolitana	1,997	84.5 %	Mixto, extenso y diversificado	59.3 %	20.9 %	60.3 %
Ruido disperso	578	80.3 %	Manufactura dispersa heterogenea	33.4 %	41.0 %	34.3 %

15.3 Atlas: contraste de casos representativos

El atlas es la unidad de consulta detallada: publica una ficha homogenea para cada cluster 4–21 y otra para el ruido, combinando mapa local, tamaño dentro y total, municipio/localidad dominante, persistencia, tipologia y prevalencia de señales. Las Figuras 24 y 25 muestran dos extremos. Xalmimilulco es compacto y especializado; el cluster 20 es extenso, de alta continuidad urbana y composicion mixta. La comparacion evita interpretar tamaño como sinonimo de homogeneidad.




Figura 24: Ficha del atlas del cluster 8, Santa Ana Xalmimilulco: concentracion compacta y perfil manufacturero de confeccion y maquila.




Figura 25: Ficha del atlas del cluster 20: estructura metropolitana extensa y coexistencia entre lavanderías y manufactura.

15.4 Clusters frente a actividad dispersa

El ruido tiene perfil propio y no es el negativo de los clusters. Frente a las unidades dispersas, la actividad agrupada registra aproximadamente 7.2 puntos porcentuales mas de lavandería/tintorería y 4.7 puntos mas de señal húmeda explícita; también aumenta la presencia de mezclilla o pantalón. En el ruido son relativamente mas frecuentes el proceso seco explícito (cerca de 7.9 puntos), el SCIAN textil general y la señal amplia de textil. La concentración selecciona con mayor frecuencia actividades de lavado y señales potencialmente hídricas, pero deja fuera numerosas microunidades manufactureras dispersas. Esto no autoriza a concluir que todo cluster descarga ni que el ruido carece de relevancia ambiental.




Figura 26: Diferencia de prevalencia entre establecimientos agrupados y actividad dispersa. Positivo indica mayor frecuencia en clusters; negativo, mayor frecuencia en ruido.

En síntesis, las concentraciones más especializadas se localizan en el corredor norponiente, con Xalmimilulco como caso destacado de confección, maquila y mezclilla; el cluster 20 constituye la mayor concentración mixta de lavanderías y manufactura. Los clusters 7 y 15 ofrecen escalas intermedias de coexistencia potencialmente abordables para validación de campo. El ruido conserva 578 establecimientos y un perfil manufacturero relevante, por lo que debe incorporarse mediante muestreo estratificado. Estas conclusiones describen estructura territorial y productiva registrada: para priorizar infraestructura todavía se requieren verificación de giros, consumo y descarga de agua, red de drenaje, topografía, caudales y calidad del efluente.

Información y evidencia mínima requerida

Para cada cluster publicar una ficha estándar: N, superficie/envolvente, municipio/localidad dominante, top SCIAN, distribución de personal, señales productivas, evidencia hídrica, distancia a red hidrográfica, estabilidad y notas de incertidumbre.

16 Sobrerrepresentación de señales

16.1 Base comparativa

Cada cluster se compara contra el **universo completo de 4,010 establecimientos dentro de la cuenca**, incluyendo unidades agrupadas y ruido. Para una señal s y un cluster g se calculan la prevalencia interna $p_{g,s} = n_{g,s}/n_g$, la prevalencia base $p_s = n_s/4,010$, la diferencia absoluta $p_{g,s} - p_s$ y

el *lift*

$$L_{g,s} = \frac{p_{g,s}}{p_s}.$$

Un *lift* superior a uno significa que la señal es relativamente mas frecuente en el cluster que en el universo interior; no significa que sea exclusiva del grupo ni que explique su formacion. Su lectura es multiplicativa: $L = 1$ indica la misma prevalencia que la base, $L = 1.5$ indica una frecuencia 1.5 veces mayor, $L = 2$ el doble y $L = 10$ diez veces la prevalencia base. Por ejemplo, el *lift* de 10.62 para tejido/hilado en el cluster 10 significa que esa señal aparece aproximadamente 10.6 veces con mayor frecuencia relativa que en el conjunto de la cuenca: 95.1 % frente a 9.0 %. Un *lift* menor que uno indica subrepresentacion.

La base descriptiva del *lift* es siempre el universo completo de **4,010 establecimientos dentro de la cuenca**, por lo que incluye al cluster evaluado. En cambio, Fisher y el odds ratio construyen el contraste entre el cluster y **el resto del universo**, excluyendo de ese segundo grupo a los miembros del propio cluster. Son contrastes relacionados, pero no identicos: el *lift* compara la prevalencia interna con la prevalencia global, mientras el OR compara momios internos contra externos. Incluir al propio cluster en la base global reduce el *lift* de los grupos grandes y vuelve conservadora su lectura, especialmente para el cluster 20, que contiene casi la mitad de los establecimientos interiores. Por ello se reportan tambien conteos, diferencia en puntos porcentuales, OR, intervalo y q ajustado.

16.2 Prueba estadística y criterio de reporte

Para cada par cluster–señal se construyo una tabla 2×2 : presencia/ausencia de la señal dentro del cluster y presencia/ausencia en el resto del universo. La prueba exacta bilateral de Fisher se usa como herramienta de contraste de asociacion dentro del universo observado y produce un *odds ratio* (OR). Un OR mayor que uno indica mayores momios dentro del cluster; su intervalo de confianza al 95 % se calculo con correccion de Haldane–Anscombe de 0.5 para mantener estimaciones finitas cuando existen celdas con cero. El *lift* compara prevalencias globales y el OR compara momios cluster–resto: ambos describen asociacion relativa, pero no son identicos ni expresan causalidad.

Como se contrastan simultaneamente 19 grupos —18 clusters y ruido— contra 18 señales, se realizaron **342 comparaciones**. Los valores p se ajustaron en conjunto mediante Benjamini–Hochberg (BH) para limitar la tasa esperada de falsos descubrimientos bajo este conjunto de contrastes. Un rasgo se conserva como evidencia descriptiva suficiente solamente si cumple simultaneamente: al menos cinco casos, prevalencia interna de 5 % o mas, *lift* de al menos 1.25 y $q \leq 0.05$. Fisher y BH ayudan a ordenar asociaciones observadas, pero **DENUE no es una muestra probabilística** y estas pruebas **no corrigen la dependencia espacial** entre establecimientos. En consecuencia, sus valores no autorizan inferencia poblacional general ni sustituyen relevancia practica, validacion de procesos o trabajo de campo.

16.3 Resultados de sobrerrepresentacion

Los resultados separan perfiles territoriales con significado productivo. El **cluster 8 es la concentracion de Santa Ana Xalmimilulco, municipio de Huejotzingo**, integrada por 337 establecimientos. Combina confeccion (85.8 % frente a 39.0 % en la cuenca; *lift* 2.20), maquila (55.8 % frente a 14.7 %; *lift* 3.80) y mezclilla o pantalon (40.7 % frente a 4.6 %; *lift* 8.91). En terminos directos, la señal de mezclilla o pantalon es casi nueve veces mas frecuente en este cluster que en el universo interior. La coexistencia de diferencias absolutas grandes, 137–289 casos por señal y valores q extremadamente pequeños muestra que Xalmimilulco no es solamente una acumulacion espacial: es una concentracion especializada en confeccion, maquila y prendas asociadas con mezclilla.

Los **clusters 9 y 10 se localizan en el municipio de Tlahuapan**. El cluster 9 corresponde principalmente a **San Miguel Tianguistenco** y contiene 30 establecimientos; el cluster 10 corresponde

a **San Rafael Ixtapalucan** y contiene 142. Ambos muestran especializacion en tejido/hilado: la señal aparece en 80.0 % del cluster 9 y 95.1 % del cluster 10, frente a 9.0 % en la cuenca. Sus lifts de 8.94 y 10.62 indican que tejido/hilado es aproximadamente nueve y once veces mas frecuente, respectivamente, que en la base regional. El resultado no significa que produzcan nueve u once veces mas volumen, sino que la *proporcion de establecimientos etiquetados* con esa actividad es mucho mayor.

El **cluster 6 corresponde a Santiago Coltzingo, municipio de Tlahuapan**, y contiene 20 establecimientos. Dieciseis presentan señal de maquila: 80.0 % frente a 14.7 % en la cuenca, con lift 5.45. Esto significa que la prevalencia relativa de maquila es alrededor de 5.5 veces la regional. Es una especializacion estadisticamente clara, pero su base absoluta es pequeña; por ello representa una hipotesis focal para verificacion de campo y no, por si sola, una justificacion de infraestructura. Los clusters 4 y 5 tambien muestran maquila y confeccion, aunque sus tamaños reducidos exigen la misma cautela.

Los clusters 12, 13, 17 y 19 comparten sobrerrepresentacion de confeccion; 12 y 13 agregan proceso seco explicito, mientras 19 incorpora produccion y maquila. En el cluster 20 se sobrerrepresentan lavanderia/tintoreria (59.3 % frente a 39.6 %), lavado generico (43.6 % frente a 29.9 %) y humedo explicito (15.7 % frente a 9.2 %). Sus lifts son mas moderados que los del tejido o la mezclilla, pero se apoyan en cientos de casos: 1,185 registros sectoriales de lavanderia/tintoreria, 871 señales de lavado y 313 de proceso humedo. Esta escala absoluta le confiere importancia operativa, pero **lavanderia/tintoreria es una categoria sectorial/SCIAN y no equivale a lavanderia industrial verificada**.

Sensibilidad interpretativa del cluster 20. Sin modificar su membresia, se contrastaron etiquetas superpuestas ya existentes. De sus 1,997 establecimientos, 1,185 (59.3 %) pertenecen al SCIAN de lavanderia/tintoreria; 335 (16.8 %) sobreviven el universo estricto con MH; 22 (1.1 %) tienen *evidencia_hidrica=SI*; 1,205 (60.3 %) tienen SI o REVISAR; 313 (15.7 %) presentan señal de humedo explicito; y 871 (43.6 %) lavado generico contextualizado. Las categorias no son excluyentes y sus conteos no deben sumarse. El contraste muestra que la señal sectorial amplia es mucho mayor que la evidencia humeda explicita o confirmada: sirve para priorizar verificacion, no para afirmar que existan 1,185 lavanderias industriales.

Cuadro 11: Rasgos representativos que superan los criterios conservadores de sobrerrepresentacion.

Cluster	Señal	N cluster	N señal	% cluster	% base	Dif. pp	Lift	OR	IC 95 % OR	q_{BH}
C10	Tejido/hilado	142	135	95.1	9.0	86.1	10.62	313.74	[138.89, 619.34]	8.18×10^{-141}
C9	Tejido/hilado	30	24	80.0	9.0	71.0	8.94	43.52	[17.12, 97.95]	1.27×10^{-19}
C6	Maquila	20	16	80.0	14.7	65.3	5.45	23.85	[7.68, 62.20]	6.89×10^{-10}
C8	Confeccion	337	289	85.8	39.0	46.8	2.20	11.35	[8.24, 15.37]	3.41×10^{-75}
C8	Maquila	337	188	55.8	14.7	41.1	3.80	10.30	[8.10, 13.04]	1.19×10^{-76}
C8	Mezclilla/pantalon	337	137	40.7	4.6	36.1	8.91	54.01	[37.26, 76.81]	7.65×10^{-117}
C12	Confeccion	224	188	83.9	39.0	45.0	2.15	9.17	[6.32, 13.00]	1.44×10^{-44}
C13	Proceso seco	149	71	47.7	16.1	31.6	2.97	5.22	[3.75, 7.28]	2.79×10^{-19}
C19	Confeccion	100	76	76.0	39.0	37.0	1.95	5.17	[3.22, 8.06]	3.62×10^{-13}
C20	Lavanderia/tintoreria	1,997	1,185	59.3	39.6	19.8	1.50	5.87	[5.09, 6.75]	2.18×10^{-146}
C20	Humedo explicito	1,997	313	15.7	9.2	6.4	1.70	6.38	[4.74, 8.45]	3.92×10^{-47}




Figura 27: Rasgos sobrerepresentados que cumplen tamaño mínimo, prevalencia, lift y corrección por pruebas múltiples. El color representa $\log_2(\text{lift})$: un valor de 1 equivale a dos veces la prevalencia base y un valor de 2 a cuatro veces. Las celdas blancas no satisfacen todos los criterios.

La significancia no sustituye la relevancia práctica. Por ejemplo, los clusters 6 y 9 exhiben asociaciones muy fuertes, pero contienen solo 20 y 30 establecimientos; son buenos candidatos para una inspección focalizada, no evidencia suficiente para dimensionar infraestructura. El cluster 20 tiene lifts menores porque su propio tamaño eleva la prevalencia base, pero concentra el mayor número absoluto de señales hídricas. Finalmente, una señal sobrerepresentada proviene de SCIAN o texto comercial: identifica una hipótesis productiva y no verifica proceso real, consumo, descarga ni contaminante.

Información y evidencia mínima requerida

Nunca presentar solo significancia. Reportar para cada señal: n cluster, n señal, proporción cluster, proporción base, diferencia absoluta, lift, odds ratio, intervalo si se calcula, p , q ajustado y una nota de relevancia práctica.

17 Similitud entre clusters y tipologías productivas

Preguntas guía

- ¿Que variables entran al vector de perfil?
- ¿Como se escalan o ponderan variables con naturalezas distintas?
- ¿Que distancia se usa y por que?
- ¿La tipología jerárquica representa similitud productiva, no proximidad espacial?
- ¿Que pares de clusters son mas parecidos y en que dimensiones?

17.1 Construcción del vector y distancia combinada

La comparación se realiza después del clustering y excluye el ruido: cada uno de los 18 clusters interiores se representa mediante prevalencias entre cero y uno. El archivo auditable de vectores contiene 18 señales multilabel, cuatro proporciones SCIAN a tres dígitos (313, 314, 315 y 812) y siete estratos de personal. Sin embargo, la distancia utilizada en la tipología actual incorpora solamente dos familias: señales y SCIAN. Los estratos de personal se conservaron para auditoría y descripción, pero **no entran en la distancia combinada**; esto evita afirmar que la tipología resume una dimensión que el código no pondera.

Para las señales se utiliza distancia coseno,

$$d_{\cos}(i, j) = 1 - \frac{\mathbf{s}_i \cdot \mathbf{s}_j}{\|\mathbf{s}_i\| \|\mathbf{s}_j\|},$$

que compara el patrón relativo de prevalencias y reduce la influencia de la magnitud total. Para la composición SCIAN se usa la distancia de Jensen–Shannon entre distribuciones, una medida simétrica y acotada basada en divergencia informativa. Se añade 10^{-12} a cada categoría para evitar problemas numéricos con ceros. Como ambas familias ya son proporciones, no se aplica estandarización z ; la distancia final les asigna el mismo peso:

$$d(i, j) = 0.5 d_{\cos}(\mathbf{s}_i, \mathbf{s}_j) + 0.5 d_{JS}(\mathbf{c}_i, \mathbf{c}_j).$$

Por tanto, el resultado depende explícitamente de una decisión normativa: señales textuales/codificadas y estructura SCIAN aportan la mitad cada una.

17.2 Tipología jerárquica y resultados

La matriz combinada se agrupa mediante enlace promedio. Con 18 clusters se definieron cuatro tipos exploratorios, siguiendo $k = \text{round}(\sqrt{18}) = 4$. Las etiquetas 1–4 son identificadores sin orden sustantivo. Esta tipología expresa **similitud productiva entre clusters espacialmente distintos**; no fusiona membresías, no mide proximidad geográfica y no modifica la solución HDBSCAN.

Cuadro 12: Tipología exploratoria derivada de los perfiles combinados.

Tipo	Clusters	Lectura dominante
1	7, 14, 15, 18, 20, 21	Coexistencia de lavanderias y manufactura; incluye el sistema metropolitano y nucleos mixtos menores.
2	9, 10	Especializacion muy marcada en tejido e hilado.
3	4, 5, 8, 11, 12, 13, 16, 17, 19	Manufactura orientada a confeccion y, en varios casos, maquila, mezcilla o proceso seco.
4	6	Perfil singular de maquila con 100% SCIAN textil y tamaño reducido; queda separado de los otros grupos bajo el corte elegido.

Los pares mas cercanos confirman la coherencia de estos tipos. Los clusters 14 y 18 tienen la menor distancia (0.029) y comparten perfiles mixtos pequeños; 4 y 13 alcanzan 0.042 y 12 y 13, 0.045, todos dentro del bloque manufacturero. Los clusters 16 y 19 tienen distancia 0.055 y 7 y 21, tambien 0.055. Xalmimilulco (8) se aproxima a 12 (0.060), seguido de 4 (0.076) y 19 (0.087), por la combinacion de confeccion, maquila y estructura SCIAN. Los clusters 9 y 10 forman su propio par especializado (0.091). En el tipo mixto, el cluster 20 es mas semejante a 7 (0.082) que a los nucleos manufactureros; ello muestra que la composicion puede relacionar territorios alejados.




Figura 28: Matriz de distancia productiva combinada entre clusters. Los tonos claros indican mayor similitud; la diagonal vale cero. La matriz compara perfiles posteriores y no distancias geograficas.

La lectura por familias evita confundir mecanismos. Dos clusters pueden ser similares porque comparten señales aunque difieran en SCIAN, o viceversa; por eso se conservaron la matriz combinada, los vectores originales y el enlace jerarquico. La tipologia es descriptiva y sensible al peso 50/50, al corte en cuatro tipos y a la exclusion actual del personal. Antes de convertirla en estratos de muestreo definitivos conviene repetirla variando pesos, incorporando personal como tercera familia y comprobando si los pares principales permanecen estables.

Requisitos de trazabilidad

Conservar matrices de distancia por familia de variables y una matriz combinada. Asi puede auditarse si la similitud es impulsada por SCIAN, señales, personal o composicion territorial.

18 Mega-cluster y subnucleos exploratorios

Hechos ya identificados en el repositorio

El inventario reporta un cluster mayor de 1,997 establecimientos. La segunda pasada estudia subnucleos de forma diagnostica, sin reemplazar la membresia principal congelada.

Preguntas guía

- ¿Por que el mega-cluster aparece como una sola estructura con la configuracion principal?
- ¿Que subnucleos espaciales se observan internamente y cuantos establecimientos contiene cada uno?
- ¿Cuales son sus municipios/localidades, composicion productiva y señales hídricas?
- ¿Son los subnucleos estables a parametros razonables o solo una particion ilustrativa?
- ¿Alguno coincide con barreras/continuidades urbanas o hidrologicas que deban estudiarse posteriormente?

18.1 Por que aparece una sola estructura

El cluster 20 contiene 1,997 establecimientos, todos dentro de la cuenca, distribuidos en seis municipios y 14 localidades. Su probabilidad media de pertenencia es 0.990 y su persistencia media frente a escenarios alternativos es 0.999. Aparece como una sola estructura porque la solución principal HDBSCAN con selección EOM privilegia ramas densas que mantienen suficiente continuidad espacial a una escala regional. En Puebla, Cholula y Cuautlancingo existen máximos locales, pero entre ellos permanecen cadenas y bandas de establecimientos que impiden una separación estable bajo la configuración principal. Los diagnósticos KDE y hexagonales de la Sección 11 mostraron el mismo fenómeno: a escala fina existen focos y vacíos, mientras a 1,000–2,000 m se integran en un continuo metropolitano.

La gran extensión no significa homogeneidad. La envolvente convexa alcanza 265.29 km², el cluster abarca Puebla, San Andrés Cholula, San Pedro Cholula, Cuautlancingo, Amozoc y Coronango, y su perfil combina 59.3 % de lavanderías/tintorerías con 40.7 % de manufactura. Por ello se realizó una segunda pasada exclusivamente diagnóstica sobre sus coordenadas, sin alterar la etiqueta 20 de la solución congelada.

18.2 Segunda pasada y subnucleos observados

La exploración interna utilizó HDBSCAN con `min_cluster_size=30`, `min_samples=10` y selección *leaf*. Esta configuración favorece ramas locales más finas que EOM. Identifiqué 18 subnucleos con 1,108 establecimientos; 889 puntos, equivalentes a 44.5 % del cluster, no alcanzaron la densidad local necesaria y quedaron como ruido *solo en esta segunda pasada*. Los 1,997 continúan perteneciendo al cluster 20 principal.




Figura 29: Dieciocho subnúcleos exploratorios del cluster 20. Los puntos grises no se asignan a una rama local bajo la especificación *leaf*, pero conservan su membresía en el mega-cluster principal.

Los subnúcleos 0–5 describen principalmente el sistema Cholula–Tlaxcalancingo–Momoxpan y los subnúcleos 6–17 distintos focos de Heroica Puebla de Zaragoza. Sus tamaños varían entre 30 y 112 establecimientos; ninguno concentra por sí solo más de 5.7 % del mega-cluster. Esta fragmentación, junto con el 44.5 % no asignado internamente, indica heterogeneidad local, pero también ausencia de una partición exhaustiva y naturalmente separada.

Cuadro 13: Geografía y señales seleccionadas de los 18 subnúcleos diagnósticos.

ID	<i>n</i>	% mega	km ²	Localidad dominante	Lav. %	Hum. %
0	31	1.6	0.89	San Andres Cholula	83.9	16.1
1	76	3.8	4.38	Cholula de Rivadavia	59.2	19.7
2	46	2.3	4.14	Heroica Puebla de Zaragoza	80.4	23.9
3	57	2.9	2.91	San Bernardino Tlaxcalancingo	75.4	19.3
4	92	4.6	9.94	Heroica Puebla de Zaragoza	58.7	6.5
5	93	4.7	8.37	Santiago Momoxpan	57.0	12.9
6	58	2.9	4.51	Heroica Puebla de Zaragoza	60.3	15.5

ID	<i>n</i>	% mega	km ²	Localidad dominante	Lav. %	Hum. %
7	41	2.1	2.02	Heroica Puebla de Zaragoza	58.5	14.6
8	36	1.8	1.74	Heroica Puebla de Zaragoza	50.0	5.6
9	65	3.3	2.86	Heroica Puebla de Zaragoza	53.8	10.8
10	33	1.7	1.65	Heroica Puebla de Zaragoza	57.6	24.2
11	74	3.7	3.75	Heroica Puebla de Zaragoza	59.5	16.2
12	112	5.6	6.56	Heroica Puebla de Zaragoza	60.7	16.1
13	97	4.9	4.69	Heroica Puebla de Zaragoza	44.3	14.4
14	78	3.9	3.19	Heroica Puebla de Zaragoza	39.7	19.2
15	54	2.7	2.16	Heroica Puebla de Zaragoza	70.4	13.0
16	30	1.5	1.18	Heroica Puebla de Zaragoza	30.0	10.0
17	35	1.8	1.33	Heroica Puebla de Zaragoza	62.9	14.3

El perfilado posterior confirma diferencias internas. Los subnucleos 0, 2 y 3 superan 75 % en lavandería/tintorería; 10 alcanza la mayor señal húmeda explícita (24.2 %), seguido de 2 (23.9 %). Los subnucleos 14 y 16 muestran mayor peso relativo de confección, con 37.2 % y 36.7 %, y menor lavandería que el promedio del cluster. Estas diferencias sirven para diseñar recorridos y estratos de muestreo, no para inferir descargas verificadas.

18.3 Estabilidad y relación con barreras territoriales

La membresía del cluster 20 principal es muy estable, pero **los 18 subnucleos no cuentan todavía con una prueba equivalente de estabilidad**. Proviene de una sola especificación *leaf*; no se compararon sistemáticamente otros tamaños mínimos, valores de `min_samples` ni perturbaciones posicionales para cada rama. Por tanto deben considerarse una partición ilustrativa de la heterogeneidad interna. El porcentaje no asignado de 44.5 % refuerza esta cautela.

El mapa sugiere continuidades urbanas entre Puebla, Cholula, Cuautlancingo y Amozoc, pero este análisis no incorpora vialidades, relieve, colectores, parteaguas urbanos ni cauces como variables de separación. En consecuencia, no puede afirmarse que los límites entre subnucleos coincidan con barreras hidrológicas o de drenaje. La siguiente validación debe superponer medoides y envoltorios con topografía, red sanitaria, cruces de cauce, puntos de descarga y capacidad de conducción antes de proponer unidades operativas.

Limite de interpretacion

Los subnucleos diagnosticos no deben convertirse automaticamente en “proyectos de colector”. Son hipotesis de concentracion que necesitan contrastarse con topografia, drenaje existente, puntos de descarga y caudales.

19 Resultados principales por territorio

Esta sección traduce el pipeline a hallazgos espaciales concretos. Los conteos se refieren al universo sectorial dentro de la cuenca y las prevalencias productivas son etiquetas posteriores al clustering. La prioridad que se presenta es de **validación territorial**; no es un ranking de inversión.

19.1 Resultados a escala de cuenca

De los 4,010 establecimientos interiores, 3,432 (85.6 %) pertenecen a 18 clusters y 578 (14.4 %) permanecen dispersos. La estructura regional tiene tres niveles: un continuo metropolitano dominante de 1,997 establecimientos; un corredor norponiente fragmentado en núcleos manufactureros y mixtos; y actividad dispersa en 18 municipios. Los mapas de las Figuras 19 y 22 muestran que el tamaño no determina el perfil: el cluster 20 es mixto y dominado por lavanderías, mientras Xalmimilulco, Tlalancaleca, Tlanalapan e Ixtapalucan presentan especializaciones manufactureras diferentes.

Las concentraciones principales por tamaño son: cluster 20 (1,997), Xalmimilulco/cluster 8 (337), Tlalancaleca/cluster 12 (224), Tlanalapan/cluster 13 (149) e Ixtapalucan/cluster 10 (142). Por señal hídrica y coexistencia destacan 20, 15, 7, 21 y 18. Por especialización productiva destacan 8 en confección–maquila–mezclilla, 9–10 en tejido/hilado y 12–13 en confección y proceso seco. Estas categorías responden preguntas distintas: tamaño identifica volumen de unidades para investigar; prevalencia hídrica orienta verificación de procesos; especialización ayuda a diseñar instrumentos de campo y muestreo.

19.2 Resultados por municipio

Puebla contiene 1,762 establecimientos, 43.9 % del universo interior, y 1,610 agrupados en el cluster 20. Huejotzingo reúne 451 unidades y la mayor proporción agrupada entre los municipios grandes (96.7 %), repartida principalmente entre el cluster mixto 7 y Xalmimilulco/cluster 8. San Martín Texmelucan contiene 459 unidades y cuatro clusters, lo que lo convierte en el territorio con mayor diversidad de núcleos interpretados. Tlalancaleca e Ixtapalucan/Tlahuapan representan especializaciones manufactureras compactas.

Cuadro 14: Municipios principales del universo sectorial dentro de la cuenca.

Municipio	<i>n</i>	Agr. %	Clusters	Lav. %	Conf. %	SI+REV. %	Persist. %
Puebla	1,762	91.4	1	56.0	23.2	57.0	97.5
San Martín Texmelucan	459	68.8	4	21.1	68.8	21.6	89.8
Huejotzingo	451	96.7	2	16.0	71.6	25.9	98.8
San Matías Tlalancaleca	247	100.0	2	6.9	83.4	13.8	100.0
Tlahuapan	228	88.2	4	4.4	11.4	5.3	93.9
San Andrés Cholula	199	71.9	1	68.8	12.6	68.8	92.6
San Pedro Cholula	160	82.5	1	58.1	18.8	60.6	98.8
Cuahtlancingo	132	81.8	2	62.9	20.5	63.6	86.7
Amozoc	96	81.2	3	39.6	29.2	40.6	94.0
San Miguel Xoxtla	68	100.0	1	10.3	70.6	10.3	99.4

No se reporta aquí una “densidad municipal” porque el denominador territorial pertinente no se definió: dividir por toda la superficie administrativa penalizaría municipios extensos y no representaría suelo urbano o industrial disponible. Las densidades convexas se mantienen a escala de cluster y también son descriptivas. Para comparación municipal futura debe definirse un denominador común, como superficie urbanizada, corredor industrial o área efectivamente servida por drenaje.

19.3 Resultados por localidad/corredor

La escala de localidad revela prioridades que el total municipal oculta. Heroica Puebla de Zaragoza domina por tamaño y perfil de lavandería; Santa Ana Xalmimilulco es el núcleo manufacturero especializado más grande; San Matías Tlalancaleca y San Rafael Tlanalapan concentran confección; San Rafael Ixtapalucan concentra tejido/hilado. Huejotzingo cabecera y San Martín Texmelucan presentan coexistencia más equilibrada entre manufactura y lavanderías.

Cuadro 15: Localidades principales para lectura territorial y validacion.

Localidad	n	Agr. %	Lav. %	Conf. %	Hum. %	SI+REV. %
Heroica Puebla de Zaragoza	1,696	94.8	57.1	22.4	15.5	58.1
Santa Ana Xalmimilulco	337	100.0	8.0	85.8	1.5	20.2
San Matias Tlalancaleca	223	100.0	7.2	84.3	0.0	14.8
San Martin Texmelucan de Labastida	195	70.8	35.9	54.4	4.1	35.9
San Rafael Tlanalapan	143	88.8	9.8	79.7	0.0	9.8
San Rafael Ixtapalucan	142	100.0	3.5	0.7	2.1	4.2
Cholula de Rivadavia	118	79.7	64.4	17.8	17.8	65.3
San Bernardino Tlaxcalancingo	112	68.8	68.8	14.3	18.8	68.8
Santa Maria Moyotzingo	90	56.7	14.4	73.3	1.1	16.7
Huejotzingo	71	100.0	47.9	40.8	7.0	52.1
San Miguel Xoxtla	68	100.0	10.3	70.6	1.5	10.3
San Juan Cuautlancingo	54	100.0	79.6	13.0	11.1	79.6




Figura 30: Prevalencia de lavandería/tintorería en los 18 clusters interiores. El umbral de 80 % es descriptivo; ningún cluster lo alcanza, aunque el cluster 20 lidera por prevalencia y, sobre todo, por 1,185 casos.

19.4 Huejotzingo y Santa Ana Xalmimilulco

Huejotzingo y Santa Ana Xalmimilulco se mantienen como caso detallado porque fueron el punto de partida de la versión 1, donde se realizó auditoría manual y se construyeron tablas trazables para relacionar observaciones de campo, MH y claves DENUÉ cuando existía correspondencia. En el análisis

regional actual, Huejotzingo contiene 451 establecimientos sectoriales: 436 se agrupan en dos clusters. El cluster 7 reúne 99 unidades y representa coexistencia mixta en la cabecera y localidades proximas; el cluster 8 contiene los 337 establecimientos de Santa Ana Xalmimilulco y constituye una concentracion manufacturera compacta.

Xalmimilulco conserva una señal territorial fuerte bajo la definicion sectorial regional: 100 % de sus 337 unidades queda agrupado, su persistencia es 1.00 y se sobrerrepresentan confeccion, maquila y mezclilla/pantalón. Lo que no puede afirmarse es que los mismos 337 establecimientos pertenezcan al universo hidrico estricto. La comparacion legacy–estricto y la fuente MH responden otra pregunta: identificar unidades con evidencia mas directa o con validacion de campo. El clustering regional utiliza deliberadamente el universo sectorial para no excluir pequeñas lavanderias industriales o talleres cuyo uso de agua no aparece en el nombre o SCIAN.

Preguntas guía

- ¿Que hallazgos sobreviven a cambios de filtro y parametros?
- ¿Cuales dependen de registros dudosos o revisiones manuales?
- ¿Que concentraciones tienen evidencia suficiente para visita de campo prioritaria?

Los hallazgos que sobreviven a cambios razonables de parametros son la existencia de una concentracion compacta en Xalmimilulco, el predominio manufacturero del corredor norponiente y la continuidad metropolitana del cluster 20. En Xalmimilulco, la membresia territorial completa y la sobrerrepresentacion productiva son robustas dentro del universo sectorial. En cambio, la clasificacion individual como proceso hidrico depende de texto, SCIAN, MH y auditoria manual; los registros sin evidencia explicita y las coincidencias no enlazadas a un ID DENUÉ requieren revision y no deben contarse como descarga confirmada.

La visita de campo debe priorizar preguntas diferentes por territorio. En Xalmimilulco/cluster 8 debe verificarse el eslabon entre confeccion, maquila, mezclilla y operaciones de lavado o limpieza no registradas. En San Rafael Ixtapalucan y San Miguel Tianguistenco (clusters 10 y 9) debe comprobarse el proceso real asociado con tejido/hilado. En Santiago Coltzingo/cluster 6 debe validarse la señal de maquila pese a su reducido tamaño. Para procesos potencialmente humedos deben estratificarse el cluster 20 por sus subnucleos, Huejotzingo/cluster 7 y Texmelucan/cluster 15. Esta priorizacion organiza recorridos, entrevistas, aforos y muestreo; no selecciona todavia trazos de colector.

20 Siguiendo pasos y aportaciones

Este proyecto convierte un directorio de establecimientos en una base territorial auditable para decidir **donde investigar primero**. La aportacion principal no es un trazo de colector, sino una forma reproducible de pasar del universo economico a concentraciones espaciales, describir el perfil productivo de cada concentracion y reconocer que resultados son robustos, sensibles o todavia inciertos. El resultado reduce un territorio regional amplio a zonas y preguntas de campo concretas, sin confundir proximidad, actividad registrada o cercania a rios con una descarga comprobada.

20.1 Que se gana con el analisis

Se obtiene, primero, un **denominador conocido**: 4,365 establecimientos para deteccion y 4,010 para interpretacion dentro de la cuenca. Segundo, se obtiene una geografia comparable de 18 concentraciones interiores y 578 unidades dispersas. Tercero, cada concentracion deja de ser solamente un conjunto de puntos: se caracteriza por SCIAN, municipio, localidad, tamaño laboral, confeccion, tejido, maquila,

mezclilla, lavandería y evidencia hídrica. Cuarto, se cuantifica incertidumbre mediante escenarios alternativos, ARI, Jaccard, persistencia, perturbación posicional, efecto de borde, ruido y pruebas de sobrerrepresentación.

Esto cambia la capacidad de decisión. Antes se conocían establecimientos individuales y algunos casos locales; ahora pueden reconocerse sistemas territoriales distintos: Xalmimilulco como concentración de confección–maquila–mezclilla; Ixtapalucan y Tianguistenco como núcleos de tejido/hilado; Huejotzingo y Texmelucan como zonas de coexistencia; y el cluster metropolitano 20 como una estructura extensa con predominio de lavanderías y subnúcleos internos. La actividad dispersa también queda documentada y puede incorporarse a un muestreo estratificado.

20.2 Como acceder a los resultados en este reporte

Cuadro 16: Guía de lectura y localización de resultados.

Secciones	Contenido	Uso en la siguiente etapa
4–10	Universos, filtros, auditoría legacy, MH y transición regional	Saber que entra, que se excluye y con qué nivel de evidencia.
11	Diagnóstico espacial, k-NN, KDE, hexágonos y borde	Reconocer escalas de concentración y heterogeneidad territorial.
12–13	Experimentos, selección y estabilidad del clustering	Elegir una partición reproducible y localizar membresías sensibles.
14	Clusters, envolventes, borde y ruido	Ubicar concentraciones y actividad dispersa sin tratarlas como zonas de servicio.
15	Perfil económico y productivo	Saber qué actividades contiene cada concentración.
16	Sobrerrepresentación	Identificar especializaciones relativas y su soporte estadístico.
17	Similitud y tipologías	Comparar territorios alejados con perfiles productivos semejantes.
18	Mega-cluster y subnúcleos	Diseñar estratos de recorrido dentro del continuo metropolitano.
19	Resultados por cuenca, municipio y localidad	Seleccionar zonas y preguntas prioritarias para verificación.
20	Aportaciones, archivos y secuencia siguiente	Conectar el diagnóstico con hidrología, drenaje, tratamiento y decisión.

20.3 Donde están guardados los datos relevantes

Todas las rutas siguientes son relativas a la raíz del repositorio. Los CSV pueden abrirse en una hoja de cálculo o en Python/R; los GPKG en QGIS/ArcGIS o mediante GeoPandas; los JSON en un editor de texto; y el HTML interactivo en un navegador. El archivo `docs/INVENTARIO_GENERAL_PROYECTO.md` ofrece una entrada general, mientras `docs/parte_2/trazabilidad/` documenta scripts y productos de la fase de clustering.

Cuadro 17: Productos del repositorio para las proximas etapas.

Ruta	Contenido	Uso siguiente
outputs/parte_2/01_matriz/matriz_maestra_establecimientos.csv	Universo analítico integrado, IDs, coordenadas y señales	Base para campo, nuevas variables y cruces institucionales.
outputs/parte_2/02_geometrias/establecimientos_parte2.gpkg	Establecimientos georreferenciados	Cruce GIS con hidrología, drenaje, relieve y plantas.
outputs/parte_2/02_geometrias/contexto_parte2.gpkg	Cuenca y contexto territorial utilizado	Mantener límites y CRS consistentes.
outputs/parte_2/05_seleccion/persistencia_establecimientos.csv	Estabilidad por establecimiento	Separar núcleos robustos de puntos sensibles en campo.
outputs/parte_2/06_clusters/solucion_principal.gpkg	Membresías y geometría de la solución elegida	Unidad principal para superposiciones espaciales.
outputs/parte_2/06_clusters/resumen_clusters_borde.csv	Conteos dentro/fuera y cruce del límite	Controlar efecto de borde en nuevas capas.
outputs/parte_2/07_perfiles/establecimientos_perfilados_cuenca.csv	Registro interior con cluster y perfil productivo	Preparar directorios de visita y estratos de muestreo.
outputs/parte_2/07_perfiles/perfiles_clusters.csv	Resumen productivo de clusters	Comparar necesidades de verificación por zona.
outputs/parte_2/07_perfiles/composicion_municipal.csv y composicion_localidad.csv	Distribución territorial	Enlace con autoridades y planeación local.
outputs/parte_2/08_sobrerrepresentacion/sobrerrepresentacion_senales.csv	Lift, OR, Fisher y BH	Seleccionar especializaciones que requieren instrumentos de campo distintos.
outputs/parte_2/11_cierre/fichas_resumen_clusters.csv	Ficha compacta por cluster	Tabla de entrada para priorización de validación.
outputs/parte_2/11_cierre/diagnostico_mega_cluster.gpkg	Puntos, subnúcleos y hexágonos del cluster 20	Planear recorridos metropolitanos sin redefinir membresía.

Ruta	Contenido	Uso siguiente
outputs/parte_2/11_cierre/validacion_final.csv y inventario_cierre.csv	Pruebas e hashes de productos	Verificar integridad antes de entregar o actualizar.
outputs/parte_2/12_atlas/	Fichas PNG por cluster y ruido	Consulta visual rapida y comunicacion con campo.
outputs/parte_2/14_segunda_pasada/subnucleos_mega_cluster_documentados.csv	Geometria y perfil de 18 subnucleos	Estratificacion exploratoria de visitas en el cluster 20.
outputs/parte_2/14_segunda_pasada/explorador_interactivo_clusters.html	Explorador interactivo	Revision visual de establecimientos y agrupamientos.
outputs/cuenca_alto_atoyac_puebla_estricto_mh/tables/	Universo estricto con integracion MH y auditoria	Contrastar evidencia hidrica y observaciones de campo.
outputs/xalmimilulco/ y outputs/huejotzingo/	Productos locales y comparaciones legacy	Conservar la trazabilidad de la fase inicial.

20.4 Integracion con hidrologia, drenaje y plantas de tratamiento

El valor de las concentraciones surge al combinarlas con la infraestructura y el funcionamiento real del agua. La membresia espacial indica donde hay proximidad entre establecimientos; el perfil productivo indica que procesos conviene verificar; la hidrologia aporta cauces, subcuencas y receptores; la topografia y la red de drenaje determinan rutas posibles, pendientes, bombeo y conectividad; las plantas de tratamiento aportan ubicacion, capacidad disponible, tecnologia y compatibilidad con efluentes textiles. Ninguna de estas capas sustituye a las otras.

La integracion recomendada sigue esta secuencia:

1. Superponer `solucion_principal.gpkg` con red sanitaria, colectores, atarjeas, pozos de visita, plantas, cauces, modelo de elevacion y limites operativos.
2. Delimitar areas realmente tributarias por gravedad y separar establecimientos cercanos en linea recta pero desconectados hidraulicamente.
3. Verificar en campo actividad, proceso, punto y forma de descarga, horario, produccion, pretratamiento y estado operativo.
4. Aforar y muestrear por estratos productivos: lavanderia/acabado, confeccion-maquila-mezclilla, tejido/hilado y actividad dispersa.
5. Estimar caudales y cargas por zona validada, con incertidumbre y escenarios de conexion.
6. Comparar capacidad y compatibilidad de las plantas existentes antes de plantear ampliacion, pretratamiento o nueva infraestructura.
7. Formular alternativas de conduccion y tratamiento; evaluar CAPEX, OPEX, riesgo, beneficio ambiental, poblacion expuesta, permisos y gobernanza.

El producto final de esa integracion sera una estrategia territorial: que zonas requieren inspeccion inmediata, donde conviene muestrear, que concentraciones pueden compartir una solucion, cuales necesitan pretratamiento, que planta podria recibirlas y que alternativas son inviables por topografia o capacidad. Solo entonces corresponde pasar de *prioridad de validacion* a *prioridad de anteproyecto* y despues a una decision de inversion.

20.5 Siguientes pasos inmediatos

1. Congelar una version reproducible de datos, diccionarios, scripts, hashes y entorno de software.
2. Preparar directorios de campo desde `establecimientos_perfilados_cuenca.csv`, conservando ID DENUE, cluster, persistencia, evidencia y fuente MH cuando aplique.
3. Priorizar recorridos diferenciados en Xalmimilulco, Ixtapalucan, Tianguistenco, Coltzingo, Huejotzingo, Texmelucan y subnucleos seleccionados del cluster 20.
4. Solicitar al organismo operador capas de drenaje y plantas con diametro, material, cota, sentido, capacidad y estado.
5. Integrar DEM/topografia, hidrografia validada, descargas registradas y permisos en el mismo CRS metrico EPSG:32614.
6. Diseñar campaña de aforo y calidad del agua: caudal medio y maximo, DQO/DBO, SST, color, temperatura, pH, sales, metales y parametros asociados al proceso.
7. Construir balances preliminares de caudal y carga por zona hidraulicamente conectada.
8. Desarrollar y comparar alternativas conceptuales de colector, pretratamiento y tratamiento mediante criterios tecnicos, economicos, ambientales y sociales.

Limite de interpretacion

El analisis actual permite decidir donde validar y que medir. No permite todavia definir trazos, diametros, capacidad de planta ni monto de inversion. Esas decisiones requieren conectividad hidraulica, caudales, calidad de descarga, topografia, infraestructura existente y evaluacion de alternativas.

A Anexo A. Inventario de scripts y productos

El inventario general se consulta en `docs/INVENTARIO_GENERAL_PROYECTO.md`. Para la Parte 2 existen dos indices especializados: `docs/parte_2/trazabilidad/inventario_scripts_200.md` y `inventario_outputs_cierre.md`. El primero describe responsabilidades y dependencias de los scripts; el segundo enumera productos analiticos. Los hashes y tamanos del cierre se encuentran en `outputs/parte_2/11_cierre/inventario_cierre.csv`.

Cuadro 18: Inventario funcional resumido de scripts activos.

Scripts	Funcion	Producto principal
00--10	Flujo legacy de Xalmimilulco/Huejotzingo: carga, normalizacion, filtros, auditoria y mapas	outputs/xalmimilulco/, outputs/huejotzingo/ y tablas legacy.
100--102	Construccion regional de universos amplio, estricto, con/sin MH y todos SCIAN	outputs/cuenca_alto_atoyac_puebla*/.
200_parte2_comun.py	Rutas, constantes, señales y utilidades compartidas	Configuracion comun de toda la Parte 2.
201--203	Auditoria, matriz maestra, geometrias y diagnostico k-NN	Etapas 00_auditoria a 03_diagnosticos.
204--206	Bateria DBSCAN/HDBSCAN/OPTICS, seleccion y materializacion	Escenarios, ARI/Jaccard, persistencia y solucion_principal.gpkg.
207--210	Perfilado, sobrerrepresentacion, similitud y figuras	Etapas 07_perfiles a 10_figuras.
211--218	Auditoria de cierre, atlas, documentos y validacion	Etapas 11_cierre, 12_atlas, 13_figuras_finales.
219_ejecutar_parte2_completa.py	Orquestacion reproducible del pipeline principal	Reconstruccion ordenada de la Parte 2.
220--222	Segunda pasada: estabilidad, subnucleos, matrices y documentacion	outputs/parte_2/14_segunda_pasada/.
223_figuras_diagnostico_kde_hex.py	KDE, mallas hexagonales y curvas k-distancia	outputs/parte_2/03_diagnosticos/figuras/.

Los scripts 00–10 deben considerarse historicos pero vigentes para trazabilidad local; 100–102 y 200–223 constituyen el flujo regional activo. Un script no debe eliminarse solo por haber sido reemplazado: primero debe marcarse como historico y conservarse la salida con la que se utilizo en el reporte.

Informacion y evidencia minima requerida

El inventario actual documenta 38 scripts Python y 15 carpetas/etapas de resultados en `outputs/parte_2/`. Conviene convertir ese inventario en una tabla generada automaticamente para que no quede obsoleta.

B Anexo B. Diccionario de datos de la matriz maestra

La fuente operativa mas amplia es `outputs/parte_2/01_matriz/matriz_maestra_establecimientos.csv`. El diccionario de señales de la segunda pasada se conserva en `outputs/parte_2/14_segunda_`

pasada/diccionario_variables_analiticas.csv. La siguiente tabla identifica las variables necesarias para reutilizar la matriz sin introducir atributos productivos en el clustering.

Cuadro 19: Diccionario minimo de variables analiticas.

Variable/familia	Tipo/unidad	Significado y fuente	Uso
d_llave	texto	Identificador analitico estable derivado de la integracion	Joins, auditoria y trazabilidad; no define clusters.
cleee	texto	Clave unica DENUe cuando esta disponible	Enlace con DENUe y fuentes externas.
nom_est, raz_soc	texto	Nombre comercial y razon social DENUe/MH	Auditoria y señales textuales; no clustering.
cve_scian, desc_scian	codigo/texto	Actividad economica declarada	Universo y perfilado posterior.
Longitud, Latitud	grados	Coordenadas originales	Control y construccion geometrica.
x_utm14n, y_utm14n	metros	Coordenadas EPSG:32614	Unicas variables que entran al clustering espacial.
dentro_cuenca	booleano	Interseccion con poligono de cuenca	Separa deteccion e interpretacion.
Municipio, localidad	categoría	Adscripcion territorial DENUe	Perfilado y resultados territoriales.
evidencia_hidrica	categoría	SI, REVISAR, SIN_EVIDENCIA	Prioridad de validacion; nunca entra al clustering.
textil, mezclilla, maquila	booleano	Señales multilabel de diccionario	Perfil, lift y tipologías.
humedo_explicito, lavado_generico	booleano	Evidencia textual directa o ambigua de proceso humedo	Estratificacion de campo, no confirmacion de descarga.
proceso_seco_explicito	booleano	Confeccion, corte, costura, bordado u operaciones secas declaradas	Cautela y perfil productivo.
actividad_*	booleano	Familias posteriores: lavandería, acabado, confeccion, telas, tejido/hilado, bordado	Perfilado, sobrerrepresentacion y similitud.
cluster	entero	-1 ruido; 0-21 cluster principal	Resultado espacial, no atributo de entrada.
probabilidad	0-1	Fuerza de membresia HDBSCAN	Incertidumbre local.
persistencia_territorial	entero	Fraccion de escenarios donde se conserva asignacion equivalente	Robustez por establecimiento.

Variable/familia	Tipo/unidad	Significado y fuente	Uso
grupo_espacial	categoría	CLUSTER_NNN RUIDO_DISPERSO	o Agregación de perfiles y tablas.
Descripcion estrato personal ocupado	categoría	Intervalo DENUÉ de personal	Proxy descriptivo; no caudal ni producción.

Los nulos son admisibles en campos administrativos o de contacto, pero no en identificador analítico, coordenadas usadas, bandera de cuenca o membresía final. Antes de un nuevo cruce deben comprobarse unicidad de `d_llave`, conteos y CRS.

C Anexo C. Diccionarios SCIAN y texto

La tabla siguiente reproduce el diccionario operativo contenido en `data/processed/catalogs/ giro_textil.csv`, agrupado por el tipo de señal que genera cada término. Los términos se presentan en su forma normalizada, sin acentos y en minúsculas, tal como son comparados por el filtro. Una misma expresión puede pertenecer a varias etiquetas porque cada columna representa una dimensión analítica distinta; por ejemplo, *deshebrado* puede indicar contexto textil, producción, mezclilla y proceso seco. El número entre parentesis corresponde a las entradas registradas para cada etiqueta.

Etiqueta	Funcion dentro del filtro	Terminos asociados
humedo_explicito (49)	Identifica palabras que describen directamente lavado, teñido, acabado químico u otro tratamiento potencialmente húmedo. En contexto textil puede producir <code>evidencia_hidrica=SI</code> .	acabado; acabado de prendas; acabado químico; acabado textil; acid wash; baño químico; blanqueado; blanqueamiento; blanqueo; centrifugado; colorante; decolorado; deslavado; deslave; enjuague; enzimas; lavado de jeans; lavado de mezclilla; lavado de prendas; lavado de ropa; lavado industrial; lavado textil; lavandería de prendas; lavandería industrial; lavandería y tintorería; mercerización; mercerizado; neutralizado; oxidante; pigmentado; poliproseso; prelavado; procesamiento de ropa; proceso enzimático; procesos húmedos; sosa cáustica; stone lav; stone wash; stonewashed; suavizado; suavizado químico; tenido; tenido de prendas; tinte; tintorería; tintorería industrial; tintura; tratamiento de prendas; tratamiento textil.
lavado_generico (6)	Registra referencias amplias a lavado o tratamiento que necesitan contexto textil para interpretarse y normalmente conducen a revisión.	clean clothes; laundry; lavado; lavandería; tratamiento; tratamiento especial.
maquila (11)	Señala organización productiva por encargo o taller; apoya la inclusión cuando coincide con señales textiles o de mezclilla.	confección en serie; ensamble de prendas; maquila; maquila de mezclilla; maquila de prendas; maquila de ropa; maquila textil; maquilado; maquiladora; taller de mezclilla; taller textil.

Etiqueta	Funcion dentro del filtro	Terminos asociados
mezclilla (20)	Identifica denim, mezclilla y procesos o prendas relacionados. No demuestra por si sola un proceso humedo.	acid wash; denim; desebrado; deshebrado; fosil; jean; jeans; lavado de jeans; lavado de mezclilla; maquila de mezclilla; mesclilla; mezclilla; pantalon de mezclilla; pantalones de mezclilla; prendas de mezclilla; stone lav; stone wash; stonewashed; taller de mezclilla; transformacion de mezclilla.
no_textil_explicito (22)	Etiqueta negativa con prioridad sobre la candidatura textual; evita interpretar como textiles actividades claramente ajenas o comercio simple.	agua potable y alcantarillado; auto lavado; autolavado; captacion, tratamiento y suministro de agua; comercio al por mayor de madera; comercio al por menor de articulos usados; comercio al por menor de ropa; comercio al por menor de telas; elaboracion de derivados y fermentos lacteos; elaboracion de helados y paletas; elaboracion de sidra; elaboracion de tortillas; estructuras metalicas; fabricacion de muebles; lavado de botellas; lavado y lubricado de automoviles y camiones; molienda de nixtamal; productos de carton y papel; productos de herreria; productos de hierro y acero; productos de madera para la construccion; purificacion y embotellado de agua.
proceso_seco_explicito (10)	Distingue operaciones textiles que pueden realizarse principalmente sin proceso humedo; se conserva para perfilado y cautela interpretativa.	bordado; bordados; confeccion; confecciones; corte; corte y confeccion; costura; desebrado; deshebrado; planchado.
produccion (37)	Identifica expresiones de fabricacion, transformacion o actividad productiva y aporta contexto para decidir inclusion sectorial.	bordado; bordados; confeccion; confeccion en serie; confecciones; corte; corte industrial; desebrado; deshebrado; elaboracion; elaboracion de ropa; ensamble de prendas; estampado; fabrica; fabricacion; fabricacion de ropa; hilado; hilatura; impresion textil; industria; industrial; lavado industrial; lavanderia industrial; manufactura; maquiladora; procesamiento; procesamiento de ropa; produccion; serigrafia; sublimacion; tejeduria; tejido; telar; textilera; tintoreria industrial; transformacion; transformacion de mezclilla.
textil (48)	Registra referencias generales a materiales, prendas, oficios y operaciones de la cadena textil; aporta contexto sectorial, pero no prueba humedad.	acabado textil; bordado; bordados; confeccion; confecciones; costura; costurera; denim; desebrado; deshebrado; elaboracion de ropa; ensamble de prendas; estampado; fabricacion de ropa; fibra textil; hilado; hilatura; hilo; impresion textil; jean; jeans; maquila de mezclilla; maquila de prendas; maquila de ropa; maquila textil; mesclilla; mezclilla; pantalon; pantalon de mezclilla; pantalones de mezclilla; pasamaneria; prenda; prendas de mezclilla; prendas de vestir; ropa; ropa de trabajo; taller de mezclilla; taller textil; tejeduria; tejido; tela; telar; telas; textil; textilera; transformacion de mezclilla; tratamiento textil; uniforme industrial.

En total, el archivo contiene 203 asociaciones termino-etiqueta y 143 terminos unicos. La diferencia se debe a que varios terminos producen mas de una señal. Esta tabla documenta el diccionario utilizado en la corrida actual; no sustituye el archivo CSV, que permanece como fuente operativa y debe conservarse

con su hash y fecha en cada version reproducible.

D Anexo D. Bitacora de auditoria manual

La auditoria manual de version 1 se conserva en los productos legacy de Xalmimilulco y Huejotzingo. La integracion regional de la fuente MH se documenta en `outputs/cuenca_alto_atoyac_puebla_estricto_mh/tables/auditoria_integracion_mh.csv`; esta fuente procede del trabajo de campo de Mary Helen Figueroa y Mayra Jaqueline Ramirez y se mantiene separada de DENUE, aunque sus registros se enlazan con claves DENUE cuando es posible.

Para nuevas visitas debe añadirse una fila por establecimiento sin sobrescribir la evidencia previa. El esquema minimo es:

Campo	Tipo	Contenido
<code>d_llave, clec</code>	texto	Identificadores interno y DENUE para enlazar la visita.
<code>fuentes, revisor</code>	categoria/texto	DENUE, MH, visita, autoridad u otra fuente; persona responsable.
<code>fecha_observacion</code>	fecha	Fecha efectiva de consulta o visita.
<code>url/documento</code>	texto	Evidencia verificable o referencia al archivo resguardado.
<code>operacion_actual</code>	categoria	Activo, cerrado, traslado, no localizado, por confirmar.
<code>proceso_observado</code>	texto controlado	Lavado, teñido, acabado, confeccion, tejido, maquila u otro.
<code>uso_agua</code>	categoria	Confirmado, declarado, indicio, no observado, desconocido.
<code>forma_descarga</code>	categoria	Alcantarillado, cauce, infiltracion, reuso, transporte, desconocida.
<code>nota_factual</code>	texto	Observacion separada de la interpretacion analitica.
<code>decision</code>	categoria	Incluir, revisar, excluir o mantener sin evidencia.
<code>confianza</code>	ordinal	Alta, media o baja, con justificacion.

Las fotografias, entrevistas y coordenadas corregidas deben almacenarse fuera del CSV con un nombre estable referenciado por `d_llave`; cualquier dato personal o sensible requiere controles de acceso y una politica de resguardo.

E Anexo E. Catalogo de figuras, mapas y tablas

El atlas se encuentra en `outputs/parte_2/12_atlas/`; las figuras de cierre en `outputs/parte_2/13_figuras_finales/`; los diagnosticos KDE/hexagonales en `outputs/parte_2/03_diagnosticos_figuras/`; y las figuras de segunda pasada en `outputs/parte_2/14_segunda_pasada/figuras/`. El registro machine-readable de estas ultimas esta en `registro_documentacion_figuras.csv`.

Producto	Generador/origen	Mensaje y uso
----------	------------------	---------------

01_kde_hex_cuenca.png	223_figuras_diagnostico_kde_hex.py	Intensidad y conteos multiescala; no asigna clusters.
03_curvas_k_distancia.png	Script 223	Sustenta exploracion de escalas, no un umbral unico.
02_clusters_principales.png	Script 215	Localiza clusters interiores y ruido.
03_persistencia_territorial.png	Script 215	Distingue nucleos robustos y puntos sensibles.
04_tipos_productivos_clusters.png	Script 215	Muestra perfiles asignados despues del clustering.
07_rasgos_distintivos.png	Script 215	Resume señales con lift y evidencia suficiente.
09_similitud_perfiles.png	Script 215	Compara perfiles productivos, no proximidad espacial.
cluster_004.png--cluster_021.png	Script 215	Fichas visuales estandar de cada cluster interior.
ruido_disperso.png	Script 215	Perfil y geografia de unidades no agrupadas.
03_subnucleos_mega_etiquetados.png	Script 221	Particion exploratoria interna del cluster 20.
explorador_interactivo_clusters.html	Scripts 220–221	Consulta interactiva de puntos y agrupamientos.

Todos los mapas metricos de Parte 2 utilizan EPSG:32614 durante mediciones. Una exportacion puede ocultar el CRS; para analisis debe utilizarse el GPKG de origen y no georreferenciar el PNG.

F Anexo F. Glosario metodologico

Termino	Definicion en este proyecto
DENUE	Directorio Estadistico Nacional de Unidades Economicas; fuente registral, no censo de descargas.
SCIAN	Sistema de clasificacion de actividad economica utilizado para construir y perfilar universos.
Universo sectorial	Establecimientos textiles/manufactureros y lavanderias definidos para detectar concentraciones sin exigir evidencia hidrica explicita.
Evidencia hidrica	Etiqueta SI, REVISAR o SIN_EVIDENCIA; orienta auditoria, no prueba descarga.
Proceso humedo	Operacion cuyo texto o clasificacion sugiere lavado, teñido, acabado u otro uso directo de agua.
CRS/UTM	Sistema de referencia; EPSG:32614 expresa coordenadas y distancias en metros.

Efecto de borde	Distorsion causada al cortar vecinos en el limite de la cuenca; se reduce detectando sobre universo ampliado.
DBSCAN	Clustering por densidad con radio ε fijo y <code>min_samples</code> .
HDBSCAN	Extension jerarquica para densidad variable; genera clusters, ruido y probabilidad de membresia.
OPTICS	Ordenamiento por alcanzabilidad usado como contraste de densidades variables.
Ruido	Punto no asignado a un cluster bajo una especificacion; no significa error ni irrelevancia.
<code>min_cluster_size</code>	Tamaño minimo de una rama persistente en HDBSCAN.
<code>min_samples</code>	Parametro de conservadurismo de densidad local.
EOM/ <i>leaf</i>	EOM favorece ramas persistentes amplias; <i>leaf</i> revela ramas locales mas finas.
ARI	Similitud entre particiones completa, corregida por coincidencia esperada al azar.
Jaccard	Solapamiento entre dos conjuntos: interseccion dividida por union.
Persistencia	Frecuencia con la que un establecimiento conserva asignacion equivalente entre escenarios.
KDE	Superficie suavizada de intensidad espacial dependiente del ancho de banda.
k-NN/k-distancia	Distancia al vecino de orden k ; diagnostica escalas y heterogeneidad de densidad.
Lift	Prevalencia del cluster dividida por prevalencia base; 2 significa el doble de frecuencia relativa.
Odds ratio	Razon de momios dentro del cluster frente al resto del universo.
Fisher exacta	Prueba de asociacion para tabla 2×2 , valida aun con conteos pequeños.
Benjamini–Hochberg	Ajuste que controla la tasa esperada de falsos descubrimientos en pruebas multiples.
Distancia de perfiles	Combinacion 50/50 de distancia coseno de señales y Jensen–Shannon de SCIAN.
<i>Linkage</i>	Regla para fusionar perfiles en la jerarquia; se utilizo enlace promedio.
Subnucleo diagnostico	Rama local del cluster 20 usada para exploracion; no reemplaza la membresia principal.

G Anexo G. Registro de decisiones metodologicas

Las decisiones formales de Parte 2 se encuentran en `docs/parte_2/decisiones/`. Cada archivo conserva contexto, decision, justificacion, consecuencias y condiciones de revision.

ID	Archivo	Decision principal
001	001_definicion_universo.md	Separar universo sectorial de evidencia hidrica y conservar reglas audiables.
002	002_borde_crs_y_distancia.md	Detectar sobre universo ampliado y medir en EPSG:32614.
003	003_metodos_y_seleccion.md	Comparar DBSCAN, HDBSCAN y OPTICS; seleccionar por multiples criterios.
004	004_ruido_perfiles_y_sobrerrepresentacion.md	Conservar ruido y perfilar solo despues de fijar la geografia.
005	005_cierre_y_transicion_parte_3.md	Congelar resultados y definir requisitos antes de la etapa hidraulica.

Una nueva decision debe registrar fecha, responsable, alternativas, evidencia, archivos afectados y condicion de revision. Cambios en universo, CRS, parametros principales o diccionarios requieren una nueva version y no deben modificar silenciosamente los registros anteriores.

H Anexo J. Fuentes y antecedentes a incorporar

La bibliografia utilizada por el reporte se administra en `docs/reporte_completo/repote_completo.bib`. Las fuentes registrales y espaciales efectivamente consumidas por el pipeline se inventarian en `outputs/parte_2/00_auditoria/inventario_fuentes.csv`. Para una entrega final, cada capa debe conservar institucion, titulo oficial, version o fecha de corte, URL de descarga, CRS, licencia y hash del archivo recibido.

- INEGI – DENUÉ y diccionario de datos de la version utilizada.
- Fuente oficial de poligono de cuenca, division municipal y red hidrografica.
- Informes tecnicos de CONAGUA/SEMARNAT/autoridades estatales pertinentes.
- Registros de emisiones/transferencias y descargas cuando sean aplicables.
- Literatura academica y tecnica sobre contaminacion, actividad textil y salud ambiental en la Cuenca del Alto Atoyac.
- *Salud ambiental en la Cuenca del Alto Atoyac: situacion, peligros ambientales y acciones para reducir el riesgo de enfermedades cronicas no transmisibles*, como antecedente contextual a revisar y citar formalmente en la version final.

La siguiente etapa debe añadir de manera prioritaria planos o bases del organismo operador sobre drenaje y plantas; modelos de elevacion y topografia; registros de descargas y permisos; resultados de aforo y laboratorio; y documentacion tecnica de capacidad y proceso de cada planta de tratamiento. Estas fuentes no deben mezclarse con DENUÉ sin conservar identificador, fecha, responsable y regla de enlace.

Referencias

Comisión Nacional de los Derechos Humanos. Recomendación no. 10/2017 sobre la violación a los derechos humanos a un medio ambiente sano, saneamiento del agua y acceso a la información, en relación con la contaminación de los ríos atoyac, xochiac y sus afluentes. Technical report,

Comisión Nacional de los Derechos Humanos, Ciudad de México, México, March 2017. URL https://hist.cndh.org.mx/sites/default/files/doc/Recomendaciones/2017/Rec_2017_010.pdf.

Comisión Nacional del Agua. Declaratoria de clasificación de los ríos atoyac y xochiac o hueyapan, y sus afluentes. Diario Oficial de la Federación, 2011. URL https://dof.gob.mx/nota_detalle_popup.php?codigo=5199672. Publicada el 6 de julio de 2011.

Comisión Nacional del Agua. Firman gobiernos de México y de Puebla convenio con industrias textiles para mejorar la calidad del agua del río atoyac. Comunicado de prensa, November 2022. URL <https://www.gob.mx/conagua/prensa/firman-gobiernos-de-mexico-y-de-puebla-convenio-con-industrias-textiles-para-mejorar-la-calidad-del-agua-del-rio-atoyac?idiom=es-MX>.

Gabriela Pérez Castresana, Aline Romero Natale, Raúl Camacho Sanabria, Arturo Sánchez Porras, and Matilde Ortuño Vilchis. *Salud ambiental en la Cuenca del Alto Atoyac: Situación, peligros ambientales y acciones para reducir el riesgo de enfermedades crónicas no transmisibles (ECNT)*. Universidad Iberoamericana Puebla, Instituto de Investigaciones en Medio Ambiente Xabier Gorostiaga, SJ, Puebla, México, 2023. URL <https://repo.iberopuebla.mx/IIMA/saludAmbiental/>.

Alejandro Ernesto Svarch Pérez, Verónica Suárez-Rienda, Luz Angélica de la Sierra de la Vega, and Jorge Carlos Alcocer Varela. Percepción de riesgos a la salud por contaminación industrial en la cuenca del alto atoyac: aportaciones para la regulación sanitaria. *Revista Internacional de Contaminación Ambiental*, 41:581–597, 2025. doi: 10.20937/rica.55301. URL https://www.scielo.org.mx/scielo.php?pid=S0188-49992025000100146&script=sci_arttext.