

Análisis geo-estadístico para tratamiento de aguas residuales en la cuenca del Alto Atoyac:

Concentraciones territoriales de actividades textiles

Síntesis para discusión y toma de decisiones

Universidad de las Américas Puebla

Nuria Arroyo Bustamante
173605

24 de septiembre de 2026

Este documento explica dónde se concentran las unidades económicas textiles y qué preguntas conviene investigar en cada territorio. No identifica responsables de contaminación ni propone trazos de colectores.

Glosario metodológico

Las definiciones siguientes fijan el sentido específico de los términos usados en este documento; no sustituyen las advertencias de interpretación incluidas en cada sección.

Término	Definición y uso en este proyecto
DENUE	Directorio Estadístico Nacional de Unidades Económicas del INEGI. Aporta identificación, actividad declarada y coordenadas; no es un censo de procesos, consumos o descargas.
SCIAN	Sistema de Clasificación Industrial de América del Norte empleado para construir el universo sectorial y caracterizarlo después del clustering.
MH	Fuente independiente generada mediante investigación de campo por Mary Helen Figueroa y Mayra Jaqueline Ramírez. Se enlazó con identificadores DENUE cuando fue posible, sin perder su procedencia.
Universo sectorial	Conjunto amplio de actividades textiles, confección y lavandería/tintorería usado para detectar concentraciones sin exigir evidencia hídrica explícita.
Evidencia hídrica	Etiqueta SI , REVISAR o SIN_EVIDENCIA derivada de reglas textuales o MH; orienta auditoría y no confirma una descarga.
Proceso húmedo	Operación cuyo texto o clasificación sugiere lavado, teñido, acabado u otro uso directo de agua; es una hipótesis registral hasta su verificación.
DBSCAN	Método de densidad con un radio fijo ϵ y un mínimo de vecinos; se utilizó como referencia espacial más agregada.
HDBSCAN	Método jerárquico de densidad variable que asigna clusters, ruido y probabilidades de pertenencia; produjo la solución principal.
OPTICS	Ordenamiento por alcanzabilidad empleado como contraste para estructuras de densidad variable.
min_cluster_size	Tamaño mínimo de una rama persistente en HDBSCAN; en la solución principal fue 10.
min_samples	Parámetro que controla el conservadurismo de la densidad local; en la solución principal fue 20.
EOM	Regla de selección de HDBSCAN que favorece ramas amplias y persistentes; se contrapone a <i>leaf</i> , usada únicamente para explorar ramas internas más finas del cluster 20.
Ruido	Establecimiento no asignado a un cluster bajo una especificación. Significa actividad espacialmente dispersa, no error o irrelevancia.
ARI	Índice Rand ajustado: similitud global entre dos particiones, corregida por la coincidencia esperada al azar; 1 indica equivalencia.
Jaccard	Solapamiento entre dos conjuntos, calculado como intersección dividida entre unión; complementa al ARI en la comparación local.
Persistencia	Fracción de escenarios de contraste en los que un establecimiento conserva una asignación equivalente.
Lift o sobrerepresentación	Prevalencia de una señal dentro de un cluster dividida entre su prevalencia en los 4,010 establecimientos interiores. Un lift de 2 indica doble frecuencia relativa, no doble producción.
CRS/UTM	Sistema de referencia proyectado. EPSG:32614 (WGS 84/UTM 14N) expresa coordenadas y distancias en metros y se utilizó para las operaciones espaciales.

Índice

Glosario metodológico	2
1. Resumen ejecutivo	4
2. Antecedentes y pregunta del estudio	4
3. Materiales y métodos	5
4. Construcción del universo	5
5. Cómo se detectaron las concentraciones	7
6. Principales concentraciones territoriales	9
7. Diferencias productivas entre clusters	14
8. Robustez e incertidumbre	16
9. Zonas prioritarias para validación	18
10. Qué no concluye el estudio	19
11. Siguiendo pasos	19
Referencias	20

1. Resumen ejecutivo

El estudio respondió una pregunta previa a cualquier decisión de infraestructura: **¿en qué zonas de la cuenca del Alto Atoyac se concentran las unidades económicas textiles, de confección y de lavandería/tintorería, y qué perfil productivo tiene cada concentración?** La información disponible permitía ubicar establecimientos individuales, pero no ofrecía una lectura regional comparable ni separaba con claridad actividad sectorial, indicios de uso de agua y evidencia verificada en campo.

Se construyó un universo sectorial auditable de 4,365 establecimientos en 26 municipios. El análisis espacial se hizo con ese universo ampliado para evitar cortes artificiales en el borde de la cuenca; la interpretación se restringió a 4,010 establecimientos dentro de ella. La solución operativa seleccionada reconoce 22 agrupamientos en el universo de detección, de los cuales 18 intersectan la cuenca, y conserva 584 unidades como actividad espacialmente dispersa. Dentro de la cuenca, 578 unidades aparecen como ruido o dispersión.

Los resultados cambian una lectura uniforme del problema. Santa Ana Xalmimilulco destaca por confección, maquila y mezclilla; San Rafael Ixtapalucan y San Miguel Tianguistenco por tejido e hilado; Huejotzingo y el corredor de San Martín Texmelucan combinan manufactura y señales potencialmente húmedas; San Miguel Xoxtla–Coronango y Amozoc forman concentraciones diferenciadas; y Puebla–Cholula–Cuautlancingo aparece como un sistema metropolitano extenso y heterogéneo que requiere subdividir la validación, no tratarse como una sola zona operativa.

La solución seleccionada fue la mejor puntuada bajo una regla documentada, pero dos configuraciones HDBSCAN obtuvieron puntajes prácticamente iguales. La mayor parte de las membresías es estable, aunque existen puntos sensibles y bordes que deben conservarse como incertidumbre. La utilidad del resultado es **priorizar territorios, recorridos y preguntas**, no inferir descargas ni diseñar infraestructura.

Límite de interpretación. Concentración espacial $\neq$ contaminación; proximidad a río $\neq$ descarga; cluster $\neq$ zona de servicio; lavandería sectorial $\neq$ lavandería industrial verificada; priorización territorial $\neq$ recomendación de colector.

2. Antecedentes y pregunta del estudio

La cuenca del Alto Atoyac combina urbanización, actividad industrial, manufactura dispersa y una historia documentada de presión sobre el agua [10, 4, 3]. En este contexto, la industria textil y de mezclilla importa porque puede incluir operaciones con necesidades y residuos muy distintos: confección y costura, tejido e hilado, acabado, teñido, lavado, deslavado, limpieza de equipo o servicios de lavandería. El directorio económico no registra de manera completa cuáles de esas operaciones ocurren realmente en cada domicilio ni cuánto agua utilizan.

El problema operativo era doble. Primero, el territorio era demasiado amplio para visitar todas las unidades con la misma intensidad. Segundo, seleccionar únicamente negocios cuyo nombre menciona agua, lavado o teñido podía excluir talleres industriales reales con nombres poco informativos, mientras incluir toda lavandería podía mezclar servicios comerciales con operaciones industriales. El proyecto debía conservar esa incertidumbre y aun así producir una base útil para decidir dónde investigar primero.

La pregunta se formuló en términos territoriales y no acusatorios: localizar concentraciones reproducibles, describir su composición y reconocer qué resultados sobreviven a cambios razonables de parámetros. El análisis no utilizó atributos productivos para formar los clusters; primero se agrupó por proximidad espacial y después se estudió qué actividades estaban presentes en cada grupo. Así se evitó construir de

antemano los perfiles que luego se pretendía descubrir.

3. Materiales y métodos

Las fuentes principales fueron la descarga estatal DENUÉ del 11 de septiembre de 2026, acotada a los códigos SCIAN 313, 314, 315 y 812210, y la descarga local del 4 de septiembre usada en la fase inicial [9]. La delimitación de la cuenca corresponde al producto *Cuenca del Alto Atoyac 2021*, derivado del SINA de Conagua; los límites municipales proceden del Marco Geoestadístico 2020 del INEGI; y la red hidrográfica proviene de la Red Hidrográfica Digital de México 1:250,000 de 2006. Las tres capas fueron distribuidas por el Ecosistema Nacional Informático en GeoPackage/GeoJSON, con metadatos de 2023 y licencia de libre uso MX [5, 6, 7]. MH se trató como fuente de campo independiente, con enlace a claves DENUÉ cuando existía correspondencia.

El universo se construyó mediante normalización, control de identificadores, recorte municipal, selección SCIAN y reglas textuales aplicadas a nombre, razón social y descripción de actividad. Se conservaron modalidades amplia y estricta para auditar el efecto de exigir señales hídricas, pero el clustering regional empleó el universo sectorial completo para no excluir talleres o lavanderías pequeñas cuyo uso de agua no fuera explícito en el registro.

Las capas fuente se armonizaron en EPSG:4326 para intercambio y se proyectaron a **EPSG:32614 (WGS 84/UTM zona 14N)** para distancias, vecindades y agrupamiento. El clustering se realizó **exclusivamente con las coordenadas métricas de los establecimientos**. Las características económicas y productivas se incorporaron después para describir e interpretar los grupos, nunca para formarlos. Se compararon DBSCAN [8], HDBSCAN [2] y OPTICS [1] en 57 configuraciones, con análisis de sensibilidad, ARI, Jaccard, persistencia y perturbaciones posicionales.

El procesamiento reproducible se ejecutó en Python. Los scripts y el archivo de requerimientos documentan el uso de pandas, NumPy, GeoPandas, Shapely, Pyogrio y Matplotlib; las etapas analíticas incorporan además scikit-learn, hdbscan, SciPy, Seaborn y Plotly. No se reportan versiones porque el repositorio no las fija. Los productos auditables se almacenaron como CSV, GeoPackage, PNG y HTML.

4. Construcción del universo

El punto de partida fue una descarga estatal del Directorio Estadístico Nacional de Unidades Económicas (DENUÉ) acotada a actividades SCIAN de interés. Tras normalización, control de identificadores y delimitación municipal, se construyó un universo sectorial de 4,365 establecimientos. De ellos, 4,010 se encuentran dentro del polígono de la cuenca. Los 355 puntos de **apoyo exterior** son establecimientos de los municipios de referencia situados fuera del polígono; se conservaron durante la detección para que la frontera cartográfica no eliminara vecinos reales ni fragmentara clusters, y después quedaron fuera de la interpretación sustantiva.

El universo sectorial es deliberadamente más amplio que el universo hídrico estricto. Incluye manufactura textil, confección y servicios de lavandería/tintorería potencialmente relevantes. En paralelo se generaron modalidades amplia y estricta, con y sin la fuente MH de trabajo de campo. La regla amplia protege cobertura; la estricta exige señales más directas y excluye lavanderías sin contexto adicional. Ninguna modalidad reemplaza a la otra: muestran el costo de priorizar sensibilidad o especificidad.

MH se conserva como fuente independiente de DENUÉ porque procede del trabajo de campo de Mary Helen Figueroa y Mayra Jacqueline Ramírez. Cuando fue posible, sus hallazgos se asociaron

con identificadores DENU, sin perder la procedencia. Este vínculo permite auditar coincidencias y diferencias sin presentar la evidencia de campo como si fuera un atributo original del directorio.

Universos de detección e interpretación




Figura 1: Universo ampliado para detección y universo interior para interpretación. Los puntos exteriores controlan el efecto de borde.

Límite de interpretación. DENUÉ describe ubicación y actividad declarada. No prueba operación actual, proceso húmedo, consumo de agua, descarga, contaminante ni incumplimiento.

5. Cómo se detectaron las concentraciones

Los establecimientos se proyectaron a un sistema métrico y se compararon 57 configuraciones de tres métodos de agrupamiento por densidad: DBSCAN, HDBSCAN y OPTICS. En lenguaje sencillo, estos métodos buscan conjuntos de puntos suficientemente próximos y separan como dispersos aquellos que no forman una concentración bajo la escala evaluada. Las variables económicas no participaron en esta etapa.

La comparación consideró cuántos grupos se formaban, cuánto ruido quedaba, si un solo grupo absorbía demasiado territorio, qué tan estable era la partición frente a configuraciones vecinas y qué ocurría al desplazar ligeramente las coordenadas. Antes de puntuar se descartaron soluciones degeneradas: menos de 3 o más de 80 clusters, ruido menor a 1 % o mayor a 75 %, o un cluster mayor superior a 60 % del universo. La configuración HDBSCAN con `min_cluster_size=10`, `min_samples=20` y selección EOM alcanzó el mayor puntaje operativo, 0.963. El tamaño mínimo de 10 conserva concentraciones locales; `min_samples=20` exige soporte vecinal más conservador; y EOM favorece ramas persistentes, evitando convertir fluctuaciones finas en clusters principales.

La selección representa un compromiso verificable: ARI medio de 0.937 frente a las cinco configuraciones HDBSCAN más próximas, ARI de 0.926 ante perturbaciones de 25 m, probabilidad media de pertenencia de 0.914, 22 clusters y un grupo mayor de 45.75 %. La referencia DBSCAN fue más estable ante perturbación (0.996) y dejó menos ruido (7.54 %), pero produjo solo 13 grupos y fusionó 2,178 establecimientos en el mayor. Dos alternativas HDBSCAN obtuvieron 0.962, apenas 0.001 menos, y ARI de 0.998 y 0.989 frente a la principal. Por ello la selección es una referencia reproducible y defendible dentro de una familia próxima, no una geografía única o verdadera.

Cuadro 2: Criterios cuantitativos que se reutilizan en el reporte.

Clasificación	Regla visible	Origen y función
Escenario elegible	3–80 clusters; ruido 1–75 %; cluster mayor $\leq 60\%$	Selección de escenarios, reporte maestro §13.1; excluye particiones degeneradas.
Persistencia sensible	< 0.50	Comparación de cinco escenarios; señala membresía inestable.
Persistencia estable	0.50–0.79	Comparación de cinco escenarios; indica estabilidad intermedia.
Núcleo robusto	0.80–1.00	Comparación de cinco escenarios; conserva asignación equivalente con alta frecuencia.
Rasgo sobrerrepresentado conservador	$n \geq 5$, prevalencia $\geq 5\%$, lift ≥ 1.25 y $q \leq 0.05$	Contrastes de 18 señales en 18 clusters y ruido; evita destacar asociaciones con soporte mínimo o sin contraste suficiente.

Además de los clusters se conservaron las unidades dispersas. El ruido no significa error, irrelevancia o ausencia de impacto; indica que esos establecimientos no forman una concentración bajo la configuración seleccionada. Pueden requerir otra estrategia de inspección, especialmente cuando se encuentren cerca de infraestructura o receptores sensibles.

Flujo general del estudio y la siguiente etapa

El diagrama resume la secuencia completa. Los atributos productivos se incorporan después de fijar la geografía de los clusters; la integración hidráulica corresponde a la etapa siguiente y todavía requiere datos de campo e infraestructura.




Figura 2: Flujo metodológico desde las fuentes registrales hasta la integración hídrica propuesta. La última caja representa trabajo futuro, no un resultado ya demostrado.

Solución espacial principal: clusters dentro de la cuenca




Figura 3: Concentraciones interiores de la solución seleccionada y actividad dispersa. La leyenda establece la correspondencia cluster–color; el cluster 20 es el continuo metropolitano amarillo que se examina internamente en la Figura 4. Los colores representan membresía espacial, no contaminación.

6. Principales concentraciones territoriales

La Tabla 3 vincula el identificador y color de la Figura 3 con su territorio y composición. Las actividades son etiquetas multilabel: un establecimiento puede pertenecer a más de una columna, por lo que los porcentajes no suman 100 %. “Lav./tint.” corresponde a actividad sectorial de lavandería/tintorería; no equivale a lavandería industrial verificada.

Cuadro 3: Resumen auditable de los 18 clusters que intersectan la cuenca.

Cluster	Municipios con integrantes	<i>n</i>	Lav./tint. %	Confección %	Fabr. telas %	Acabado %
4	Chiautzingo	28	7.1	78.6	0.0	0.0
5	San Matías Tlalancaleca; Tlahuapan	33	6.1	78.8	6.1	0.0
6	Tlahuapan	20	0.0	40.0	0.0	0.0
7	Huejotzingo	99	44.4	31.3	7.1	1.0
8	Huejotzingo	337	8.0	85.8	1.5	1.2
9	Tlahuapan	30	0.0	16.7	0.0	0.0
10	Tlahuapan	142	3.5	0.7	0.7	0.7
11	Ocoyucan	8	12.5	37.5	0.0	0.0
12	San Matías Tlalancaleca; San Salvador el Verde	224	7.1	83.9	1.3	1.3
13	San Martín Texmelucan; San Salvador el Verde	149	8.1	81.2	0.0	0.0
14	Cuautlancingo	14	35.7	42.9	0.0	0.0
15	San Martín Texmelucan	92	48.9	40.2	1.1	0.0
16	San Martín Texmelucan	51	15.7	70.6	2.0	2.0
17	San Martín Texmelucan	45	13.3	84.4	0.0	0.0
18	Amozoc	32	40.6	40.6	0.0	0.0
19	San Miguel Xoxtla; Coronango	100	9.0	76.0	2.0	0.0
20	Puebla; San Andrés Cholula; San Pedro Cholula; Cuautlancingo; Amozoc; Coronango	1,997	59.3	20.9	5.3	1.0
21	Amozoc	31	41.9	25.8	9.7	0.0

Santa Ana Xalmimilulco y Huejotzingo

Santa Ana Xalmimilulco corresponde al cluster 8 y reúne 337 establecimientos. Es una concentración manufacturera compacta: 85.8 % tiene señal de confección, 55.8 % de maquila y 40.7 % de mezclilla o pantalón. La evidencia sugiere una organización productiva especializada que amerita verificar si operaciones de lavado, limpieza o acabado ocurren dentro de talleres registrados principalmente como confección. No debe suponerse que todas las unidades pertenecen al universo hídrico estricto.

La cabecera de Huejotzingo y localidades próximas forman el cluster 7, con 99 establecimientos dentro de la cuenca. Su perfil es de **coexistencia mixta**: manufactura y lavandería/tintorería aparecen juntas sin que una categoría anule a la otra; 44.4 % pertenece a lavandería/tintorería sectorial. Xalmimilulco y Huejotzingo deben tratarse como preguntas de campo distintas: el primero por cadenas de confección–maquila–mezclilla; el segundo por coexistencia de manufactura y servicios potencialmente húmedos.

Tlahuapan

San Miguel Tianguistenco (cluster 9, 30 establecimientos) y San Rafael Ixtapalucan (cluster 10, 142) sobresalen por tejido e hilado: 80.0 % y 95.1 %, respectivamente. Santiago Coltzingo (cluster 6, 20) concentra señal de maquila en 16 unidades. Los porcentajes son altos, pero los tamaños de Tianguistenco y Coltzingo son pequeños; son candidatos para inspección focal, no bases para dimensionar obra.

San Martín Texmelucan, Tlanalapan y Moyotzingo

El sistema no aparece como una sola masa homogénea. San Rafael Tlanalapan forma el cluster 13 con 149 unidades y una presencia importante de confección y proceso seco explícito. San Martín Texmelucan participa en los clusters 15 y 17; el 15 reúne 92 unidades y casi la mitad corresponde a lavandería/tintorería sectorial. Santa María Moyotzingo forma el cluster 16 con 51 unidades. La segunda etapa debe revisar conexiones funcionales entre estos núcleos sin fusionarlos automáticamente.

San Miguel Xoxtle–Coronango y Amozoc

El cluster 19 reúne 100 establecimientos y se centra en San Miguel Xoxtle; 76 % tiene señal de confección. Su relación con Coronango debe estudiarse mediante movilidad productiva, drenaje e infraestructura, no solo por cercanía. Amozoc presenta dos concentraciones: clusters 18 y 21, con 32 y 31 unidades, y participaciones sectoriales de lavandería/tintorería cercanas a 41 %. Son núcleos pequeños que ameritan corroborar procesos reales.

Sistema Puebla–Cholula–Cuautlancingo

El cluster 20 contiene 1,997 establecimientos y articula seis municipios y 14 localidades. No es una sola zona industrial ni una futura zona de servicio. Es una estructura metropolitana continua, con máximos locales conectados por bandas de establecimientos y un perfil mixto: 59.3 % pertenece a lavandería/tintorería sectorial y 20.9 % a confección. La exploración interna aplicó HDBSCAN *leaf* con `min_cluster_size=30` y `min_samples=10`: reconoce 18 subnúcleos descriptivos con 1,108 establecimientos, pero deja 889 (44.5 %) sin rama local bajo esa especificación. Los 1,997 conservan su membresía principal; la segunda pasada solo hace legible la heterogeneidad metropolitana y orienta recorridos, no crea 18 zonas de servicio ni demuestra conexiones hidráulicas o funcionales.




Figura 4: Subnúcleos A–R exploratorios del cluster 20. El gris identifica puntos sin rama local en la segunda pasada, que permanecen dentro del cluster principal. Las letras son identificadores y los colores distinguen ramas; no representan categorías productivas ni zonas de servicio.

La Tabla 4 reporta el municipio y localidad dominantes disponibles en el producto auditable; no debe leerse como lista exhaustiva del ámbito de cada rama. Las proporciones son multilabel y mantienen la misma definición que en la Tabla 3.

Cuadro 4: Resumen de los 18 subnúcleos exploratorios del cluster 20.

Sub.	Municipio / localidad dominante	<i>n</i>	Lav./tint. %	Confección %	Fabr. telas %	Acabado %
A	San Andrés Cholula / San Andrés Cholula	31	83.9	9.7	0.0	0.0
B	San Pedro Cholula / Cholula de Rivadavia	76	59.2	15.8	3.9	1.3
C	Puebla / Heroica Puebla de Zaragoza	46	80.4	6.5	0.0	0.0
D	San Andrés Cholula / San Bernardino Tlaxcalancingo	57	75.4	14.0	3.5	0.0
E	Puebla / Heroica Puebla de Zaragoza	92	58.7	30.4	1.1	0.0
F	San Pedro Cholula / Santiago Momoxpan	93	57.0	17.2	7.5	3.2
G	Puebla / Heroica Puebla de Zaragoza	58	60.3	25.9	0.0	0.0
H	Puebla / Heroica Puebla de Zaragoza	41	58.5	24.4	0.0	0.0
I	Puebla / Heroica Puebla de Zaragoza	36	50.0	8.3	19.4	5.6
J	Puebla / Heroica Puebla de Zaragoza	65	53.8	18.5	7.7	0.0
K	Puebla / Heroica Puebla de Zaragoza	33	57.6	30.3	3.0	0.0
L	Puebla / Heroica Puebla de Zaragoza	74	59.5	33.8	1.4	0.0
M	Puebla / Heroica Puebla de Zaragoza	112	60.7	14.3	5.4	0.9
N	Puebla / Heroica Puebla de Zaragoza	97	44.3	19.6	10.3	2.1
O	Puebla / Heroica Puebla de Zaragoza	78	39.7	37.2	1.3	0.0
P	Puebla / Heroica Puebla de Zaragoza	54	70.4	25.9	1.9	1.9
Q	Puebla / Heroica Puebla de Zaragoza	30	30.0	36.7	10.0	3.3
R	Puebla / Heroica Puebla de Zaragoza	35	62.9	17.1	11.4	0.0

7. Diferencias productivas entre clusters

Las concentraciones no son intercambiables. El perfil posterior al clustering distingue núcleos manufactureros, territorios especializados en tejido/hilado, sistemas de confección–maquila–mezclilla y grupos mixtos con mayor presencia de lavandería/tintorería. Esta diferencia permite diseñar instrumentos de campo específicos: no conviene preguntar lo mismo a un taller de confección que a un establecimiento de acabado o a una lavandería registrada como servicio.

En Xalmimilulco, la mezcla de confección, maquila y mezclilla apunta a relaciones entre talleres y etapas productivas. En Tlahuapan, tejido/hilado domina las concentraciones de Ixtapalucan y Tianguistenco. Tlanalapan combina confección con procesos secos; Texmelucan y el cluster metropolitano presentan perfiles más mixtos. El ruido conserva numerosas microunidades manufactureras y no debe leerse como el opuesto económico de los clusters.

Composición posterior: manufactura y lavanderías




Figura 5: Tipos productivos de las concentraciones, asignados después de fijar la geografía.

La sobrerrepresentación compara la frecuencia de una señal dentro de un cluster con su frecuencia en los 4,010 establecimientos del universo interior. En la Figura 6 el color representa $\log_2(\text{lift})$, una transformación sin unidades: 0 equivale a lift 1, 1 al doble y 2 a cuatro veces la prevalencia base. Una celda solo se muestra como rasgo distintivo si cumple simultáneamente el **criterio conservador** documentado: al menos 5 establecimientos, prevalencia interna de 5 % o más, lift de al menos 1.25 y valor $q \leq 0.05$ después del ajuste Benjamini–Hochberg de 342 contrastes. Este filtro evita destacar señales sostenidas por muy pocos casos, sin convertir el análisis en inferencia causal.

“Mención de lavado” significa que el texto comercial contiene vocabulario de lavado; “mención de pantalón” y “mezclilla o pantalón” son señales textuales de producto; las columnas marcadas SCIAN provienen de la actividad económica declarada. Por ejemplo, tejido/hilado aparece 10.62 veces más frecuentemente en el cluster 10 que en el universo interior, con 135 de 142 establecimientos, mientras en el cluster 9 aparece en 24 de 30; ambos tienen soporte absoluto suficiente, aunque el segundo es pequeño. El cluster 8 destaca por confección, maquila y mezclilla/pantalón con cientos de casos, y el cluster 20 presenta contrastes más moderados pero gran soporte absoluto: lavandería/tintorería sectorial abarca 1,185 unidades, 313 tienen señal húmeda explícita y 22 evidencia hídrica SI. Las categorías se traslapan y ninguna confirma por sí sola producción, uso de agua o una lavandería industrial.




Figura 6: Señales distintivas que cumplen simultáneamente $n \geq 5$, prevalencia interna $\geq 5\%$, lift ≥ 1.25 y $q \leq 0.05$. El color es $\log_2(\text{lift})$, sin unidades; las celdas claras sin contraste no satisfacen los cuatro filtros.

8. Robustez e incertidumbre

En este estudio, **robustez** significa que la estructura territorial general reaparece cuando se cambian razonablemente los parámetros, se contrasta con otro método o se introduce un pequeño error posicional; **incertidumbre** significa que la membresía y los límites de algunos establecimientos no son invariantes. Variar parámetros cambia la escala mínima y la exigencia de densidad; comparar métodos permite comprobar si la lectura depende de una sola lógica algorítmica; y perturbar 25 m simula una imprecisión

cartográfica pequeña mediante tres réplicas gaussianas independientes en x y y .

La solución elegida obtiene el mayor puntaje y un ARI medio de 0.937 con las cinco configuraciones HDBSCAN más similares. Las alternativas cercanas con `min_samples=20` producen ARI de 0.998 y 0.989 frente a la principal, mientras las de `min_samples=10` conservan ARI de 0.925 y 0.922. Ante las tres perturbaciones de 25 m, los ARI globales fueron 0.895, 0.892 y 0.989; al comparar solo establecimientos agrupados en ambas particiones aumentaron a 0.979, 0.979 y 1.000. Los cambios ocurren principalmente en transiciones entre cluster y ruido y en bordes locales, no en el núcleo de las concentraciones. Por eso una variación puntual no invalida automáticamente la estructura regional.

De los 4,365 establecimientos de detección, 4,107 (94.1 %) son núcleos robustos, 94 (2.2 %) tienen estabilidad intermedia y 164 (3.8 %) son sensibles según los umbrales de la tabla de criterios. El cluster 20 es muy persistente y eleva la similitud global; al excluirlo, la concordancia frente a algunas alternativas disminuye, aunque la estructura restante continúa siendo reconocible. Por eso cualquier directorio de visita debe incluir la persistencia de membresía y evitar tratar todos los puntos con la misma certeza.

Persistencia territorial entre especificaciones




Figura 7: Persistencia territorial. Los puntos sensibles señalan dónde la delimitación requiere mayor cautela.

La incertidumbre tiene varias fuentes que el clustering no resuelve: vigencia y precisión de DENUÉ; nombres comerciales poco informativos; procesos no declarados; dependencia espacial entre establecimientos; límites de la red hidrográfica disponible; y ausencia de drenaje, caudal y calidad del agua. Las pruebas estadísticas del perfil se usan para ordenar asociaciones del universo observado; DENUÉ no es una muestra probabilística y esas pruebas no corrigen dependencia espacial.




Figura 8: Equilibrio entre ruido, tamaño del grupo mayor y estabilidad de configuraciones seleccionadas.

9. Zonas prioritarias para validación

La prioridad debe entenderse como una secuencia de preguntas y no como un ranking automático de inversión.

Territorio	Pregunta prioritaria de validación
Santa Ana Xalmimilulco	Verificar vínculos entre confección, maquila, mezclilla y operaciones no registradas de lavado, limpieza o acabado.
Huejotzingo	Separar lavandería comercial, servicios a terceros y procesos textiles; identificar descargas y horarios reales.
Ixtapalucan, Tianguistenco y Coltzingo	Corroborar procesos asociados con tejido/hilado y maquila, consumo de agua y destino de residuos.
Texmelucan, Tlanalapan y Moyotzingo	Examinar conexiones productivas y sanitarias entre núcleos distintos; no asumir un solo corredor hidráulico.
Xoxtla–Coronango	Validar continuidad funcional, talleres activos y relación con redes de drenaje.
Amozoc	Distinguir lavanderías sectoriales de operaciones industriales y revisar la estabilidad de núcleos pequeños.
Puebla–Cholula–Cuautlancingo	Estratificar visitas por subnúcleo, actividad y persistencia; superponer red sanitaria y capacidad de tratamiento.

La selección de establecimientos para campo debe conservar ID DENUÉ, fuente, cluster, persistencia, señales productivas y modalidad amplia/estricta. Conviene incluir controles fuera de los núcleos y una fracción del ruido, porque validar únicamente los puntos más evidentes produciría una imagen sesgada de la actividad territorial.

10. Qué no concluye el estudio

- No identifica establecimientos contaminantes ni prueba incumplimiento.
- No convierte una cercanía cartográfica a un río en ruta de descarga.
- No demuestra que una categoría de lavandería/tintorería corresponda a lavandería industrial.
- No estima consumo, caudal, carga contaminante, producción ni toxicidad.
- No delimita áreas tributarias, cuencas sanitarias ni zonas de servicio.
- No demuestra que el cluster metropolitano sea homogéneo o deba atenderse con una sola solución.
- No convierte significancia estadística en causalidad, prioridad ambiental o viabilidad de obra.
- No selecciona un trazo de colector, una planta o una inversión.

Los mapas son instrumentos de priorización. Una concentración puede aumentar la eficiencia de un recorrido o de un muestreo, pero la decisión hidráulica depende de pendientes, redes existentes, conexiones, puntos de descarga, caudales, tecnología de tratamiento, permisos y costos. Estos datos no están contenidos en DENUÉ.

11. Siguiendo pasos

El siguiente avance debe integrar las concentraciones económicas identificadas con la **hidrología, el relieve y la red de drenaje**. El propósito es entender por qué rutas potenciales salen los residuos líquidos de estas agrupaciones, cómo se desplazan por gravedad o bombeo a través de la infraestructura sanitaria y de la superficie, en qué puntos pueden incorporarse a cauces o cuerpos de agua y hacia dónde continúan fluyendo. Esta reconstrucción debe combinarse con la información existente sobre colectores, atarjeas, pozos de visita, puntos de captación o intercepción, descargas conocidas y plantas de tratamiento, incluyendo su ubicación, área atendida, capacidad y estado operativo.

La integración permitirá pasar de una concentración de establecimientos a una hipótesis de funcionamiento hídrico territorial: qué agrupaciones podrían compartir una ruta de drenaje, qué receptores quedarían aguas abajo, qué infraestructura puede captar o tratar los flujos y dónde existen vacíos de información o posibles desconexiones. Las rutas resultantes serán hipótesis para verificar mediante inspección, aforo, trazadores, muestreo y datos del organismo operador; no se inferirán como descargas comprobadas únicamente por pendiente, cercanía o coincidencia cartográfica. Se propone esta secuencia:

1. Integrar establecimientos y clusters con cauces, cuerpos de agua, subcuencas, modelo de elevación y pendientes; después incorporar atarjeas, colectores, pozos de visita, cárcamos, captadores o interceptores, puntos de descarga y plantas de tratamiento existentes.
2. Diseñar una validación estratificada por territorio, perfil productivo, evidencia hídrica y persistencia, incluyendo unidades dispersas como contraste.
3. Verificar actividad, proceso, materias primas, limpieza de equipo, punto de descarga, horario, pretratamiento y estado operativo.
4. Realizar aforos y muestreo fisicoquímico con cadena de custodia en establecimientos, drenajes y receptores seleccionados.

5. Delimitar áreas realmente tributarias y rutas posibles por gravedad o bombeo; separar proximidad euclidiana de conexión hidráulica.
6. Evaluar capacidad disponible, tecnología y compatibilidad de efluentes de las plantas existentes.
7. Construir escenarios de caudal y carga con incertidumbre y comparar alternativas de prevención, pretratamiento, conducción y tratamiento mediante CAPEX, OPEX, riesgo, beneficio ambiental, permisos y gobernanza.

Lo ganado con este proyecto es una reducción auditable del territorio: de miles de registros aislados a concentraciones, perfiles y preguntas verificables. La próxima decisión no es dónde construir, sino dónde y cómo producir la evidencia hidráulica y ambiental que todavía falta.

Acceso a resultados

La matriz maestra está en `outputs/parte_2/01_matriz/`; la solución espacial en `outputs/parte_2/06_clusters/`; los perfiles en `outputs/parte_2/07_perfiles/`; los contrastes en `outputs/parte_2/08_sobrerrepresentacion/`; el atlas en `outputs/parte_2/12_atlas/`; y los subnúcleos y el explorador interactivo en `outputs/parte_2/14_segunda_pasada/`. El reporte maestro documenta métodos, advertencias y trazabilidad completa.

Referencias

- [1] Ankerst, M., Breunig, M. M., Kriegel, H.-P. y Sander, J. (1999). *OPTICS: Ordering Points To Identify the Clustering Structure*. Proceedings of ACM SIGMOD, 49–60.
- [2] Campello, R. J. G. B., Moulavi, D. y Sander, J. (2013). *Density-Based Clustering Based on Hierarchical Density Estimates*. Advances in Knowledge Discovery and Data Mining, 160–172.
- [3] Comisión Nacional de los Derechos Humanos (2017). *Recomendación No. 10/2017 sobre los ríos Atoyac, Xochiac y sus afluentes*.
- [4] Comisión Nacional del Agua (2011). *Declaratoria de clasificación de los ríos Atoyac y Xochiac o Hueyapan, y sus afluentes*. Diario Oficial de la Federación, 6 de julio de 2011.
- [5] Ecosistema Nacional Informático (2023). *Cuenca del Alto Atoyac 2021*. Datos de origen: SINA–Conagua; GeoPackage/GeoJSON; libre uso MX.
- [6] Ecosistema Nacional Informático (2023). *División municipal de la cuenca del Alto Atoyac 2020*. Datos de origen: Marco Geoestadístico 2020, INEGI; libre uso MX.
- [7] Ecosistema Nacional Informático (2023). *Red hidrográfica de la Cuenca del Alto Atoyac y su área de influencia 2006*. Datos de origen: Red Hidrográfica Digital de México, INEGI; libre uso MX.
- [8] Ester, M., Kriegel, H.-P., Sander, J. y Xu, X. (1996). *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise*. Proceedings of KDD, 226–231.
- [9] Instituto Nacional de Estadística y Geografía (2026). *Directorio Estadístico Nacional de Unidades Económicas (DENUE)*, descargas del 4 y 11 de septiembre de 2026 y diccionario de datos conservados en el repositorio.
- [10] Pérez Castresana, G. et al. (2023). *Salud ambiental en la Cuenca del Alto Atoyac: situación, peligros ambientales y acciones para reducir el riesgo de enfermedades crónicas no transmisibles*. Universidad Iberoamericana Puebla.